BAB I

PENDAHULUAN

1.1. Latar Belakang Masalah

Kualitas udara merupakan aspek penting dalam kesehatan lingkungan perkotaan karena udara ambien yang tercemar dapat meningkatkan risiko gangguan pernapasan, menurunkan kenyamanan aktivitas masyarakat, dan memperbesar beban kesehatan publik. Pedoman kualitas udara global menempatkan *Particulate Matter* 2.5 (PM2.5), *Particulate Matter* 10 (PM10), Ozon (O3), Nitrogen Dioksida (NO2), Sulfur Dioksida (SO2), dan Karbon Monoksida (CO) sebagai parameter penting dalam penilaian risiko kesehatan akibat pencemaran udara (*World Health Organization*, 2021). Kondisi tersebut relevan bagi DKI Jakarta sebagai wilayah metropolitan dengan intensitas transportasi, aktivitas perkantoran, permukiman padat, serta sumber emisi perkotaan yang tinggi. Oleh karena itu, pemantauan dan analisis kualitas udara tidak cukup hanya dipandang sebagai kegiatan pencatatan lingkungan, tetapi juga sebagai dasar penyusunan informasi peringatan dini dan kebijakan pengendalian pencemaran udara.

Di Indonesia, mutu udara ambien dikomunikasikan melalui Indeks Standar Pencemar Udara (ISPU). Berdasarkan Peraturan Menteri Lingkungan Hidup dan Kehutanan Nomor 14 Tahun 2020, ISPU merupakan angka tanpa satuan yang menggambarkan kondisi mutu udara ambien di lokasi tertentu berdasarkan dampaknya terhadap kesehatan manusia, nilai estetika, dan makhluk hidup lainnya (Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia, 2020). Dalam dataset penelitian ini, parameter yang tersedia dan digunakan terdiri dari *Particulate Matter* 2.5 (PM2.5), *Particulate Matter* 10 (PM10), Sulfur Dioksida (SO2), Karbon Monoksida (CO), Ozon (O3), dan Nitrogen Dioksida (NO2). Keenam parameter tersebut menjadi dasar analisis karena masing-masing merepresentasikan karakter pencemar udara yang berbeda.

PM2.5 adalah partikulat halus berdiameter aerodinamis tidak lebih dari 2,5 mikrometer, sedangkan PM10 adalah partikulat berdiameter aerodinamis tidak lebih dari 10 mikrometer. Ukuran PM2.5 yang lebih kecil membuatnya lebih mudah masuk ke saluran pernapasan bagian dalam, sehingga parameter ini penting dalam kajian risiko kualitas udara perkotaan. Sulfur Dioksida (SO2) adalah gas yang terbentuk dari pembakaran bahan bakar yang mengandung sulfur. Karbon Monoksida (CO) adalah gas hasil pembakaran tidak sempurna dari bahan bakar berbasis karbon. Ozon (O3) permukaan adalah polutan sekunder di troposfer yang terbentuk melalui reaksi fotokimia antara oksida nitrogen dan senyawa organik volatil dengan bantuan radiasi matahari. Nitrogen Dioksida (NO2) adalah gas reaktif yang terbentuk terutama dari proses pembakaran bersuhu tinggi, termasuk emisi kendaraan bermotor dan aktivitas pembakaran lainnya. Penjelasan parameter ini penting agar penelitian tidak hanya dipahami sebagai percobaan algoritma, tetapi juga sebagai analisis data lingkungan yang memiliki makna substantif.

Data yang digunakan dalam penelitian ini merupakan data sekunder ISPU DKI Jakarta yang bersumber dari Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui portal Satu Data Jakarta dan diakses dalam bentuk dataset terstruktur melalui Kaggle. Portal data pemerintah menjelaskan bahwa data ISPU DKI Jakarta diperoleh dari pengukuran Stasiun Pemantau Kualitas Udara di Provinsi DKI Jakarta (Pemerintah Provinsi DKI Jakarta, 2025). Dataset mentah yang diperiksa memiliki 5.539 baris dan 11 kolom dengan rentang tanggal 1 Januari 2010 sampai 28 Februari 2025. Namun, penelitian ini membatasi periode analisis pada 1 Januari 2020 sampai 31 Desember 2024, sehingga data yang digunakan berada pada lima tahun kalender penuh.

Pembatasan periode 2020-2024 dilakukan karena periode tersebut merepresentasikan fase pandemi, transisi, dan pasca-pandemi. Tahun 2020-2021 berkaitan dengan pembatasan mobilitas masyarakat, sedangkan tahun 2022-2024 berkaitan dengan pemulihan aktivitas perkotaan dan normalisasi mobilitas. Fokus waktu ini memberikan dasar ilmiah untuk menguji

apakah karakter kontribusi polutan terhadap status kualitas udara tidak sehat mengalami perbedaan antara masa pembatasan mobilitas dan masa setelah aktivitas masyarakat kembali meningkat. Tahun 2025 tidak digunakan karena data yang tersedia belum mencakup satu siklus tahunan penuh, sedangkan data sebelum 2020 tidak menjadi fokus karena penelitian diarahkan pada periode perubahan mobilitas yang berkaitan dengan pandemi dan pasca-pandemi.

Setelah pemotongan periode 2020-2024, pemeriksaan awal terhadap dataset menunjukkan terdapat 1.827 observasi harian. Satu baris dengan kategori TIDAK ADA DATA dikeluarkan dari data pemodelan karena kategori tersebut bukan status mutu udara. Dengan demikian, jumlah observasi yang digunakan untuk pemodelan adalah 1.826 hari. Target penelitian dibentuk sebagai klasifikasi biner, yaitu kelas Tidak Sehat+ dan kelas Bukan Tidak Sehat+. Kelas Tidak Sehat+ terdiri dari kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT, sedangkan kelas Bukan Tidak Sehat+ terdiri dari kategori BAIK dan SEDANG. Penamaan kelas pembanding mengikuti kategori asli pada kolom categori agar definisi target tetap konsisten dengan struktur dataset. Dalam konteks ini, SANGAT TIDAK SEHAT tetap dipahami sebagai kategori asli ISPU, sedangkan Tidak Sehat+ merupakan definisi operasional penelitian dan bukan kategori resmi baru dalam regulasi ISPU.

Target biner tersebut digunakan sebagai dasar pemodelan agar keluaran penelitian tetap berada pada kerangka klasifikasi status ISPU. Dengan demikian, model tidak diarahkan untuk memperkirakan nilai ISPU numerik, tetapi untuk membedakan hari yang termasuk Tidak Sehat+ dan Bukan Tidak Sehat+ secara terukur. Evaluasi model dilakukan menggunakan *Precision, Recall, F1-Score*, dan *Receiver Operating Characteristic-Area Under the Curve* (ROC-AUC) agar kemampuan model dalam membedakan kedua kelas dapat dinilai secara komprehensif.

Penelitian terdahulu yang dekat dengan konteks penelitian ini menunjukkan bahwa pembelajaran mesin (*machine learning*) dan pembelajaran mendalam (*deep learning*) telah banyak digunakan dalam analisis kualitas udara. (Hasna et al., 2024) membahas penggunaan

Random Forest untuk klasifikasi ISPU DKI Jakarta, sedangkan (Banjarnahor et al., 2025) membandingkan *Support Vector Machine* dan Random Forest pada kategori indeks kualitas udara Jakarta. (Karmoude et al., 2025) menunjukkan bahwa *machine learning* banyak digunakan dalam kajian kualitas udara, sementara (Radjabaycolle et al., 2025) memperlihatkan pemanfaatan LSTM dan SHAP pada studi kualitas udara Jakarta. Selain itu, (Yenkikar et al., 2025) memperkuat relevansi SHAP sebagai pendekatan interpretabilitas pada indeks kualitas udara. Berdasarkan penelitian tersebut, masih terdapat ruang untuk membandingkan Random Forest, XGBoost, LSTM, dan GRU dalam satu kerangka klasifikasi biner Tidak Sehat+ pada periode 2020-2024 serta melengkapi evaluasi model dengan interpretasi kontribusi fitur menggunakan SHAP.

Model ensemble yang digunakan dalam penelitian ini adalah Random Forest dan XGBoost. Random Forest bekerja dengan membangun banyak pohon keputusan dan menggabungkan hasilnya untuk meningkatkan stabilitas klasifikasi. XGBoost membangun model pohon secara bertahap dengan memperbaiki kesalahan model sebelumnya, sehingga sering digunakan pada data tabular yang memiliki hubungan tidak linear. Model pembelajaran mendalam (*deep learning*) yang digunakan adalah Long Short-Term Memory (LSTM) dan Gated Recurrent Unit (GRU). LSTM dan GRU digunakan karena keduanya dirancang untuk membaca data berurutan. Pada model LSTM dan GRU, jendela geser (*sliding window*) 14 hari digunakan dengan skema X[i-window:i] → y[i], yaitu data empat belas hari sebelumnya menjadi masukan untuk mengklasifikasikan status hari target berikutnya.

Selain membandingkan performa model, penelitian ini menempatkan interpretabilitas model sebagai komponen utama. Interpretabilitas diperlukan karena model klasifikasi kualitas udara sebaiknya tidak hanya menghasilkan label Tidak Sehat+ atau Bukan Tidak Sehat+, tetapi juga memberikan penjelasan mengenai kontribusi parameter polutan dan fitur waktu terhadap keputusan model. Untuk kebutuhan tersebut, penelitian ini menggunakan SHapley Additive exPlanations (SHAP). SHAP digunakan untuk mengukur kontribusi fitur terhadap keputusan

klasifikasi model, bukan untuk membuktikan hubungan sebab-akibat. Dengan demikian, hasil interpretasi dibaca sebagai kontribusi fitur menurut model yang dianalisis.

Berdasarkan uraian tersebut, penelitian ini diarahkan untuk membandingkan performa model Random Forest, XGBoost, LSTM, dan GRU dalam klasifikasi status ISPU DKI Jakarta, serta mendiagnosis kontribusi fitur polutan dan fitur waktu menggunakan SHAP. Fokus penelitian berada pada keterhubungan antara data ISPU 2020-2024, target klasifikasi Tidak Sehat+, skema evaluasi klasifikasi, dan interpretabilitas model. Dengan demikian, penelitian ini tidak hanya bertujuan memilih model dengan performa terbaik, tetapi juga menyusun dasar analisis yang mampu menjelaskan fitur pencemar udara dan konteks waktu yang berkontribusi terhadap status kualitas udara tidak sehat di Jakarta.

1.2. Identifikasi Permasalahan

Berdasarkan latar belakang yang telah diuraikan, permasalahan dalam penelitian ini dapat diidentifikasi sebagai berikut:

1. Data ISPU DKI Jakarta perlu dianalisis secara lebih operasional untuk membentuk model yang mampu membedakan hari Tidak Sehat+ dan Bukan Tidak Sehat+ secara terukur.
2. Periode 2020-2024 mencakup fase pandemi, transisi, dan pasca-pandemi, sehingga kontribusi polutan terhadap status kualitas udara perlu dianalisis dalam kerangka waktu yang jelas.
3. Penelitian terdahulu dalam konteks kualitas udara Jakarta telah menunjukkan pemanfaatan model pembelajaran mesin (*machine learning*) maupun pembelajaran mendalam (*deep learning*) untuk klasifikasi atau prediksi kualitas udara. Namun, kajian yang secara terpadu membandingkan Random Forest, XGBoost, LSTM, dan GRU pada target klasifikasi biner Tidak Sehat+ dan Bukan Tidak Sehat+ dengan pembagian data kronologis serta metrik evaluasi yang sama masih terbatas. Kondisi tersebut menunjukkan perlunya pengujian keempat model dalam satu kerangka eksperimen agar perbandingan kinerja yang dihasilkan lebih adil dan dapat dipertanggungjawabkan.

4. Model klasifikasi kualitas udara tidak cukup hanya dinilai berdasarkan performa, karena kontribusi fitur polutan terhadap keputusan model perlu dijelaskan agar hasil penelitian dapat dipahami secara ilmiah.
5. Diperlukan pendekatan interpretabilitas model menggunakan SHapley Additive exPlanations (SHAP) untuk mendiagnosis kontribusi fitur polutan dan fitur waktu terhadap keputusan klasifikasi status Tidak Sehat+.

1.3. Perumusan Masalah

Berdasarkan identifikasi permasalahan tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Pengembangan model klasifikasi biner status ISPU DKI Jakarta periode 2020-2024 untuk membedakan kelas Tidak Sehat+ dan Bukan Tidak Sehat+ dengan membandingkan kinerja Random Forest, XGBoost, LSTM, dan GRU.
2. Pengembangan analisis interpretabilitas model menggunakan SHAP untuk menjelaskan kontribusi fitur polutan dan fitur waktu terhadap keputusan klasifikasi status Tidak Sehat+.

1.4. Tujuan dan Manfaat

1.4.1. Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Membangun dan membandingkan model Random Forest, XGBoost, LSTM, dan GRU untuk klasifikasi biner status ISPU Tidak Sehat+ dan Bukan Tidak Sehat+ pada data ISPU DKI Jakarta periode 2020-2024.
2. Mengevaluasi performa model menggunakan metrik klasifikasi yang mencakup Precision, Recall, F1-Score, dan ROC-AUC.
3. Menerapkan SHAP pada model berbasis ensemble yang dipilih setelah proses evaluasi untuk menginterpretasikan kontribusi fitur polutan dan fitur waktu terhadap hasil klasifikasi status Tidak Sehat+.

1.4.2. Manfaat Penelitian

Manfaat penelitian ini disusun berdasarkan pihak yang memperoleh kegunaan langsung dari hasil pengembangan model dan analisis interpretabilitas.

1. Bagi penulis, penelitian ini menjadi sarana penerapan ilmu pengolahan data, pembelajaran mesin, pembelajaran mendalam, dan kecerdasan buatan terjelaskan pada studi kasus kualitas udara.
2. Bagi objek penelitian, hasil penelitian dapat menjadi bahan kajian berbasis data untuk memahami klasifikasi status ISPU Jakarta serta kontribusi parameter pencemar terhadap kondisi Tidak Sehat+.
3. Bagi pembaca dan peneliti selanjutnya, penelitian ini dapat menjadi referensi mengenai perbandingan model ensemble dan pembelajaran mendalam, pembagian data kronologis, pencegahan kebocoran target, serta penggunaan SHAP pada klasifikasi kualitas udara.

1.5. Metode Penelitian

Penelitian ini menggunakan metode kuantitatif dengan pendekatan eksperimental komputasional. Pendekatan kuantitatif digunakan karena penelitian memanfaatkan data numerik polutan ISPU, sedangkan pendekatan eksperimental digunakan karena penelitian membandingkan beberapa algoritma dalam skenario pemodelan yang sama. Seluruh proses dilakukan menggunakan Python dalam lingkungan Google Colaboratory agar tahapan penelitian dapat ditelusuri dan direproduksi.

Tahapan penelitian dimulai dari pemahaman data, pemotongan periode 2020-2024, pembersihan data, pembentukan target biner, rekayasa fitur polutan dan fitur waktu, pembagian data berbasis waktu, pelatihan model, evaluasi model, dan interpretasi SHAP.

1.5.1. Teknik Pengumpulan Data

A. Observasi

Observasi dilakukan terhadap data sekunder berupa dataset publik ISPU DKI Jakarta. Data utama yang digunakan bersumber dari Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui

portal Satu Data Jakarta dan diakses dalam bentuk dataset terstruktur melalui Kaggle. Data tersebut memuat kolom tanggal, stasiun pemantauan, PM2.5, PM10, SO2, CO, O3, NO2, max, critical, dan categori. Penelitian ini tidak menggunakan wawancara karena seluruh analisis didasarkan pada data sekunder kuantitatif dan studi pustaka.

B. Studi Pustaka

Studi pustaka dilakukan dengan menelaah regulasi ISPU, dokumen data terbuka, dan artikel ilmiah yang relevan dengan klasifikasi kualitas udara, model ensemble, pembelajaran mendalam (*deep learning*), dan interpretabilitas SHAP. Literatur utama dipilih berdasarkan kedekatan dengan penelitian, terutama penelitian yang menggunakan data kualitas udara Jakarta, Random Forest untuk klasifikasi ISPU, komparasi model pembelajaran mesin (*machine learning*) pada kualitas udara Jakarta, serta SHAP untuk interpretasi model kualitas udara.

1.5.2. Metode Analisis Data

Metode analisis data dalam penelitian ini dilakukan melalui tahapan berikut:

1. Pemahaman data (*data understanding*), yaitu memahami struktur dataset, rentang tanggal, jumlah baris, jumlah kolom, serta makna setiap variabel.
2. Prapemrosesan data (*data preprocessing*), yaitu memfilter periode 1 Januari 2020 sampai 31 Desember 2024 dan mengeluarkan kategori TIDAK ADA DATA dari data pemodelan.
3. Penanganan nilai kosong dan imputasi (*missing values* dan imputasi), yaitu memeriksa nilai kosong, membentuk indikator *missing values*, kemudian mengisi nilai kosong pada kolom polutan menggunakan interpolasi berbasis waktu untuk celah pendek, median bulanan dari data latih, dan median global dari data latih sebagai langkah akhir imputasi.
4. Rekayasa fitur (*feature engineering*), yaitu membentuk fitur polutan utama, fitur waktu, indikator akhir pekan, indikator pasca-pandemi, serta indikator *missing values*. Fitur waktu yang digunakan meliputi tahun, bulan, hari dalam minggu, indikator akhir pekan, dan indikator pasca-pandemi agar model memiliki konteks temporal yang sesuai dengan periode pandemi, transisi, dan pasca-pandemi.

5. Pembentukan target (*target engineering*), yaitu mengubah kategori ISPU menjadi target biner Tidak Sehat+ dan Bukan Tidak Sehat+. Kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT diberi label positif, sedangkan BAIK dan SEDANG diberi label pembanding.
6. Pencegahan kebocoran target (*target leakage*), yaitu tidak menggunakan kolom max dan critical sebagai fitur model karena kedua kolom tersebut merupakan informasi turunan yang sangat dekat dengan pembentukan kategori ISPU.
7. Pembagian data kronologis, yaitu pembagian data dilakukan secara kronologis, yaitu data 2020-2023 sebagai data latih dan data 2024 sebagai data uji.
8. Pemodelan (*modeling*), yaitu melatih Random Forest dan XGBoost pada data tabular, serta melatih LSTM dan GRU dengan jendela geser (*sliding window*) 14 hari untuk membaca pola urutan waktu.
9. Evaluasi model (*model evaluation*), yaitu membandingkan model menggunakan Precision, Recall, F1-Score, dan ROC-AUC.
10. Analisis interpretabilitas (*explainability analysis*), yaitu menggunakan SHAP pada model berbasis ensemble yang dipilih setelah proses evaluasi untuk menjelaskan kontribusi fitur terhadap keputusan klasifikasi kelas Tidak Sehat+.

1.6. Ruang Lingkup

Agar penelitian tetap terarah, ruang lingkup penelitian ini dibatasi sebagai berikut:

1. Data yang digunakan adalah data sekunder ISPU DKI Jakarta yang bersumber dari DLH DKI Jakarta melalui Satu Data Jakarta dan diakses melalui Kaggle.
2. Dataset awal mencakup rentang 1 Januari 2010 sampai 28 Februari 2025. Penelitian ini membatasi analisis pada periode 1 Januari 2020 sampai 31 Desember 2024 karena fokus penelitian diarahkan untuk membandingkan karakter kualitas udara pada masa pandemi, transisi, dan pasca-pandemi. Data tahun 2010-2019 tidak digunakan karena berada di luar

fokus periode penelitian, sedangkan data tahun 2025 tidak digunakan karena belum mencakup satu tahun penuh.

3. Variabel *input* utama dibatasi pada enam parameter polutan, yaitu PM2.5, PM10, SO2, CO, O3, dan NO2, serta fitur pendukung berupa tahun, bulan, hari dalam minggu, indikator akhir pekan, indikator pasca-pandemi, dan indikator *missing values*.
4. Kolom max dan critical tidak digunakan sebagai fitur model karena berpotensi menyebabkan kebocoran target (*target leakage*).
5. Target penelitian adalah klasifikasi biner status ISPU, yaitu Tidak Sehat+ dan Bukan Tidak Sehat+. Tidak Sehat+ terdiri dari kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT, sedangkan Bukan Tidak Sehat+ terdiri dari kategori BAIK dan SEDANG.
6. Model yang dibandingkan adalah Random Forest, XGBoost, LSTM, dan GRU. LSTM dan GRU menggunakan pendekatan jendela geser (*sliding window*) 14 hari dengan skema X[i-window:i] → y[i] untuk memanfaatkan informasi urutan waktu dari empat belas hari sebelumnya.
7. Evaluasi model menggunakan metrik klasifikasi, yaitu Precision, Recall, F1-Score, dan ROC-AUC.
8. Analisis interpretabilitas dilakukan menggunakan SHAP pada model berbasis ensemble yang dipilih setelah proses evaluasi, sehingga interpretasi difokuskan pada kontribusi fitur terhadap keputusan klasifikasi.
9. Penelitian tidak memasukkan variabel meteorologi eksternal seperti suhu, kelembapan, curah hujan, arah angin, atau kecepatan angin karena variabel tersebut tidak tersedia pada dataset utama yang digunakan.
10. Implementasi penelitian dilakukan menggunakan Python dalam lingkungan Google Colaboratory, dengan pustaka utama Pandas, NumPy, Scikit-learn, XGBoost, TensorFlow/Keras, Matplotlib, Seaborn, dan SHAP.

1.7. Hipotesis

Hipotesis penelitian dirumuskan secara operasional berdasarkan tujuan pengembangan model dan interpretasi fitur.

H0(1): Tidak terdapat perbedaan kinerja yang menonjol antara model ensemble dan model pembelajaran mendalam dalam klasifikasi status ISPU Tidak Sehat+ dan Bukan Tidak Sehat+ berdasarkan Precision, Recall, F1-Score, dan ROC-AUC.

H1(1): Terdapat perbedaan kinerja antara model ensemble dan model pembelajaran mendalam, dengan dugaan model ensemble memberikan kinerja lebih baik karena data penelitian berbentuk tabular.

H0(2): Tidak terdapat fitur polutan atau fitur waktu yang dominan dalam keputusan klasifikasi model berdasarkan nilai rata-rata absolut SHAP.

H1(2): Terdapat fitur polutan atau fitur waktu yang dominan dalam keputusan klasifikasi model berdasarkan nilai rata-rata absolut SHAP.

Penerimaan atau penolakan hipotesis dilakukan berdasarkan hasil evaluasi model pada data uji 2024 dan hasil interpretasi SHAP pada model ensemble terpilih.