BAB II

LANDASAN TEORI

2.1. Tinjauan Pustaka

Tinjauan pustaka pada penelitian ini disusun sebagai dasar teoritis bagi pembahasan Indeks Standar Pencemar Udara (ISPU), parameter pencemar udara, klasifikasi kualitas udara, model pembelajaran mesin, model pembelajaran mendalam, evaluasi klasifikasi, pencegahan kebocoran target, serta interpretabilitas model menggunakan SHapley Additive exPlanations (SHAP). Landasan teori ini diperlukan agar penelitian tidak hanya dipahami sebagai penerapan algoritma, tetapi juga sebagai kajian data lingkungan yang memiliki konteks kesehatan, kebijakan publik, dan metodologi komputasional.

2.1.1. Indeks Standar Pencemar Udara

Indeks Standar Pencemar Udara atau ISPU merupakan indikator yang digunakan untuk menyampaikan kondisi mutu udara ambien kepada masyarakat dalam bentuk angka tanpa satuan. Berdasarkan Peraturan Menteri Lingkungan Hidup dan Kehutanan Republik Indonesia Nomor 14 Tahun 2020, ISPU menggambarkan kondisi mutu udara ambien di lokasi tertentu berdasarkan dampaknya terhadap kesehatan manusia, nilai estetika, dan makhluk hidup lainnya (Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia, 2020). Dengan adanya ISPU, informasi kualitas udara dapat dikomunikasikan secara lebih sederhana karena nilai parameter pencemar udara yang bersifat teknis diterjemahkan ke dalam kategori mutu udara.

Kategori ISPU ditetapkan berdasarkan rentang angka resmi dalam Peraturan Menteri Lingkungan Hidup dan Kehutanan Nomor P.14/Menlhk/Setjen/Kum.1/7/2020 tentang Indeks Standar Pencemar Udara. Rentang tersebut digunakan untuk menjelaskan kategori kualitas udara yang muncul pada dataset sebelum target penelitian dibentuk.

Tabel II. 1 Kategori ISPU dan Rentang Nilai

Kategori ISPU	Status Warna	Rentang Nilai ISPU	Keterangan Penelitian
Baik	Hijau	1-50	Kategori asli ISPU dan termasuk Bukan Tidak Sehat+ pada target biner.
Sedang	Biru	51-100	Kategori asli ISPU dan termasuk Bukan Tidak Sehat+ pada target biner.
Tidak Sehat	Kuning	101-200	Kategori asli ISPU dan termasuk Tidak Sehat+ pada target biner.
Sangat Tidak Sehat	Merah	201-300	Kategori asli ISPU dan termasuk Tidak Sehat+ pada target biner.
Berbahaya	Hitam	>=301	Kategori resmi ISPU, tetapi tidak muncul pada data penelitian periode 2020-2024.

Sumber: Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia (2020), diolah oleh penulis (2026)

Dalam penelitian ini, ISPU digunakan sebagai dasar pembentukan target klasifikasi. Status kualitas udara tidak diperlakukan sebagai nilai numerik yang diprediksi melalui regresi, melainkan sebagai kategori yang diklasifikasikan ke dalam dua kelompok, yaitu Tidak Sehat+ dan Bukan Tidak Sehat+. Kelompok Tidak Sehat+ merupakan gabungan dari kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT, sedangkan kelompok Bukan Tidak Sehat+ merupakan gabungan dari kategori BAIK dan SEDANG. Penggabungan kategori tersebut dilakukan agar model diarahkan untuk mengenali kondisi kualitas udara yang berpotensi lebih berisiko terhadap kesehatan masyarakat.

Istilah Tidak Sehat+ dalam penelitian ini bukan merupakan kategori resmi baru dalam regulasi ISPU, melainkan definisi operasional penelitian untuk kebutuhan klasifikasi biner. Dengan demikian, istilah tersebut digunakan untuk membedakan hari dengan kondisi kualitas udara yang perlu mendapat perhatian lebih tinggi dari hari dengan kualitas udara yang masih berada pada kategori baik atau sedang. Istilah prediksi pada penelitian ini juga dimaknai sebagai prediksi status atau kelas kualitas udara, bukan prediksi nilai numerik ISPU.

2.1.2. Parameter Pencemar Udara

Parameter pencemar udara merupakan variabel utama yang digunakan untuk menilai kualitas udara. Pada penelitian ini, parameter yang digunakan terdiri dari Particulate Matter 2.5

(PM2.5), Particulate Matter 10 (PM10), Sulfur Dioksida (SO2), Karbon Monoksida (CO), Ozon (O3), dan Nitrogen Dioksida (NO2). Keenam parameter tersebut dipilih karena tersedia dalam dataset ISPU DKI Jakarta dan merepresentasikan karakter pencemar udara yang berbeda. Pedoman kualitas udara *global* menempatkan Particulate Matter 2.5 (PM2.5), Particulate Matter 10 (PM10), Ozon (O3), Nitrogen Dioksida (NO2), Sulfur Dioksida (SO2), dan Karbon Monoksida (CO) sebagai parameter penting dalam penilaian risiko kesehatan akibat pencemaran udara (World Health Organization, 2021).

PM2.5 merupakan partikulat halus dengan diameter aerodinamis tidak lebih dari 2,5 mikrometer. Ukurannya yang sangat kecil membuat partikel ini dapat masuk lebih dalam ke saluran pernapasan sehingga sering menjadi perhatian utama dalam kajian kualitas udara dan kesehatan lingkungan. PM10 merupakan partikulat dengan diameter aerodinamis tidak lebih dari 10 mikrometer. Meskipun ukurannya lebih besar dibandingkan PM2.5, PM10 tetap relevan karena dapat masuk ke sistem pernapasan dan menunjukkan kontribusi pencemar berbasis debu, aktivitas lalu lintas, maupun sumber partikulat lain.

Sulfur Dioksida (SO2) merupakan gas yang umumnya berkaitan dengan pembakaran bahan bakar yang mengandung sulfur. Karbon Monoksida (CO) merupakan gas hasil pembakaran tidak sempurna dari bahan bakar berbasis karbon. Ozon (O3) permukaan merupakan polutan sekunder yang terbentuk melalui reaksi fotokimia antara senyawa prekursor dengan bantuan sinar matahari. Nitrogen Dioksida (NO2) merupakan gas reaktif yang banyak dikaitkan dengan proses pembakaran bersuhu tinggi, termasuk emisi kendaraan bermotor dan aktivitas perkotaan lainnya. Dalam penelitian ini, parameter polutan tidak hanya dipandang sebagai angka *input* model, tetapi juga sebagai representasi kondisi lingkungan yang dapat membantu menjelaskan status kualitas udara.

2.1.3. Klasifikasi Kualitas Udara

Klasifikasi merupakan pendekatan analisis data yang bertujuan memetakan sekumpulan fitur *input* ke dalam kelas atau kategori tertentu. Dalam konteks kualitas udara, klasifikasi dapat

digunakan untuk menentukan apakah kondisi udara berada pada kelas baik, sedang, tidak sehat, atau kategori lain sesuai definisi yang digunakan. Berbeda dengan regresi yang menghasilkan nilai numerik, klasifikasi menghasilkan label kelas sebagai keluaran model.

Penelitian ini menggunakan pendekatan klasifikasi biner. Target yang digunakan adalah status Tidak Sehat+ dan Bukan Tidak Sehat+. Kelas Tidak Sehat+ menjadi kelas positif karena merepresentasikan kondisi kualitas udara yang lebih berisiko, sedangkan Bukan Tidak Sehat+ menjadi kelas pembanding. Pendekatan ini selaras dengan tujuan penelitian, yaitu membangun model yang mampu membedakan hari dengan status kualitas udara tidak sehat dari hari yang tidak termasuk kategori tersebut.

Kategori asli tetap ditampilkan pada BAB IV sebagai bagian dari *data understanding*, sedangkan pemodelan menggunakan target biner agar fokus penelitian diarahkan pada pemisahan kondisi Tidak Sehat+ dan Bukan Tidak Sehat+. Kategori TIDAK ADA DATA tidak digunakan dalam pemodelan karena tidak merepresentasikan status kualitas udara yang dapat dipelajari model.

$$\text{Proporsi Kelas} = (\text{Jumlah Observasi Kelas} / \text{Total Observasi}) \times 100\%$$

Rumus proporsi kelas digunakan untuk membaca distribusi kategori asli, distribusi target biner, dan proporsi kelas pada pembagian data latih serta data uji. Nilai persentase yang dihasilkan membantu menjelaskan apakah komposisi kelas relatif seimbang atau cenderung didominasi oleh salah satu kelas.

Tabel II. 2 Definisi Operasional Target Biner

Kategori Asli Dataset	Definisi Operasional	Peran dalam Pemodelan
BAIK	Bukan Tidak Sehat+	Kelas negatif
SEDANG	Bukan Tidak Sehat+	Kelas negatif
TIDAK SEHAT	Tidak Sehat+	Kelas positif
SANGAT TIDAK SEHAT	Tidak Sehat+	Kelas positif
TIDAK ADA DATA	Dikeluarkan	Tidak digunakan dalam pemodelan

Sumber: Diolah oleh penulis (2026)

(Liu et al., 2024) menunjukkan bahwa klasifikasi kelas kualitas udara dapat dilakukan menggunakan metode *machine learning* berdasarkan data pemantauan kualitas udara. Literatur tersebut memperkuat posisi penelitian ini bahwa data pencemar udara dapat digunakan untuk membangun model klasifikasi status kualitas udara. Namun, penelitian ini tetap memiliki batasan yang jelas karena tidak diarahkan untuk memprediksi nilai numerik ISPU, melainkan untuk membedakan status Tidak Sehat+ dan Bukan Tidak Sehat+.

2.1.4. Data Sekunder dan Data Deret Waktu Harian

Data sekunder adalah data yang tidak dikumpulkan langsung oleh peneliti melalui pengukuran lapangan, melainkan diperoleh dari sumber yang telah tersedia. Pada penelitian ini, data yang digunakan merupakan data sekunder ISPU DKI Jakarta yang bersumber dari Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui Satu Data Jakarta dan diakses dalam bentuk dataset terstruktur melalui Kaggle. Penggunaan data sekunder sesuai dengan karakter penelitian yang berfokus pada analisis komputasional terhadap data historis kualitas udara.

Data ISPU memiliki karakter deret waktu harian karena setiap observasi berkaitan dengan tanggal tertentu. Karakter ini penting karena kualitas udara dapat dipengaruhi oleh pola temporal, seperti perubahan aktivitas masyarakat, hari kerja dan akhir pekan, serta perubahan periode pandemi, transisi, dan pasca-pandemi. Oleh karena itu, selain fitur polutan utama, penelitian ini juga menggunakan fitur waktu seperti tahun, bulan, hari dalam minggu, indikator akhir pekan, indikator pasca-pandemi, dan indikator *missing values*.

Meskipun data memiliki urutan waktu, penelitian ini tidak diarahkan sebagai peramalan nilai ISPU numerik. Urutan waktu digunakan untuk menjaga validitas pembagian data secara kronologis dan untuk membentuk masukan sekuensial pada model Long Short-Term Memory (LSTM) dan Gated Recurrent Unit (GRU). Dengan demikian, pendekatan deret waktu dalam penelitian ini tetap berada dalam kerangka klasifikasi status kualitas udara.

2.1.5. *Machine Learning*

Machine learning merupakan cabang kecerdasan buatan yang memungkinkan sistem mempelajari pola dari data tanpa harus diprogram secara eksplisit untuk setiap aturan keputusan. Pada penelitian kualitas udara, *machine learning* dapat digunakan untuk mempelajari hubungan antara parameter pencemar udara, fitur waktu, dan status kualitas udara. (Karmoude et al., 2025) menjelaskan bahwa metode *machine learning* banyak digunakan dalam kajian kualitas udara karena mampu menangani pola data yang kompleks dan tidak selalu linear. Dalam penelitian ini, *machine learning* digunakan untuk membangun model klasifikasi berdasarkan data tabular yang terdiri dari parameter polutan dan fitur pendukung waktu. Model *machine learning* yang digunakan adalah Random Forest dan XGBoost. Keduanya termasuk dalam kelompok model ensemble yang menggabungkan beberapa model dasar untuk meningkatkan stabilitas dan kemampuan prediksi.

2.1.6. *Ensemble Learning*

Ensemble learning adalah pendekatan pemodelan yang menggabungkan beberapa model untuk menghasilkan klasifikasi yang lebih stabil dibandingkan model tunggal. Prinsip utama dari pendekatan ini adalah bahwa gabungan beberapa model dapat mengurangi kelemahan satu model tertentu, baik dari sisi variansi maupun bias. Dalam klasifikasi kualitas udara, pendekatan ensemble banyak digunakan karena data lingkungan sering memiliki hubungan antarvariabel yang tidak linear.

Dalam penelitian ini, pendekatan ensemble direpresentasikan oleh Random Forest dan XGBoost. Random Forest menggunakan mekanisme bagging, sedangkan XGBoost menggunakan mekanisme boosting. Keduanya relevan untuk data tabular karena mampu membaca pola dari fitur polutan dan fitur waktu tanpa mengharuskan hubungan antarvariabel berbentuk linear. (Fahim et al., 2025) menunjukkan bahwa teknik ensemble dapat digunakan untuk meningkatkan klasifikasi indeks kualitas udara, terutama ketika model perlu mengevaluasi hubungan antara parameter pencemar dan kelas kualitas udara.

2.1.7. Random Forest

Random Forest merupakan algoritma ensemble yang membangun banyak pohon keputusan kemudian menggabungkan hasil prediksi dari pohon-pohon tersebut. Pada masalah klasifikasi, keputusan akhir Random Forest umumnya ditentukan berdasarkan suara mayoritas dari sejumlah pohon keputusan. Pendekatan ini membantu meningkatkan stabilitas model karena keputusan tidak bergantung hanya pada satu pohon.

Random Forest sering digunakan pada data tabular karena mampu menangani hubungan nonlinear antarfitur, relatif kuat terhadap variasi data, dan dapat memberikan gambaran mengenai kontribusi fitur melalui ukuran kepentingan fitur. Dalam konteks ISPU, Random Forest relevan karena data yang digunakan terdiri dari parameter polutan dan fitur waktu yang bersifat terstruktur.

(Hasna et al., 2024) menggunakan Random Forest untuk klasifikasi ISPU DKI Jakarta tahun 2022. (Banjarnahor et al., 2025) juga membandingkan Random Forest dengan Support Vector Machine untuk kategori kualitas udara Jakarta. Kedua penelitian tersebut menunjukkan bahwa Random Forest telah digunakan dalam konteks kualitas udara Jakarta, sehingga pemakaian Random Forest pada penelitian ini memiliki dasar empiris yang dekat dengan objek penelitian.

2.1.8. XGBoost

Extreme Gradient Boosting (XGBoost) merupakan algoritma ensemble berbasis pohon keputusan yang bekerja dengan prinsip *boosting*. Berbeda dengan Random Forest yang membangun banyak pohon secara relatif independen, XGBoost membangun pohon secara bertahap dengan memperbaiki kesalahan dari model sebelumnya. Pendekatan ini memungkinkan XGBoost menangkap pola yang kompleks pada data tabular.

XGBoost banyak digunakan karena memiliki mekanisme regularisasi, mampu menangani hubungan nonlinear, dan menunjukkan performa kompetitif pada berbagai masalah klasifikasi. Dalam penelitian ini, XGBoost digunakan sebagai salah satu model ensemble untuk

dibandingkan dengan Random Forest, LSTM, dan GRU. (Rajagukguk et al., 2025) membandingkan XGBoost, Random Forest, dan Logistic Regression untuk klasifikasi ISPU Jakarta. (Sajiwo et al., 2024) juga menggunakan XGBoost untuk klasifikasi ISPU DKI Jakarta dengan pendekatan penanganan data tidak seimbang. Kedua penelitian tersebut memperkuat relevansi XGBoost dalam studi klasifikasi kualitas udara Jakarta.

2.1.9. *Deep Learning*

Deep learning merupakan pendekatan pembelajaran mesin yang menggunakan jaringan saraf berlapis untuk mempelajari pola data yang kompleks. Berbeda dengan model pembelajaran mesin konvensional yang umumnya bekerja pada data tabular secara langsung, model *deep learning* dapat dirancang untuk membaca struktur data tertentu, termasuk data berurutan.

Dalam penelitian ini, model *deep learning* yang digunakan adalah Long Short-Term Memory (LSTM) dan Gated Recurrent Unit (GRU). Keduanya dipilih karena mampu membaca pola urutan waktu dari data harian. Namun, pemakaian LSTM dan GRU pada penelitian ini tetap diarahkan untuk klasifikasi status ISPU, bukan untuk memprediksi nilai numerik ISPU. Data empat belas hari sebelumnya digunakan sebagai masukan untuk mengklasifikasikan kelas status pada hari target berikutnya dengan skema X[i-window:i] → y[i].

(Jalali et al., 2025) menunjukkan bahwa pendekatan berbasis kecerdasan buatan dapat digunakan dalam aplikasi kualitas udara, termasuk klasifikasi dan model berbasis pembelajaran mendalam. Sementara itu, (Radjabaycolle et al., 2025) menggunakan LSTM dan SHAP pada studi kualitas udara Jakarta. Literatur tersebut menjadi dasar bahwa model sekuensial dapat digunakan dalam kajian kualitas udara, meskipun penelitian ini tetap membatasi keluaran model pada kelas Tidak Sehat+ dan Bukan Tidak Sehat+.

2.1.10. Long Short-Term Memory

Long Short-Term Memory atau LSTM merupakan salah satu jenis jaringan saraf berulang yang dirancang untuk menangani data berurutan. LSTM memiliki mekanisme gerbang yang membantu model menyimpan, melupakan, dan memperbarui informasi dari urutan data

sebelumnya. Mekanisme tersebut membuat LSTM sering digunakan pada data yang memiliki pola temporal.

Dalam penelitian ini, LSTM digunakan untuk membaca urutan data ISPU harian melalui pendekatan *sliding window* 14 hari. Artinya, data empat belas hari sebelumnya menjadi masukan untuk mengklasifikasikan status kualitas udara pada hari target berikutnya dengan skema X[i-window:i] → y[i]. Dengan cara ini, LSTM tidak hanya membaca kondisi polutan pada satu hari, tetapi juga pola historis jangka pendek yang mendahului status tersebut.

Meskipun LSTM sering ditemukan dalam penelitian peramalan deret waktu, penggunaan LSTM pada penelitian ini diposisikan sebagai model klasifikasi sekuensial. Oleh karena itu, pembahasan LSTM pada penelitian ini tidak diarahkan pada prediksi nilai ISPU, melainkan pada kemampuan model membaca pola urutan waktu untuk membedakan status Tidak Sehat+ dan Bukan Tidak Sehat+.

2.1.11. Gated Recurrent Unit

Gated Recurrent Unit atau GRU merupakan varian jaringan saraf berulang yang juga dirancang untuk data berurutan. GRU memiliki struktur gerbang yang lebih sederhana dibandingkan LSTM, sehingga secara umum dapat menjadi alternatif model sekuensial yang lebih ringan. Walaupun lebih sederhana, GRU tetap mampu mempertahankan informasi penting dari urutan data sebelumnya.

Dalam penelitian ini, GRU digunakan dengan pendekatan yang sama seperti LSTM, yaitu menggunakan *sliding window* 14 hari. Tujuan penggunaan GRU adalah membandingkan kemampuan model sekuensial yang lebih sederhana dengan LSTM serta model ensemble berbasis data tabular. Dengan demikian, perbandingan model mencakup dua kelompok utama, yaitu model ensemble dan model pembelajaran mendalam berbasis urutan waktu.

2.1.12. *Sliding Window*

Sliding window adalah teknik pembentukan data masukan dengan mengambil sejumlah observasi historis sebagai satu jendela *input*. Pada data harian, pendekatan ini memungkinkan

model membaca informasi dari beberapa hari sebelumnya untuk mengklasifikasikan kondisi pada hari target berikutnya. Teknik ini relevan untuk LSTM dan GRU karena kedua model tersebut membutuhkan data berbentuk urutan.

Dalam penelitian ini, ukuran jendela yang digunakan adalah 14 hari. Dengan demikian, data empat belas hari sebelumnya digunakan sebagai masukan untuk mengklasifikasikan status ISPU pada hari target berikutnya dengan skema X[i-window:i] → y[i]. Pemilihan jendela ini bertujuan memberi konteks historis jangka pendek kepada model tanpa mengubah arah penelitian menjadi peramalan nilai ISPU. *Output* yang diprediksi tetap berupa kelas biner, yaitu Tidak Sehat+ atau Bukan Tidak Sehat+.

2.1.13. Data Preprocessing

Data preprocessing merupakan tahap penyiapan data sebelum model dilatih dan dievaluasi. Pada penelitian berbasis data sekunder, preprocessing mencakup seleksi periode, pembersihan kategori yang tidak valid, pembentukan target penelitian, penanganan *missing values*, imputasi, *scaling*, dan *feature engineering*. Tahap ini diperlukan agar data yang masuk ke model sesuai dengan tujuan analisis dan tidak memuat informasi yang dapat menimbulkan bias evaluasi.

Dalam konteks klasifikasi status ISPU, preprocessing juga mencakup pemisahan antara kolom yang digunakan sebagai fitur, kolom yang menjadi sumber target, dan kolom yang harus dikecualikan. Pemisahan tersebut penting agar model tidak menggunakan informasi yang secara langsung sudah merepresentasikan label target.

2.1.14. Missing Values dan Imputasi

Missing values adalah nilai yang tidak tersedia pada suatu kolom data. Nilai kosong dapat muncul karena gangguan pencatatan, keterbatasan alat pemantauan, perubahan sistem, atau faktor teknis lain. Jika tidak ditangani, *missing values* dapat mengganggu proses pelatihan model dan menurunkan kualitas interpretasi hasil.

Imputasi digunakan untuk mengisi nilai kosong dengan pendekatan tertentu. Pada data numerik, median dan interpolasi dapat digunakan sesuai karakter data dan kebutuhan analisis. Selain

mengisi nilai kosong, indikator *missing values* dapat dibentuk untuk menandai bahwa suatu nilai pada awalnya tidak tersedia. Indikator tersebut membantu model membedakan nilai observasi asli dan nilai yang berasal dari proses pengisian. Apabila suatu variabel memiliki *missing values* sangat besar, interpretasi terhadap variabel tersebut tetap perlu dibatasi.

$$\text{Persentase Missing} = (\text{Jumlah Missing} / \text{Jumlah Observasi}) \times 100\%$$

Rumus tersebut digunakan untuk membaca tabel *missing values* pada BAB IV. Persentase *missing values* membantu menunjukkan tingkat kelengkapan data pada setiap parameter polutan, sehingga pembaca dapat memahami kualitas data sebelum dan sesudah imputasi.

2.1.15. Scaling dan Standardisasi

Scaling atau standardisasi adalah proses menyamakan skala fitur numerik agar berada pada rentang atau distribusi yang lebih sebanding. Salah satu bentuk standardisasi yang umum digunakan adalah z-score, yaitu mengurangi nilai fitur dengan rata-rata kemudian membaginya dengan simpangan baku. Proses ini penting terutama untuk model berbasis jaringan saraf seperti LSTM dan GRU karena model tersebut sensitif terhadap perbedaan skala antarf fitur. Sebaliknya, model berbasis pohon keputusan seperti Random Forest dan XGBoost relatif tidak terlalu sensitif terhadap skala fitur karena pemisahan data dilakukan berdasarkan aturan percabangan.

$$z = (x - \mu) / \sigma$$

Dalam rumus tersebut, μ menunjukkan rata-rata data latih, sedangkan σ menunjukkan simpangan baku data latih.

2.1.16. Evaluasi Model Klasifikasi

Evaluasi model diperlukan untuk menilai kemampuan model dalam membedakan kelas target. Karena penelitian ini merupakan klasifikasi biner, evaluasi dilakukan menggunakan Precision, Recall, F1-Score, dan Receiver Operating Characteristic-Area Under the Curve (ROC-AUC). Keempat metrik tersebut digunakan agar penilaian model tidak hanya bergantung pada jumlah

prediksi benar secara umum, tetapi juga memperhatikan kemampuan model dalam mengenali kelas Tidak Sehat+.

Precision mengukur proporsi prediksi positif yang benar-benar termasuk kelas positif. Dalam konteks penelitian ini, Precision menunjukkan seberapa banyak prediksi Tidak Sehat+ yang benar-benar merupakan hari Tidak Sehat+. Rumus Precision adalah Precision = TP / (TP + FP), dengan TP sebagai *true positive* dan FP sebagai *false positive*.

Recall mengukur proporsi kelas positif yang berhasil dikenali oleh model. Dalam konteks penelitian ini, Recall menunjukkan kemampuan model mendeteksi hari Tidak Sehat+ dari seluruh hari yang memang termasuk Tidak Sehat+. Rumus Recall adalah Recall = TP / (TP + FN), dengan FN sebagai *false negative*.

F1-Score merupakan rata-rata harmonis antara Precision dan Recall. Metrik ini berguna ketika penelitian perlu melihat keseimbangan antara ketepatan prediksi positif dan kemampuan mendeteksi kelas positif. Rumus F1-Score adalah F1-Score = 2 × (Precision × Recall) / (Precision + Recall). ROC-AUC mengukur kemampuan model membedakan kelas positif dan negatif pada berbagai ambang batas klasifikasi. Pada penelitian ini, ROC-AUC digunakan sebagai metrik tambahan untuk melihat kemampuan diskriminatif model terhadap status Tidak Sehat+ dan Bukan Tidak Sehat+.

Confusion matrix merupakan tabel yang memperlihatkan perbandingan antara kelas aktual dan kelas prediksi. Dalam konteks penelitian ini, true positive (TP) berarti hari Tidak Sehat+ diprediksi sebagai Tidak Sehat+, true negative (TN) berarti hari Bukan Tidak Sehat+ diprediksi sebagai Bukan Tidak Sehat+, false positive (FP) berarti hari Bukan Tidak Sehat+ diprediksi sebagai Tidak Sehat+, dan false negative (FN) berarti hari Tidak Sehat+ diprediksi sebagai Bukan Tidak Sehat+.

ROC curve menunjukkan kemampuan model memisahkan kelas positif dan kelas negatif pada berbagai threshold. *Precision-Recall curve* digunakan untuk membaca hubungan antara Precision dan Recall pada kelas positif, terutama ketika distribusi kelas tidak sepenuhnya

seimbang. Selain itu, distribusi kelas yang tidak seimbang dapat membuat model lebih condong mengenali kelas mayoritas. Pembobotan kelas digunakan agar kelas minoritas atau kelas positif tetap memperoleh perhatian selama proses pelatihan model. Dalam penelitian ini, kelas positif adalah Tidak Sehat+.

Secara operasional, ROC curve dibentuk dari pasangan True Positive Rate (TPR) dan False Positive Rate (FPR) pada berbagai threshold prediksi. TPR menunjukkan proporsi kelas positif yang berhasil dikenali, sedangkan FPR menunjukkan proporsi kelas negatif yang keliru diprediksi sebagai kelas positif.

$$TPR = TP / (TP + FN)$$

$$FPR = FP / (FP + TN)$$

ROC-AUC merupakan luas area di bawah ROC curve. Nilai ini digunakan untuk merangkum kemampuan diskriminasi model berdasarkan probabilitas prediksi kelas positif.

$$class_weight_i = n_samples / (n_classes \times n_i)$$

$$scale_pos_weight = \text{jumlah kelas negatif / jumlah kelas positif}$$

Pada rumus *class_weight* balanced, n_samples menunjukkan jumlah data latih, n_classes menunjukkan jumlah kelas, dan n_i menunjukkan jumlah observasi pada kelas ke-i. Sementara itu, *scale_pos_weight* digunakan pada XGBoost untuk memberi bobot lebih besar pada kelas positif ketika jumlah kelas positif lebih sedikit daripada kelas negatif. Dalam penelitian ini, pembobotan kelas digunakan agar model tetap memperhatikan kelas positif Tidak Sehat+ pada data yang tidak seimbang.

2.1.17. Target Leakage

Target leakage merupakan kondisi ketika fitur *input* mengandung informasi yang terlalu dekat dengan target sehingga model dapat memperoleh performa tinggi secara tidak wajar. Kondisi ini berbahaya karena model seolah-olah tampak akurat, padahal prediksi yang dihasilkan tidak mencerminkan kemampuan generalisasi yang sebenarnya.

Dalam penelitian ini, kolom max dan critical tidak digunakan sebagai fitur model karena kedua kolom tersebut sangat dekat dengan pembentukan kategori ISPU. Kolom max menunjukkan nilai parameter dominan, sedangkan critical berkaitan dengan parameter pencemar kritis yang menentukan status. Jika kedua kolom tersebut digunakan sebagai fitur, model berisiko mempelajari informasi yang secara langsung berkaitan dengan label target. Oleh karena itu, pencegahan *target leakage* dilakukan dengan hanya menggunakan parameter polutan utama, fitur waktu, indikator akhir pekan, indikator pasca-pandemi, dan indikator *missing values*.

Keputusan ini penting agar evaluasi model lebih dapat dipertanggungjawabkan. Model diharapkan mempelajari pola parameter dan konteks waktu, bukan memanfaatkan kolom yang secara langsung atau tidak langsung sudah memuat informasi target.

2.1.18. Explainable Artificial Intelligence dan SHAP

Explainable Artificial Intelligence atau XAI merupakan pendekatan yang bertujuan menjelaskan cara model menghasilkan prediksi. Dalam penelitian kualitas udara, interpretabilitas penting karena model tidak cukup hanya memberikan label prediksi, tetapi juga perlu menjelaskan fitur apa yang berkontribusi terhadap prediksi tersebut. (Agbehadji & Obagbuwa, 2025) menempatkan interpretabilitas model sebagai bagian penting dalam kajian risiko polusi udara dan kesehatan pernapasan.

SHAP atau *SHapley Additive exPlanations* merupakan salah satu metode interpretabilitas yang digunakan untuk mengukur kontribusi setiap fitur terhadap prediksi model. SHAP didasarkan pada konsep nilai Shapley, yaitu pendekatan yang menilai kontribusi suatu fitur dengan mempertimbangkan peran fitur tersebut dalam berbagai kombinasi fitur. Dengan demikian, SHAP dapat memberikan penjelasan baik pada tingkat lokal maupun *global*. Penjelasan lokal menunjukkan kontribusi fitur pada satu prediksi tertentu, sedangkan penjelasan *global* menunjukkan pola kontribusi fitur pada keseluruhan data.

Secara formal, nilai Shapley untuk fitur ke-j dapat dituliskan sebagai berikut.

$$\varphi_j = \Sigma_{S \subseteq F \setminus \{j\}} \left(|S|! \, (|F|-|S|-1)! \, / \, |F|! \right) \left[f(S \cup \{j\}) - f(S) \right]$$

Dalam rumus tersebut, F menyatakan himpunan seluruh fitur, S menyatakan subset fitur tanpa fitur ke-j, dan f menyatakan fungsi model. Pada penelitian ini, rumus tersebut digunakan sebagai dasar konsep SHAP, sedangkan perhitungan aktual dilakukan menggunakan pustaka SHAP di Python, bukan dihitung secara manual.

Mean absolute SHAP merupakan ringkasan kontribusi fitur yang diperoleh dengan menghitung rata-rata nilai absolut SHAP pada seluruh observasi. Rumus ringkasnya dituliskan sebagai berikut.

$$\text{Mean Absolute SHAP}_j = (1/n)\ \Sigma\ |\text{SHAP}_{ij}|$$

Dalam rumus tersebut, n menunjukkan jumlah observasi, sedangkan SHAP_ij menunjukkan nilai SHAP fitur ke-j pada observasi ke-i.

Nilai tersebut menunjukkan rata-rata kontribusi absolut fitur ke-j pada seluruh observasi. Nilai yang lebih besar menunjukkan kontribusi rata-rata fitur yang lebih besar terhadap keputusan model, bukan hubungan sebab-akibat.

SHAP value menunjukkan arah dan besar kontribusi suatu fitur pada satu observasi terhadap keputusan model. Nilai SHAP positif dapat mendorong prediksi ke arah kelas positif, sedangkan nilai negatif dapat mendorong prediksi ke arah kelas pembanding. (Yenkikar et al., 2025) menunjukkan penggunaan SHAP untuk membaca interpretabilitas indeks kualitas udara. Dalam penelitian ini, kelas positif adalah Tidak Sehat+.

Dalam penelitian ini, SHAP digunakan pada model berbasis ensemble yang dipilih setelah evaluasi model untuk menginterpretasikan kontribusi fitur polutan dan fitur waktu terhadap prediksi status Tidak Sehat+. Pemakaian SHAP tidak dimaksudkan untuk menggantikan evaluasi model, melainkan melengkapi evaluasi performa dengan penjelasan kontribusi fitur yang lebih mudah dipahami.

2.1.19. Kerangka Konseptual Penelitian

Berdasarkan teori yang telah dijelaskan, penelitian ini menempatkan data ISPU DKI Jakarta sebagai data lingkungan harian yang dapat dianalisis menggunakan pendekatan klasifikasi.

Fitur polutan utama dan fitur waktu digunakan untuk membentuk representasi data, sedangkan target biner Tidak Sehat+ dan Bukan Tidak Sehat+ digunakan untuk mengarahkan model pada kemampuan mengenali status kualitas udara yang lebih berisiko.

Model Random Forest dan Extreme Gradient Boosting (XGBoost) mewakili pendekatan ensemble learning pada data tabular, sedangkan LSTM dan GRU mewakili pendekatan deep learning pada data berurutan. Evaluasi model menggunakan Precision, Recall, F1-Score, dan ROC-AUC agar performa klasifikasi dapat dinilai secara terukur. Setelah model dievaluasi, SHAP digunakan pada model berbasis ensemble yang dipilih setelah evaluasi model untuk menjelaskan kontribusi fitur. Dengan alur tersebut, penelitian ini memiliki dua keluaran utama, yaitu perbandingan performa model dan interpretasi kontribusi fitur terhadap status Tidak Sehat+.

Tabel dan visualisasi pada BAB IV merupakan hasil penerapan alur metodologi pada BAB III. Dengan demikian, distribusi kategori, target biner, pemeriksaan missing values, evaluasi model, dan interpretasi SHAP pada BAB IV dibaca sebagai keluaran empiris dari proses pengolahan data dan eksperimen yang dijelaskan sebelumnya.

2.2. Penelitian Terkait

Kajian terdahulu digunakan untuk menunjukkan posisi penelitian ini terhadap studi sebelumnya. Literatur yang dipilih berfokus pada klasifikasi ISPU atau AQI, kualitas udara Jakarta atau kota besar, penggunaan model Random Forest, XGBoost, LSTM, GRU, serta interpretabilitas model menggunakan SHAP atau XAI. Dengan demikian, pembahasan penelitian terdahulu tetap berada dalam ruang lingkup penelitian dan tidak melebar ke prediksi nilai ISPU secara regresi.

(Hasna et al., 2024) menerapkan Random Forest untuk klasifikasi ISPU DKI Jakarta tahun 2022. Penelitian tersebut relevan karena menggunakan objek ISPU DKI Jakarta dan model Random Forest. Namun, penelitian ini berbeda karena membandingkan empat model,

yaitu Random Forest, XGBoost, LSTM, dan GRU, dengan target klasifikasi biner Tidak Sehat+ dan Bukan Tidak Sehat+ pada periode 2020-2024.

(Banjarnahor et al., 2025) membandingkan Support Vector Machine dan Random Forest untuk prediksi kategori indeks kualitas udara Jakarta dengan parameter PM10, PM2.5, SO2, CO, O3, dan NO2. Penelitian tersebut relevan karena memiliki kedekatan objek dan parameter dengan penelitian ini. Perbedaannya, penelitian ini tidak menggunakan SVM dan tidak berfokus pada kategori multikelas, tetapi membentuk target biner agar model diarahkan pada pengenalan kondisi Tidak Sehat+.

(Radjabaycolle et al., 2025) menggunakan LSTM dan SHAP dalam studi kualitas udara Jakarta. Penelitian tersebut relevan karena menunjukkan pemanfaatan model sekuensial dan interpretabilitas pada konteks kualitas udara Jakarta. Namun, penelitian ini memperluas pembandingan dengan memasukkan Random Forest, XGBoost, LSTM, dan GRU dalam satu kerangka eksperimen, serta membatasi SHAP pada model berbasis ensemble yang dipilih setelah evaluasi model untuk interpretasi kontribusi fitur.

(Rajagukguk et al., 2025) membandingkan XGBoost, Random Forest, dan Logistic Regression untuk klasifikasi ISPU Jakarta. Kajian tersebut memiliki kedekatan langsung dengan penelitian ini karena sama-sama membahas ISPU Jakarta dan menggunakan model ensemble. Perbedaannya, penelitian ini tidak memasukkan Logistic Regression, tetapi menambahkan LSTM dan GRU sebagai model pembelajaran mendalam berbasis urutan waktu.

(Sajiwo et al., 2024) membahas klasifikasi ISPU DKI Jakarta menggunakan XGBoost dengan teknik SMOTE untuk menangani data tidak seimbang. Kajian tersebut relevan karena menggunakan XGBoost dan objek ISPU DKI Jakarta. Namun, penelitian ini tidak memosisikan SMOTE sebagai fokus utama, melainkan membandingkan model ensemble dan pembelajaran mendalam dengan pembagian data kronologis.

(Fahim et al., 2025) meneliti klasifikasi Air Quality Index menggunakan teknik ensemble *machine learning*. Kajian tersebut relevan untuk memperkuat penggunaan model

ensemble dan metrik evaluasi klasifikasi seperti F1-Score serta ROC-AUC. Perbedaannya, penelitian ini berfokus pada ISPU DKI Jakarta dengan target biner Tidak Sehat+ dan Bukan Tidak Sehat+.

(Liu et al., 2024) membahas klasifikasi kelas kualitas udara menggunakan metode *machine learning* berdasarkan data pemantauan. Studi tersebut mendukung konsep bahwa kualitas udara dapat dimodelkan sebagai masalah klasifikasi kelas. Dalam penelitian ini, konsep tersebut diterapkan pada data ISPU DKI Jakarta dengan fokus pada pemisahan kelas Tidak Sehat+ dan Bukan Tidak Sehat+.

(Jalali et al., 2025) membahas aplikasi kecerdasan buatan untuk kualitas udara, termasuk klasifikasi dan penggunaan pendekatan XAI. Literatur ini relevan sebagai penguat bahwa model pembelajaran mesin, pembelajaran mendalam, dan interpretabilitas dapat dikombinasikan dalam studi kualitas udara. Namun, penelitian ini tetap menjaga ruang lingkup pada klasifikasi status ISPU, bukan peramalan nilai numerik kualitas udara.

(Yenkikar et al., 2025) membahas pemanfaatan SHAP untuk interpretabilitas prediksi indeks kualitas udara. Penelitian tersebut mendukung penggunaan SHAP sebagai metode untuk membaca kontribusi fitur terhadap keluaran model. Dalam penelitian ini, SHAP digunakan untuk menjelaskan kontribusi parameter polutan dan fitur waktu terhadap prediksi status Tidak Sehat+.

(Agbehadji & Obagbuwa, 2025) melakukan tinjauan sistematis mengenai Explainable Artificial Intelligence dan *machine learning* dalam kajian risiko polusi udara serta kesehatan pernapasan. Kajian tersebut menempatkan interpretabilitas model sebagai bagian penting dalam analisis polusi udara. Pada penelitian ini, konsep tersebut diterapkan melalui SHAP agar model klasifikasi tidak hanya dievaluasi performanya, tetapi juga dijelaskan kontribusi fiturnya.

(Karmoude et al., 2025) meninjau penggunaan *machine learning* dalam kajian kualitas udara. Literatur ini digunakan untuk memperkuat landasan umum bahwa metode komputasional memiliki peran penting dalam analisis kualitas udara. Namun, penelitian ini

tetap memiliki fokus yang lebih spesifik, yaitu membandingkan Random Forest, XGBoost, LSTM, dan GRU untuk klasifikasi status ISPU DKI Jakarta.

Tabel II. 3 Penelitian Terkait

Penelitian Terkait	Fokus, Metode, Relevansi, dan Pembeda
1. (Hasna et al., 2024)	Membahas klasifikasi ISPU DKI Jakarta tahun 2022 menggunakan Random Forest. Relevan karena objek dan modelnya dekat dengan penelitian ini, sedangkan penelitian ini memperluas pembandingan dengan XGBoost, LSTM, dan GRU pada target biner Tidak Sehat+.
2. (Banjarnahor et al., 2025)	Membahas kategori kualitas udara Jakarta menggunakan SVM dan Random Forest dengan parameter PM10, PM2.5, SO2, CO, O3, dan NO2. Relevan dari sisi objek Jakarta dan parameter polutan, tetapi penelitian ini tidak memakai SVM dan tidak diarahkan pada multikelas.
3. (Radjabaycolle et al., 2025)	Membahas studi kualitas udara Jakarta dengan LSTM dan SHAP. Relevan untuk model sekuensial dan interpretabilitas, sedangkan penelitian ini menambahkan komparasi ensemble dan GRU serta memakai SHAP pada model berbasis ensemble yang dipilih setelah evaluasi model.
4. (Rajagukguk et al., 2025)	Membandingkan XGBoost, Random Forest, dan *Logistic Regression* untuk klasifikasi ISPU Jakarta. Sangat dekat karena membahas ISPU Jakarta, RF, dan XGBoost. Penelitian ini tidak memakai *Logistic Regression*, tetapi menambahkan LSTM dan GRU.
5. (Sajiwo et al., 2024)	Membahas klasifikasi ISPU DKI Jakarta menggunakan XGBoost dan SMOTE. Relevan untuk XGBoost dan ISPU DKI Jakarta, tetapi penelitian ini tidak memusatkan pembahasan pada SMOTE, melainkan pada komparasi model dengan pembagian data kronologis.
6. (Fahim et al., 2025)	Membahas klasifikasi AQI berbasis ensemble *machine learning*. Relevan untuk mendukung penggunaan ensemble dan metrik klasifikasi seperti F1-Score serta ROC-AUC, sedangkan penelitian ini memakai data ISPU DKI Jakarta dengan target biner.
7. (Klosterman, 2021)	Membahas klasifikasi kelas kualitas udara menggunakan machine learning berdasarkan data pemantauan. Relevan untuk memperkuat konsep kualitas udara sebagai masalah klasifikasi kelas yang dalam penelitian ini dioperasionalkan sebagai Tidak Sehat+ dan Bukan Tidak Sehat+.

Penelitian Terkait	Fokus, Metode, Relevansi, dan Pembeda
8. (Bhattacharya, 2022)	Membahas sistem AI untuk kualitas udara, termasuk klasifikasi, *deep learning*, dan XAI. Relevan sebagai penghubung ML, DL, dan interpretabilitas, tetapi penelitian ini membatasi keluaran pada klasifikasi status, bukan *forecasting* nilai.
9. (VASILEV, 2023)	Membahas interpretabilitas indeks kualitas udara menggunakan Random Forest, ARIMA, dan SHAP. Relevan untuk mendukung pemakaian SHAP dalam menjelaskan kontribusi fitur, sedangkan penelitian ini menerapkannya pada model berbasis ensemble yang dipilih setelah evaluasi model dalam klasifikasi ISPU.
10. (Awasthi et al., 2025)	Menyajikan tinjauan sistematis XAI dan ML untuk polusi udara dan risiko kesehatan. Relevan untuk menguatkan pentingnya interpretabilitas model polusi udara, sedangkan penelitian ini menerapkan SHAP secara spesifik pada data ISPU DKI Jakarta.
11.(Thampi, 2022)	Meninjau perkembangan ML untuk prediksi dan analisis kualitas udara. Relevan sebagai dasar umum penggunaan ML/DL pada kualitas udara, sedangkan penelitian ini lebih spesifik pada ISPU DKI Jakarta dan target Tidak Sehat+.

Sumber: Diolah oleh penulis (2026)

Berdasarkan penelitian terkait tersebut, dapat disimpulkan bahwa studi mengenai kualitas udara telah banyak menggunakan Random Forest, XGBoost, LSTM, dan SHAP. Namun, masih terdapat ruang penelitian untuk membandingkan model ensemble dan pembelajaran mendalam dalam satu kerangka eksperimen yang sama pada data ISPU DKI Jakarta periode 2020-2024. Selain itu, belum banyak penelitian yang secara khusus membentuk target biner Tidak Sehat+ dan Bukan Tidak Sehat+ dengan pembagian data kronologis serta interpretabilitas SHAP pada model berbasis ensemble yang dipilih setelah evaluasi model. Oleh karena itu, penelitian ini ditempatkan sebagai kajian komparatif yang menggabungkan performa klasifikasi dan interpretabilitas fitur pada konteks ISPU DKI Jakarta.

2.3. Tinjauan Organisasi/Objek Penelitian

Objek penelitian ini adalah data Indeks Standar Pencemar Udara DKI Jakarta. Data tersebut merepresentasikan kondisi kualitas udara harian berdasarkan parameter pencemar yang dipantau di wilayah DKI Jakarta. Karena penelitian ini menggunakan data sekunder, pembahasan objek penelitian tidak diarahkan pada struktur organisasi internal instansi, melainkan pada sumber data, karakteristik data, parameter yang digunakan, dan batasan objek yang dianalisis.

2.3.1. DKI Jakarta sebagai Wilayah Kajian Kualitas Udara

DKI Jakarta merupakan wilayah metropolitan dengan aktivitas transportasi, perkantoran, permukiman padat, dan mobilitas masyarakat yang tinggi. Karakter tersebut membuat kualitas udara di Jakarta menjadi isu penting dalam kajian lingkungan perkotaan. Pemantauan kualitas udara menjadi diperlukan karena perubahan aktivitas masyarakat dapat memengaruhi konsentrasi pencemar udara.

Periode 2020-2024 dipilih karena mencakup fase pandemi, transisi, dan pasca-pandemi. Tahun 2020-2021 berkaitan dengan pembatasan mobilitas masyarakat, sedangkan tahun 2022-2024 berkaitan dengan pemulihan aktivitas perkotaan dan normalisasi mobilitas. Periode tersebut

memberikan konteks temporal yang relevan untuk mempelajari status kualitas udara DKI Jakarta dalam kondisi sosial yang berubah.

2.3.2. Sumber Data ISPU DKI Jakarta

Data yang digunakan dalam penelitian ini merupakan data sekunder ISPU DKI Jakarta yang bersumber dari Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui portal Satu Data Jakarta dan diakses dalam bentuk dataset terstruktur melalui Kaggle. Portal data pemerintah menjelaskan bahwa data ISPU DKI Jakarta diperoleh dari pengukuran Stasiun Pemantau Kualitas Udara di Provinsi DKI Jakarta (Pemerintah Provinsi DKI Jakarta, 2025).

Pemanfaatan Kaggle dalam penelitian ini diposisikan sebagai media akses terhadap dataset terstruktur, bukan sebagai produsen utama data. Sumber substantif data tetap merujuk pada Dinas Lingkungan Hidup Provinsi DKI Jakarta dan Satu Data Jakarta. Hal ini penting agar sumber data penelitian dijelaskan secara transparan dan tidak menimbulkan kesan bahwa data berasal dari hasil pengukuran mandiri peneliti.

2.3.3. Karakteristik Data Penelitian

Dataset awal yang diperiksa mencakup rentang 1 Januari 2010 sampai 28 Februari 2025. Namun, penelitian ini membatasi periode analisis pada 1 Januari 2020 sampai 31 Desember 2024. Data tahun 2010-2019 tidak digunakan karena berada di luar fokus pandemi, transisi, dan pasca-pandemi. Data tahun 2025 juga tidak digunakan karena belum mencakup satu tahun penuh.

Setelah pemotongan periode 2020-2024 dan pengeluaran kategori TIDAK ADA DATA, data pemodelan yang digunakan berjumlah 1.826 hari valid. Kategori TIDAK ADA DATA dikeluarkan karena bukan merupakan status mutu udara yang dapat dimasukkan ke dalam target klasifikasi. Dengan demikian, data yang digunakan dalam pemodelan hanya mencakup hari-hari yang memiliki status kualitas udara yang dapat dipetakan ke dalam kelas Tidak Sehat+ atau Bukan Tidak Sehat+.

2.3.4. Variabel Penelitian

Variabel utama dalam penelitian ini terdiri dari parameter polutan PM2.5, PM10, SO2, CO, O3, dan NO2. Keenam parameter tersebut digunakan sebagai fitur utama karena menjadi indikator pencemar udara yang tersedia pada dataset. Selain itu, penelitian ini menggunakan fitur pendukung berupa tahun, bulan, hari dalam minggu, indikator akhir pekan, indikator pasca-pandemi, dan indikator *missing values*.

Indikator akhir pekan digunakan untuk memberi informasi apakah suatu observasi terjadi pada hari kerja atau akhir pekan. Indikator pasca-pandemi digunakan untuk memberikan konteks periode setelah fase pembatasan mobilitas. Indikator *missing values* digunakan agar proses imputasi tetap memiliki jejak dalam data, sehingga model tidak sepenuhnya mengabaikan informasi bahwa suatu nilai sebelumnya kosong dan telah diisi melalui metode imputasi.

Kolom max dan critical tidak digunakan sebagai fitur model. Keputusan ini dilakukan untuk mencegah *target leakage* karena kedua kolom tersebut memiliki hubungan yang sangat dekat dengan pembentukan kategori ISPU. Dengan tidak menggunakan kedua kolom tersebut, model diharapkan mempelajari pola dari parameter polutan dan fitur waktu, bukan dari informasi yang terlalu dekat dengan label target.

2.3.5. Target Klasifikasi

Target penelitian ini adalah status klasifikasi biner yang terdiri dari Tidak Sehat+ dan Bukan Tidak Sehat+. Kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT dikelompokkan sebagai Tidak Sehat+, sedangkan kategori BAIK dan SEDANG dikelompokkan sebagai Bukan Tidak Sehat+. Pengelompokan ini dilakukan agar model fokus mengenali kondisi kualitas udara yang lebih berisiko terhadap kesehatan masyarakat.

Pembentukan target biner juga membantu penelitian menjadi lebih operasional. Alih-alih hanya memprediksi kategori kualitas udara secara umum, model diarahkan untuk menjawab apakah suatu hari termasuk dalam kondisi Tidak Sehat+ atau tidak. Dengan demikian, keluaran model memiliki makna yang lebih langsung dalam konteks kewaspadaan kualitas udara.

2.3.6. Posisi Objek Penelitian terhadap Metode

Objek penelitian berupa data ISPU DKI Jakarta memiliki karakter tabular dan temporal. Karakter tabular terlihat dari parameter polutan dan fitur waktu yang tersusun dalam kolom-kolom terstruktur. Karakter temporal terlihat dari urutan tanggal yang membentuk observasi harian. Oleh karena itu, penelitian ini membandingkan dua pendekatan model, yaitu model ensemble untuk data tabular dan model pembelajaran mendalam untuk data berurutan.

Random Forest dan XGBoost digunakan untuk membaca hubungan antarfitur pada data tabular. LSTM dan GRU digunakan untuk membaca pola urutan waktu dengan pendekatan *sliding window* 14 hari. Evaluasi dilakukan menggunakan Precision, Recall, F1-Score, dan ROC-AUC. Setelah model dievaluasi, SHAP digunakan pada model berbasis ensemble yang dipilih setelah evaluasi model untuk menjelaskan kontribusi fitur terhadap prediksi status Tidak Sehat+.

Dengan demikian, objek penelitian, metode pemodelan, dan evaluasi yang digunakan membentuk alur metodologis yang konsisten. Data ISPU DKI Jakarta menyediakan parameter polutan dan fitur waktu; model klasifikasi digunakan untuk membedakan status Tidak Sehat+ dan Bukan Tidak Sehat+; metrik klasifikasi digunakan untuk menilai performa; dan SHAP digunakan untuk menjelaskan kontribusi fitur yang membentuk keputusan model.