BAB III

METODOLOGI PENELITIAN

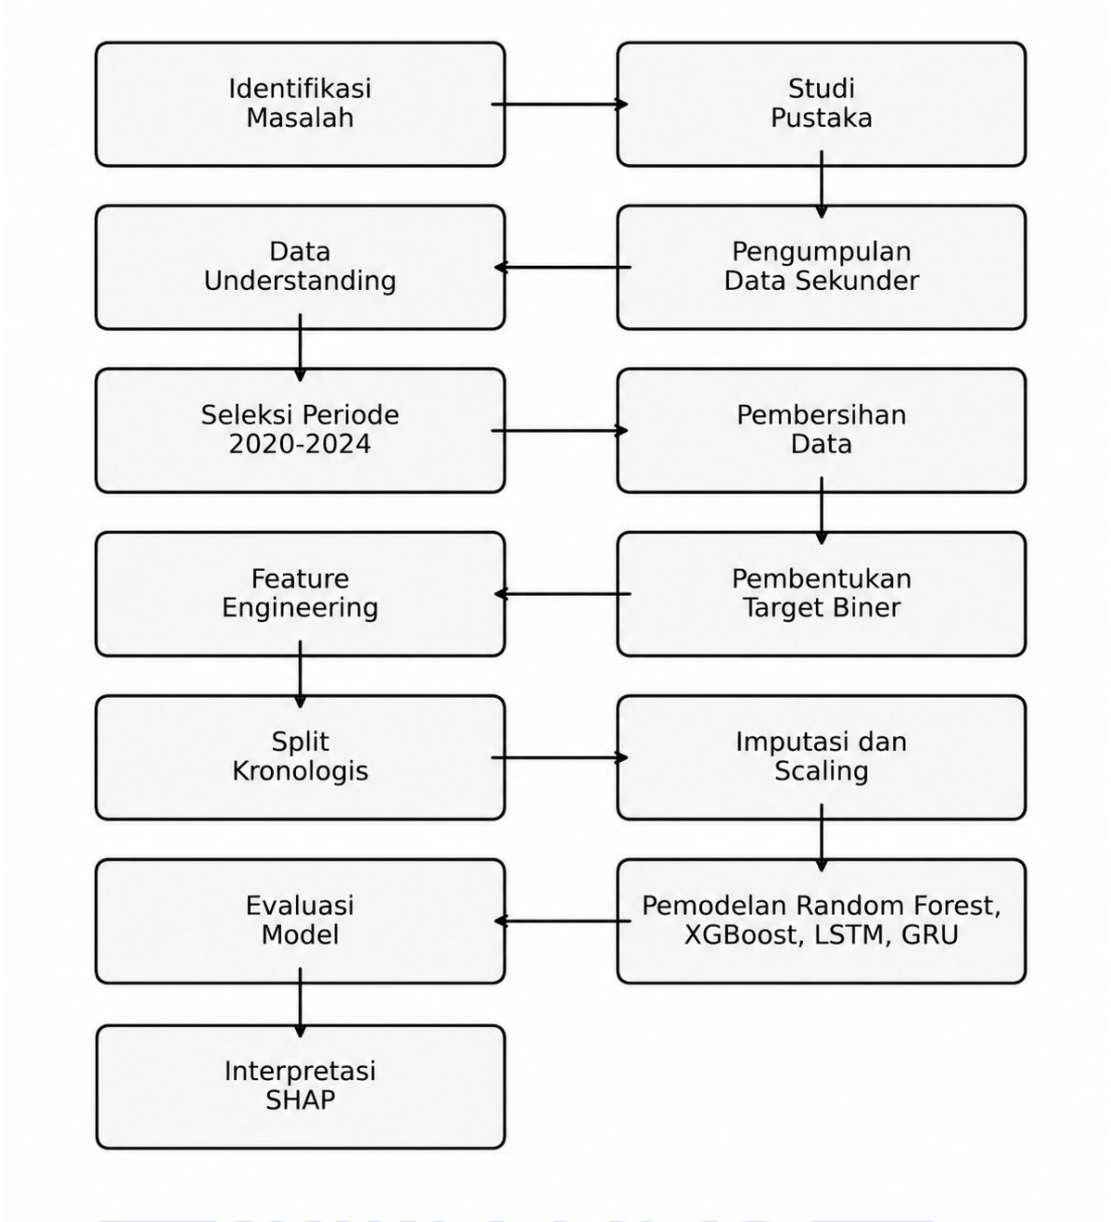
Bab ini menjelaskan proses penelitian yang dilakukan untuk mengklasifikasikan status Indeks Standar Pencemar Udara (ISPU) DKI Jakarta. Metodologi disusun sebagai alur kerja eksperimen komputasional, mulai dari pengumpulan data sekunder, pemahaman data, pengolahan fitur, pembentukan target, pembagian data, pemodelan, evaluasi, sampai penyiapan *output* untuk BAB IV.

Dataset awal yang digunakan terdiri dari 5.538 baris dan 11 kolom dengan rentang tanggal 1 Januari 2010 sampai 28 Februari 2025. Penelitian membatasi data pada periode 1 Januari 2020 sampai 31 Desember 2024. Setelah seleksi periode, data berjumlah 1.827 observasi. Satu baris dengan kategori TIDAK ADA DATA dikeluarkan, sehingga data pemodelan final berjumlah 1.826 observasi harian.

3.1. Tahapan Penelitian

Tahapan penelitian dirancang agar setiap keputusan teknis dapat ditelusuri dari data mentah sampai *output* analisis. Alur penelitian disajikan dalam bentuk gambar agar tahapan penelitian dapat dibaca sebagai proses yang berurutan, mulai dari pengumpulan data hingga penyiapan *output* untuk BAB IV.

Model yang digunakan dalam alur penelitian adalah Random Forest, Extreme Gradient Boosting (XGBoost), Long Short-Term Memory (LSTM), dan Gated Recurrent Unit (GRU). Interpretasi model dilakukan dengan SHapley Additive exPlanations (SHAP).



Gambar III. 1 Alur Tahapan Penelitian

Sumber: Diadaptasi dari kerangka penelitian kualitas udara Jakarta berbasis LSTM-SHAP (Radjabaycolle et al., 2025), diolah oleh penulis (2026).

Tahap identifikasi masalah diarahkan pada kebutuhan membandingkan kinerja model klasifikasi status ISPU DKI Jakarta dan membaca kontribusi fitur melalui SHAP. Tahap ini menghasilkan batasan bahwa penelitian tidak memprediksi nilai ISPU numerik, melainkan mengklasifikasikan status harian menjadi Tidak Sehat+ dan Bukan Tidak Sehat+.

Studi pustaka digunakan untuk menetapkan dasar konseptual mengenai ISPU, parameter polutan, klasifikasi, model ensemble, model *deep learning* berbasis

TensorFlow/Keras, evaluasi klasifikasi, serta SHAP. Hasil tahap ini menjadi dasar pemilihan Random Forest, XGBoost, LSTM, GRU, metrik Precision, Recall, F1-Score, ROC-AUC, dan interpretasi mean absolute SHAP.

Pengumpulan data sekunder dilakukan menggunakan dataset ispu_dki_all.csv. Dataset awal berisi 5.538 baris dan 11 kolom pada rentang 1 Januari 2010 sampai 28 Februari 2025. Pada tahap *data understanding*, *notebook* memeriksa nama kolom, tipe data, rentang tanggal, jumlah stasiun, distribusi kategori ISPU asli, serta *missing values* awal. Pemeriksaan tersebut menunjukkan bahwa dataset memuat lima stasiun pemantauan dan sebelas kolom utama, yaitu tanggal, stasiun, PM2.5, PM10, SO2, CO, O3, NO2, max, critical, dan categori.

Seleksi periode dilakukan dengan membatasi data pada 1 Januari 2020 sampai 31 Desember 2024 sehingga jumlah data menjadi 1.827 observasi. Periode 2020-2021 merepresentasikan fase pandemi dan pembatasan aktivitas, sedangkan 2022-2024 merepresentasikan fase transisi dan pasca-pandemi. Data tahun 2025 tidak digunakan karena belum mencakup satu tahun penuh, sementara data 2010-2019 berada di luar fokus periode penelitian. Satu baris berkategori TIDAK ADA DATA dikeluarkan karena tidak dapat dipetakan ke kelas target, sehingga data final untuk pemodelan berjumlah 1.826 observasi harian.

Pembentukan target biner dilakukan dari kolom categori. Kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT dipetakan menjadi Tidak Sehat+, sedangkan BAIK dan SEDANG dipetakan menjadi Bukan Tidak Sehat+. Hasilnya adalah 616 hari Tidak Sehat+ dan 1.210 hari Bukan Tidak Sehat+. Setelah itu, *feature engineering* membentuk 17 fitur final yang terdiri dari enam polutan, fitur waktu, indikator akhir pekan, indikator pasca-pandemi, dan indikator *missing values*. Kolom max, critical, categori, target_tidak_sehat, target_label, dan stasiun tidak digunakan sebagai fitur model.

Split data dilakukan secara kronologis. Data 2020-2023 digunakan sebagai data latih sebanyak 1.460 observasi, sedangkan data 2024 digunakan sebagai data uji sebanyak 366

observasi. Imputasi dilakukan setelah split dengan parameter dari data latih, kemudian *scaling* diterapkan untuk kebutuhan model. PM2.5 pada tahun 2020 memiliki 366 nilai kosong dari 366 hari sehingga informasi ini dicatat sebagai batasan interpretasi. Untuk LSTM dan GRU, data dibentuk menjadi sekuens 14 hari sebelumnya dengan skema X[i-window:i] → y[i].

Pemodelan dilakukan menggunakan Random Forest, XGBoost, LSTM, dan GRU. Random Forest dan XGBoost menggunakan fitur tabular pada hari target, sedangkan LSTM dan GRU menggunakan konteks historis 14 hari sebelumnya. Evaluasi model dilakukan pada data uji dengan Precision, Recall, F1-Score, ROC-AUC, *confusion matrix*, *ROC curve*, dan *Precision-Recall curve*. BAB III hanya menjelaskan prosedur perhitungan, sedangkan hasil nilai evaluasi disajikan pada BAB IV.

Interpretasi SHAP dihitung pada model berbasis ensemble yang dipilih setelah proses evaluasi. SHAP pada data uji 2024 digunakan untuk membaca kontribusi fitur pada periode evaluasi generalisasi, sedangkan SHAP historis 2020-2024 digunakan sebagai analisis diagnostik retrospektif untuk membaca pola kontribusi fitur sepanjang periode penelitian, bukan sebagai evaluasi generalisasi model. *Output* penelitian disiapkan dalam bentuk tabel, gambar, data hasil pengolahan, dan lampiran pendukung yang menjadi dasar penyajian BAB IV.

3.2. Instrumen Penelitian

Instrumen penelitian yang digunakan meliputi komputer atau laptop, lingkungan Google Colaboratory atau Jupyter *Notebook*, bahasa pemrograman Python, dataset ispu_dki_all.csv, dan *notebook* eksperimen *Notebook*_Eksperimen_ISPU.ipynb. Pengolahan data dilakukan dengan Pandas dan NumPy. Pemodelan Random Forest dilakukan dengan Scikit-learn, XGBoost dilakukan dengan pustaka XGBoost, sedangkan LSTM dan GRU dilakukan dengan TensorFlow/Keras. Visualisasi dibuat dengan Matplotlib dan Seaborn, sedangkan interpretabilitas model dilakukan dengan SHAP.

Notebook eksperimen digunakan untuk menjalankan proses penelitian secara berurutan, mulai dari pembacaan dataset sampai penyimpanan tabel dan gambar. *Output notebook* disimpan pada folder *output* yang berisi tabel berformat CSV dan gambar berformat PNG agar dapat digunakan kembali pada BAB IV.

3.3. Metode Pengumpulan Data, Populasi, dan Sampel Penelitian

Metode pengumpulan data yang digunakan adalah dokumentasi data sekunder. Data utama berupa dataset ISPU DKI Jakarta yang bersumber dari Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui portal Satu Data Jakarta dan diakses dalam bentuk dataset terstruktur melalui Kaggle. Dataset memuat kolom tanggal, stasiun, Particulate Matter 2.5 (PM2.5), Particulate Matter 10 (PM10), Sulfur Dioksida (SO2), Karbon Monoksida (CO), Ozon (O3), Nitrogen Dioksida (NO2), max, critical, dan categori.

Populasi penelitian adalah seluruh data harian pada dataset awal, yaitu 5.538 baris dan 11 kolom dengan rentang 1 Januari 2010 sampai 28 Februari 2025. Sampel penelitian adalah data periode 1 Januari 2020 sampai 31 Desember 2024 yang memenuhi kriteria kategori kualitas udara. Setelah filter periode, jumlah observasi menjadi 1.827 baris. Setelah kategori TIDAK ADA DATA dikeluarkan, data final untuk pemodelan menjadi 1.826 observasi.

Tabel III. 1 Kriteria Data Penelitian

No	Aspek	Keterangan
1	Populasi penelitian	Seluruh data harian ISPU DKI Jakarta pada dataset awal periode 1 Januari 2010 sampai 28 Februari 2025.
2	Jumlah data awal	5.538 baris dan 11 kolom.
3	Sampel/data penelitian	Data periode 1 Januari 2020 sampai 31 Desember 2024 setelah kategori TIDAK ADA DATA dikeluarkan.
4	Jumlah data periode penelitian	1.827 observasi sebelum pengeluaran TIDAK ADA DATA.
5	Jumlah data pemodelan final	1.826 observasi harian valid.
6	Kriteria inklusi	Data berada pada periode 2020-2024 dan memiliki kategori BAIK, SEDANG, TIDAK SEHAT, atau SANGAT TIDAK SEHAT.

No	Aspek	Keterangan
7	Kriteria eksklusi	Data tahun 2010-2019, data tahun 2025, dan satu baris kategori TIDAK ADA DATA.
8	Pembagian data	Data latih 1 Januari 2020 sampai 31 Desember 2023 sebanyak 1.460 observasi; data uji 1 Januari 2024 sampai 31 Desember 2024 sebanyak 366 observasi.

Sumber: Diolah oleh penulis (2026)

3.4. Metode Analisis Data

Metode analisis data dilakukan melalui tahapan operasional yang sama dengan *notebook* eksperimen. Tahapan tersebut mencakup pemahaman data, seleksi periode, pembersihan data, pembentukan target, pembentukan fitur, pencegahan *target leakage*, pembagian data kronologis, imputasi, *scaling*, pembentukan sequence, pemodelan, evaluasi, interpretasi SHAP, dan penyimpanan *output*. Hasil numerik akhir dari model tidak dibahas pada BAB III karena menjadi bagian dari BAB IV.

3.4.1. *Data Understanding*

Tahap *data understanding* dilakukan terhadap dataset awal berisi 5.538 baris dan 11 kolom. Rentang tanggal awal adalah 1 Januari 2010 sampai 28 Februari 2025, dengan 5 stasiun unik. Kolom yang diperiksa meliputi tanggal, stasiun, enam polutan, max, critical, dan categori.

Tabel III. 2 Daftar Kolom Dataset Awal dan Perannya dalam Penelitian

Kolom	Arti Kolom	Peran	Alasan
tanggal	Tanggal observasi harian	Sumber fitur waktu	Dipakai untuk urutan kronologis, seleksi periode, split data, dan pembentukan fitur waktu.
stasiun	Nama stasiun pemantauan	Dikecualikan	Penelitian memosisikan data sebagai deret harian ISPU DKI Jakarta, bukan perbandingan antarstasiun.
PM2.5	Particulate Matter 2.5	Fitur model	Parameter polutan utama.
PM10	Particulate Matter 10	Fitur model	Parameter polutan utama.
SO2	Sulfur Dioksida	Fitur model	Parameter polutan utama.
CO	Karbon Monoksida	Fitur model	Parameter polutan utama.
O3	Ozon	Fitur model	Parameter polutan utama.
NO2	Nitrogen Dioksida	Fitur model	Parameter polutan utama.
max	Nilai ISPU maksimum harian	Dikecualikan	Berisiko menyebabkan target leakage karena sangat dekat dengan penentuan kategori.
critical	Parameter dominan penentu ISPU	Dikecualikan	Berisiko menyebabkan target leakage karena memuat informasi parameter penentu kategori.
categori	Kategori ISPU asli	Sumber target	Dipakai untuk membentuk target biner, tetapi tidak menjadi fitur model.

Sumber: Diolah oleh penulis (2026)

Pada periode 2020-2024 sebelum kategori TIDAK ADA DATA dikeluarkan, distribusi kategori terdiri dari SEDANG 1.160 hari, TIDAK SEHAT 609 hari, BAIK 50 hari, SANGAT TIDAK SEHAT 7 hari, dan TIDAK ADA DATA 1 hari. Pemeriksaan ini digunakan untuk memastikan bahwa target biner dibentuk dari kategori yang valid.

3.4.2. Seleksi Periode dan Pembersihan Data

Seleksi periode dilakukan terhadap dataset awal yang terdiri dari 5.538 baris dan 11 kolom. Data dibatasi pada rentang 1 Januari 2020 sampai 31 Desember 2024 karena periode tersebut mencakup fase pandemi atau pembatasan aktivitas pada 2020-2021 serta fase transisi dan pasca-pandemi pada 2022-2024. Data 2025 tidak digunakan karena belum mencakup satu tahun penuh, sedangkan data 2010-2019 berada di luar fokus periode penelitian.

Setelah filter periode diterapkan pada *notebook*, jumlah observasi menjadi 1.827 baris. Satu baris berkategori TIDAK ADA DATA dikeluarkan karena tidak dapat dipetakan menjadi

kelas target yang valid. Dengan demikian, data final yang digunakan untuk pemodelan berjumlah 1.826 observasi harian.

3.4.3. Pembentukan Target Biner

Target penelitian dibentuk dari kolom categori. Kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT diberi label positif Tidak Sehat+, sedangkan kategori BAIK dan SEDANG diberi label Bukan Tidak Sehat+. Pada data pemodelan final, kelas Tidak Sehat+ berjumlah 616 hari (33,73%), sedangkan kelas Bukan Tidak Sehat+ berjumlah 1.210 hari (66,27%).

$$\text{Proporsi Kelas} = \text{Jumlah Observasi Kelas} / 1.826 \times 100\%$$

Berdasarkan rumus tersebut, kelas Tidak Sehat+ dihitung sebagai 616/1.826 × 100% = 33,73%, sedangkan kelas Bukan Tidak Sehat+ dihitung sebagai 1.210/1.826 × 100% = 66,27%. Perhitungan ini digunakan untuk menjelaskan komposisi target, bukan sebagai hasil performa model.

Dalam *notebook*, target numerik disimpan sebagai target_tidak_sehat, sedangkan label teks disimpan sebagai target_label. Kedua variabel ini hanya digunakan untuk kebutuhan pemodelan, evaluasi, tabel, dan visualisasi.

3.4.4. *Feature Engineering*

Fitur akhir yang digunakan berjumlah 17 fitur. Fitur tersebut terdiri dari enam polutan utama, yaitu PM2.5, PM10, SO2, CO, O3, dan NO2; fitur waktu yang terdiri dari Tahun, Bulan, Hari dalam Minggu, Indikator Akhir Pekan, dan Indikator Pasca-Pandemi; serta indikator *missing values* untuk masing-masing polutan. Daftar fitur final adalah PM2.5, PM10, SO2, CO, O3, NO2, Tahun, Bulan, Hari dalam Minggu, Indikator Akhir Pekan, Indikator Pasca-Pandemi, Indikator Missing PM2.5, Indikator Missing PM10, Indikator Missing SO2, Indikator Missing CO, Indikator Missing O3, Indikator Missing NO2.

Indikator Akhir Pekan bernilai 1 untuk Sabtu atau Minggu dan 0 untuk hari lain. Indikator Pasca-Pandemi bernilai 1 untuk tahun 2022-2024 dan 0 untuk tahun 2020-2021.

Indikator *missing values* dibentuk sebelum imputasi agar model tetap memiliki informasi bahwa nilai tertentu sebelumnya kosong.

Tabel III. 3 Daftar Fitur Final dan Variabel Target Penelitian

Kelompok	Variabel	Peran dalam Penelitian	Keterangan
Fitur polutan	PM2.5, PM10, SO2, CO, O3, NO2	Fitur model	Enam parameter polutan utama; bagian dari 17 fitur final.
Fitur waktu	Tahun, Bulan, Hari dalam Minggu, Indikator Akhir Pekan, Indikator Pasca-Pandemi	Fitur model	Lima fitur konteks waktu; bagian dari 17 fitur final.
Indikator missing values	Indikator Missing PM2.5, PM10, SO2, CO, O3, NO2	Fitur model	Enam indikator untuk menandai nilai yang awalnya kosong; bagian dari 17 fitur final.
Target/label	target_tidak_sehat	Target numerik	Bukan fitur model; bernilai 1 untuk Tidak Sehat+ dan 0 untuk Bukan Tidak Sehat+.
Target/label	target_label	Label teks/visualisasi	Bukan fitur model; digunakan untuk tabel, grafik, dan narasi hasil.

Sumber: Diolah oleh penulis (2026)

Tabel III.3 menegaskan bahwa fitur model berjumlah 17, yaitu enam fitur polutan, lima fitur waktu, dan enam indikator missing values. Variabel target_tidak_sehat dan target_label dicantumkan untuk menjelaskan keluaran penelitian, tetapi keduanya bukan fitur model.

3.4.5. Pencegahan *Target Leakage*

Kolom max dan critical tidak digunakan sebagai fitur model. Kolom max menunjukkan nilai indeks maksimum harian, sedangkan critical menunjukkan parameter pencemar yang menjadi penentu nilai tersebut. Karena keduanya terlalu dekat dengan pembentukan kategori ISPU, penggunaan kedua kolom tersebut sebagai fitur dapat menyebabkan *target leakage*.

Fitur model dibatasi pada polutan utama, fitur waktu, dan indikator *missing values*. Kolom categori, target_tidak_sehat, dan target_label juga tidak digunakan sebagai fitur karena berperan sebagai sumber target atau label pemodelan.

Kolom stasiun tidak digunakan sebagai fitur model karena penelitian memosisikan data sebagai deret harian ISPU DKI Jakarta berdasarkan struktur dataset yang dianalisis, bukan sebagai perbandingan antarstasiun pemantauan. Oleh karena itu, fitur model difokuskan pada parameter polutan, fitur waktu, dan indikator *missing values*.

3.4.6. Split Data Kronologis

Data dibagi secara kronologis berdasarkan tahun. Data latih mencakup 1 Januari 2020 sampai 31 Desember 2023 sebanyak 1.460 observasi dengan proporsi Tidak Sehat+ 36,1%. Data uji mencakup 1 Januari 2024 sampai 31 Desember 2024 sebanyak 366 observasi dengan proporsi Tidak Sehat+ 24,3%. Pembagian ini membuat model dilatih pada periode yang lebih awal dan diuji pada tahun setelahnya.

Pembagian acak tidak digunakan karena data memiliki struktur waktu harian. Dengan pembagian kronologis, evaluasi model lebih sesuai dengan kondisi penggunaan ketika model dilatih menggunakan data historis dan diuji pada periode yang lebih baru.

3.4.7. Missing Values, Imputasi, dan *Scaling*

Pemeriksaan nilai kosong pada periode 2020-2024 menunjukkan PM2.5 sebanyak 369 nilai (20,21%); PM10 sebanyak 200 nilai (10,95%); SO2 sebanyak 46 nilai (2,52%); CO sebanyak 27 nilai (1,48%); O3 sebanyak 23 nilai (1,26%); NO2 sebanyak 14 nilai (0,77%). Khusus PM2.5, tahun 2020 memiliki 366 nilai kosong dari 366 hari, sehingga interpretasi kontribusi PM2.5 pada tahun tersebut harus dibaca dengan hati-hati.

$$\text{Persentase Missing} = (\text{Jumlah Missing} / 1.826) \times 100\%$$

Sebagai contoh, PM2.5 dihitung sebagai $369/1.826 \times 100\% = 20,21\%$, sedangkan PM10 dihitung sebagai $200/1.826 \times 100\% = 10,95\%$. Perhitungan tersebut digunakan untuk membaca kualitas data dan tingkat kelengkapan parameter polutan sebelum imputasi.

Imputasi dilakukan setelah data dibagi secara kronologis. Pada data latih, nilai kosong polutan diisi melalui interpolasi berbasis waktu untuk celah pendek, median bulanan dari data

latih, dan median global dari data latih. Parameter median dari data latih kemudian diterapkan pada data uji. Pendekatan ini digunakan agar informasi dari data uji tidak ikut membentuk nilai imputasi evaluasi.

Scaling dilakukan menggunakan StandardScaler yang dilatih hanya pada data latih. Hasil *scaling* digunakan untuk LSTM dan GRU, sedangkan Random Forest dan XGBoost menggunakan data tabular tanpa *scaling* karena kedua model berbasis pohon tidak sensitif terhadap skala fitur seperti model jaringan saraf.

Detail parameter median bulanan dan median global untuk imputasi train-only disimpan pada Lampiran A.5 dalam file A5_parameter_imputasi_train.csv. Parameter mean dan standard deviation StandardScaler dari data latih disimpan pada Lampiran A.6 dalam file A6_scaler_mean_std_train.csv.

3.4.8. Pembentukan *Sequence* untuk LSTM dan GRU

LSTM dan GRU menggunakan *sliding window* 14 hari dengan skema X[i-window:i] → y[i]. Artinya, data 14 hari sebelumnya menjadi *input* untuk mengklasifikasikan status pada hari target berikutnya. Jumlah sequence data latih dihitung dari 1.460 observasi data latih dikurangi ukuran window 14 hari, sehingga diperoleh 1.460 - 14 = 1.446 sequence. Sequence tersebut dibagi secara kronologis menjadi 1.156 sequence untuk pelatihan internal dan 290 sequence untuk validasi. Data uji sequence berjumlah 366 target karena 14 hari terakhir data latih digunakan sebagai konteks awal untuk memprediksi hari pertama data uji.

Empat belas hari terakhir dari data latih digunakan sebagai konteks awal untuk memprediksi hari pertama pada data uji. Dengan cara ini, LSTM dan GRU tetap dievaluasi pada periode target yang sama dengan Random Forest dan XGBoost.

3.4.9. Pemodelan

Pemodelan dilakukan terhadap empat algoritma, yaitu Random Forest, XGBoost, LSTM, dan GRU. Random Forest dan XGBoost dilatih menggunakan data tabular pada hari

target hasil imputasi. LSTM dan GRU dilatih menggunakan data sekuensial hasil *scaling* dan *sliding window* 14 hari dengan TensorFlow/Keras.

Catatan metodologis perlu diberikan karena *input* model tidak sepenuhnya identik. Random Forest dan XGBoost menggunakan fitur tabular pada hari target, sedangkan LSTM dan GRU menggunakan konteks historis 14 hari sebelumnya untuk mengklasifikasikan hari target berikutnya. Oleh karena itu, perbandingan performa dibaca sebagai perbandingan dua pendekatan *input* yang berbeda, yaitu pendekatan tabular dan pendekatan sekuensial, bukan sebagai perbandingan *input* yang sepenuhnya sama.

Pada model ensemble, penanganan ketidakseimbangan kelas dilakukan melalui class_weight pada Random Forest dan scale_pos_weight pada XGBoost. Pada LSTM dan GRU, class weight dihitung dari data pelatihan internal. Seluruh model menghasilkan prediksi kelas dan probabilitas kelas Tidak Sehat+ pada data uji tahun 2024.

$$class_weight_i = n_samples / (n_classes \times n_i)$$

$$scale_pos_weight = \text{jumlah kelas negatif / jumlah kelas positif}$$

Berdasarkan data latih, kelas Bukan Tidak Sehat+ berjumlah 933 observasi dan kelas Tidak Sehat+ berjumlah 527 observasi. Dengan demikian, *scale_pos_weight* untuk XGBoost dihitung sebagai 933/527 ≈ 1,77. Rumus *class_weight* balanced menghasilkan bobot sekitar 0,78 untuk kelas negatif Bukan Tidak Sehat+ dan 1,39 untuk kelas positif Tidak Sehat+. Pembobotan kelas ini merupakan bagian dari proses pelatihan model, bukan hasil evaluasi performa.

3.4.10. Evaluasi Model

Evaluasi dilakukan pada data uji tahun 2024 sebanyak 366 observasi. Kelas positif pada penelitian ini adalah Tidak Sehat+, sedangkan kelas pembanding adalah Bukan Tidak Sehat+. Setiap model menghasilkan prediksi kelas dan probabilitas prediksi yang digunakan untuk mengevaluasi kemampuan model dalam membedakan kedua kelas target.

Confusion matrix digunakan untuk memperoleh nilai true positive, false positive, true negative, dan false negative. Dalam konteks penelitian ini, true positive menunjukkan hari Tidak Sehat+ yang berhasil diprediksi sebagai Tidak Sehat+, sedangkan false negative menunjukkan hari Tidak Sehat+ yang keliru diprediksi sebagai Bukan Tidak Sehat+. Nilai tersebut digunakan untuk menghitung Precision, Recall, dan F1-Score. Probabilitas prediksi digunakan untuk menghitung ROC-AUC.

Komponen confusion matrix dalam penelitian ini didefinisikan sebagai berikut: TP adalah hari dengan kategori aktual Tidak Sehat+ yang diprediksi sebagai Tidak Sehat+; TN adalah hari dengan kategori aktual Bukan Tidak Sehat+ yang diprediksi sebagai Bukan Tidak Sehat+; FP adalah hari dengan kategori aktual Bukan Tidak Sehat+ yang diprediksi sebagai Tidak Sehat+; dan FN adalah hari dengan kategori aktual Tidak Sehat+ yang diprediksi sebagai Bukan Tidak Sehat+.

Secara operasional, TP, FP, TN, dan FN diperoleh dari perbandingan antara target aktual dan prediksi kelas pada 366 observasi data uji. Precision, Recall, dan F1-Score dihitung dari komponen *confusion matrix* tersebut, sedangkan ROC-AUC dihitung dari probabilitas prediksi kelas Tidak Sehat+.

Precision = TP / (TP + FP)

Recall = TP / (TP + FN)

F1-Score = 2 × (Precision × Recall) / (Precision + Recall)

ROC-AUC dijelaskan sebagai ukuran luas area di bawah ROC curve yang dihitung dari probabilitas prediksi kelas Tidak Sehat+.

Pada notebook, ROC-AUC dihitung dari probabilitas prediksi kelas Tidak Sehat+ pada 366 observasi data uji tahun 2024. Perhitungan ROC curve dilakukan melalui pasangan TPR dan FPR pada berbagai threshold, sedangkan nilai akhir ROC-AUC tetap disajikan pada BAB IV.

Tahap evaluasi pada bab ini dijelaskan sebagai prosedur pengukuran kinerja model yang diterapkan secara konsisten terhadap Random Forest, XGBoost, LSTM, dan GRU. Nilai hasil evaluasi disajikan pada BAB IV sebagai bagian dari pembahasan hasil penelitian.

3.4.11. Interpretasi SHAP

Interpretasi dilakukan menggunakan SHAP pada model berbasis ensemble yang dipilih setelah proses evaluasi. SHAP dihitung untuk setiap fitur dan setiap observasi sehingga kontribusi fitur dapat dibaca baik pada tingkat observasi maupun secara global.

Mean absolute SHAP diperoleh dari rata-rata nilai absolut SHAP pada seluruh observasi. Nilai ini digunakan untuk menyusun peringkat kontribusi fitur tanpa membaca arah kontribusi sebagai hubungan sebab-akibat. Dengan demikian, SHAP pada penelitian ini menjelaskan pola kontribusi fitur terhadap keputusan model, bukan membuktikan penyebab perubahan kualitas udara.

$$\text{Mean Absolute SHAP}_j = (1/n)\ \Sigma\ |\text{SHAP}_{ij}|$$

Dalam rumus tersebut, $SHAP_{ij}$ menunjukkan nilai SHAP fitur ke-j pada observasi ke-i. Pada SHAP data uji 2024, n adalah jumlah observasi data uji, yaitu 366 observasi. Pada SHAP historis, nilai mean absolute SHAP diringkas per tahun dan per polutan untuk diagnosis retrospektif periode 2020-2024.

Secara operasional, nilai SHAP dihitung untuk setiap pasangan fitur dan observasi, kemudian nilai absolutnya dirata-ratakan untuk setiap fitur. Hasil akhir peringkat kontribusi fitur tidak ditampilkan pada BAB III karena menjadi bagian dari pembahasan hasil pada BAB IV.

SHAP pada data uji 2024 digunakan untuk interpretasi pada periode evaluasi generalisasi karena data tahun 2024 tidak digunakan untuk melatih model. Selain itu, SHAP historis 2020-2024 disajikan sebagai diagnosis retrospektif untuk membaca pola kontribusi rata-rata polutan sepanjang periode penelitian dengan tetap memperhatikan batasan kualitas

data, terutama *missing values* PM2.5 tahun 2020. Untuk SHAP historis, *notebook* membentuk model diagnostik berbasis konfigurasi model ensemble yang dipilih setelah evaluasi, kemudian melatihnya pada data periode 2020–2024 yang telah diimputasi; hasilnya digunakan untuk diagnosis retrospektif, bukan untuk evaluasi generalisasi.

UNIVERSITAS BINA SARANA INFORMATIKA