BAB V

PENUTUP

5.1. Kesimpulan

Berdasarkan hasil penelitian, model klasifikasi biner ISPU DKI Jakarta periode 2020-2024 berhasil dikembangkan untuk membedakan kelas Tidak Sehat+ dan Bukan Tidak Sehat+. Data final berjumlah 1.826 observasi dan dibagi secara kronologis menjadi data latih 2020-2023 serta data uji 2024.

Hasil evaluasi menunjukkan bahwa model ensemble lebih unggul dibandingkan model pembelajaran mendalam pada rancangan eksperimen ini. Random Forest memperoleh Precision 0,9767, Recall 0,9438, F1-Score 0,9600, dan ROC-AUC 0,9822. XGBoost memiliki F1-Score sama, tetapi ROC-AUC lebih rendah, sedangkan LSTM dan GRU menunjukkan performa yang lebih kecil pada input sekuens 14 hari.

Random Forest dipilih sebagai model terpilih untuk interpretasi SHAP. Hasil SHAP menunjukkan bahwa PM2.5 menjadi fitur paling dominan pada data uji 2024, diikuti PM10, O3, CO, NO2, dan SO2. Secara historis, PM2.5 dominan pada 2021-2024, sedangkan O3 dominan pada 2020. Dengan demikian, H1(1) dan H1(2) diterima karena terdapat perbedaan kinerja model dan kontribusi fitur yang dominan.

5.2. Saran

Berdasarkan hasil penelitian dan batas interpretasi yang telah dijelaskan, penelitian selanjutnya disarankan untuk menambahkan variabel meteorologi seperti suhu, kelembapan, curah hujan, arah angin, dan kecepatan angin. Variabel tersebut dapat memperkaya konteks analisis karena kualitas udara tidak hanya dipengaruhi oleh konsentrasi polutan, tetapi juga oleh kondisi cuaca dan dinamika atmosfer. Penambahan variabel meteorologi juga dapat membantu menjelaskan pola kontribusi fitur yang tidak sepenuhnya dapat ditangkap oleh fitur polutan dan fitur waktu pada dataset utama.

Penelitian selanjutnya juga disarankan untuk memperkuat kualitas data, khususnya pada parameter yang memiliki missing values besar. Pada penelitian ini, PM2.5 tahun 2020 memiliki nilai kosong penuh sebelum imputasi. Oleh karena itu, penelitian berikutnya dapat menggunakan sumber data tambahan atau mekanisme validasi data yang lebih rinci agar interpretasi pada periode dengan missing values besar dapat dilakukan dengan lebih kuat.

Untuk model deep learning, penelitian berikutnya dapat menguji variasi panjang jendela waktu selain 14 hari, misalnya 7 hari, 21 hari, atau 30 hari. Pengujian beberapa ukuran window dapat membantu menentukan apakah pola temporal kualitas udara lebih sesuai dibaca dalam rentang pendek atau panjang. Selain itu, tuning hyperparameter dan penggunaan arsitektur lain seperti Bidirectional LSTM, Attention, atau Transformer berbasis time series dapat dipertimbangkan untuk mengevaluasi kemampuan model deep learning secara lebih luas.

Pengembangan berikutnya juga dapat menerapkan time series cross-validation atau pengujian pada periode data yang lebih panjang. Strategi tersebut dapat membantu menilai stabilitas model ketika digunakan pada periode yang berbeda. Apabila data setelah tahun 2024 telah tersedia dalam satu tahun penuh, data tersebut dapat digunakan sebagai periode uji tambahan untuk mengevaluasi kemampuan generalisasi model.

Penelitian selanjutnya dapat mempertimbangkan analisis berbasis stasiun pemantauan. Dalam penelitian ini, kolom stasiun tidak digunakan sebagai fitur karena penelitian memosisikan data sebagai deret harian ISPU DKI Jakarta secara umum, bukan sebagai perbandingan antarstasiun. Analisis berbasis stasiun dapat memberikan pemahaman yang lebih rinci mengenai perbedaan pola kontribusi polutan pada lokasi pemantauan yang berbeda.

Dari sisi interpretabilitas, penggunaan SHAP dapat dikembangkan dengan analisis yang lebih mendalam, misalnya dengan membandingkan kontribusi fitur antarperiode pandemi, transisi, dan pasca-pandemi, atau dengan membaca kontribusi fitur berdasarkan musim dan

karakter waktu tertentu. Namun, interpretasi SHAP tetap perlu dibatasi sebagai penjelasan terhadap keputusan model, bukan bukti kausalitas lingkungan.

Terakhir, hasil penelitian ini dapat dijadikan dasar awal pengembangan sistem pendukung keputusan kualitas udara yang tidak hanya menampilkan hasil klasifikasi Tidak Sehat+ atau Bukan Tidak Sehat+, tetapi juga memberikan penjelasan mengenai fitur yang memengaruhi keputusan model. Dengan pendekatan tersebut, model klasifikasi kualitas udara dapat menjadi lebih transparan, lebih mudah dipahami, dan lebih informatif bagi peneliti maupun pihak yang berkepentingan dalam pemantauan kualitas udara perkotaan.

BINA SARANA INFORMATIKA
UNIVERSITAS