ANALISIS PERBANDINGAN KINERJA MODEL ENSEMBLE DAN *DEEP LEARNING* UNTUK KLASIFIKASI ISPU JAKARTA MENGGUNAKAN EXPLAINABLE AI (SHAP)

SKRIPSI

Diajukan untuk memenuhi salah satu syarat kelulusan Program Sarjana (S1)

ERIEL SETIAWAN DEWANTORO

NIM: 17220785

Program Studi Teknologi Informasi

Fakultas Teknik dan Informatika

Universitas Bina Sarana Informatika

Jakarta

2026

SURAT PERNYATAAN KEASLIAN SKRIPSI PADA PROGRAM SARJANA

Yang bertanda tangan di bawah ini:

Nama	: Eriel Setiawan Dewantoro
NIM	: 17220785
Jenjang	: Sarjana (S1)
Program Studi	: Teknologi Informasi
Fakultas	: Teknik dan Informatika
Perguruan Tinggin	: Universitas Bina Sarana Informatika

Dengan ini menyatakan bahwa Skripsi/Tugas Akhir yang telah saya buat dengan judul: **"Analisis Perbandingan Kinerja Model *Ensemble* Dan *Deep Learning* Untuk Klasifikasi Ispu Jakarta Menggunakan Explainable Ai (SHAP)",** adalah asli (orsinil) atau tidak plagiat (menjiplak) dan belum pernah diterbitkan/dipublikasikan dimanapun dan dalam bentuk apapun.

Demikianlah surat pernyataan ini saya buat dengan sebenar-benarnya tanpa ada paksaan dari pihak manapun juga. Apabila di kemudian hari ternyata saya memberikan keterangan palsu dan atau ada pihak lain yang mengklaim bahwa Skripsi pada Program Sarjana yang telah saya buat adalah hasil karya milik seseorang atau badan tertentu, saya bersedia diproses baik secara pidana maupun perdata dan kelulusan saya dari **Univeristas Bina Sarana Informatika** dicabut/dibatalkan.

Dibuat di : Bekasi
Pada tanggal : 07 Juli 2026
Yang menyatakan,



Eriel Setiawan Dewantoro

SURAT PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH UNTUK KEPENTINGAN AKADEMIS

Yang bertanda tangan di bawah ini, saya:

Nama	: Eriel Setiawan Dewantoro
NIM	: 17220785
Jenjang	: Sarjana (S1)
Program Studi	: Teknologi Informasi
Fakultas	: Fakultas Teknik dan Informatika
Perguruan Tinggi	: Universitas Bina Sarana Informatika

Dengan ini menyatakan bahwa seluruh data, informasi, interpretasi serta pernyataan yang terdapat dalam karya ilmiah Penulis dengan judul "**Analisis Perbandingan Kinerja Model *Ensemble* Dan *Deep Learning* Untuk Klasifikasi Ispu Jakarta Menggunakan Explainable Ai (SHAP)**" ini, kecuali yang disebutkan sumbernya adalah hasil pengamatan, penelitian, pengelolaan, serta pemikiran saya.

Penulis menyetujui untuk memberikan izin kepada pihak **Universitas Bina Sarana Informatika** untuk mendokumentasikan karya ilmiah saya tersebut secara internal dan terbatas, serta tidak untuk mengunggah karya ilmiah Penulis pada repository Universitas Bina Sarana Informatika.

Penulis bersedia untuk bertanggung jawab secara pribadi, tanpa melibatkan pihak **Universitas Bina Sarana Informatika**, atas materi/isi karya ilmiah tersebut, termasuk bertanggung jawab atas dampak atau kerugian yang timbul dalam bentuk akibat tindakan yang berkaitan dengan data, informasi, interpretasi serta pernyataan yang terdapat pada karya ilmiah saya ini.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di Bekasi
Pada tanggal 7 Juli 2026

Yang Menyatakan,



Eriel Setiawan Dewantoro

SURAT PERSETUJUAN DAN PENGESAHAN SKRIPSI

Skripsi ini diajukan oleh:

Nama	:	Eriel Setiawan Dewantoro
NIM	:	17220785
Jenjang	:	Sarjana (S1)
Program Studi	:	Teknologi Informasi
Fakultas	:	Teknik dan Informatika
Perguruan Tinggi	:	Universitas Bina Sarana Informatika
Judul Skripsi	:	Analisis Perbandingan Kinerja Model Ensemble dan Deep Learning untuk Klasifikasi ISPU Jakarta Menggunakan Explainable AI (SHAP)

Telah dipertahankan pada periode 2026-1 dihadapan penguji dan diterima sebagai bagian persyaratan yang diperlukan untuk memperoleh Sarjana Komputer (S.Kom) pada Program Sarjana (S1) Program Studi Teknologi Informasi di Universitas Bina Sarana Informatika.

Jakarta, 11 Agustus 2026

PEMBIMBING SKRIPSI

Pembimbing I : Suhar Janti, M.Kom.

Ditandatangani Digital:
Suharjanti
2026-08-11 17:12:35

D E W A N P E N G U J I

Penguji I : Maisyaroh, M.Kom.

Ditandatangani Digital:
Maysaroh
2026-08-11 19:41:37

Penguji II : Eva Zuraidah, M.Kom.

Ditandatangani Digital:
Eva Zuraidah
2026-08-11 19:30:47

PEDOMAN PENGGUNAAN HAK CIPTA

Skripsi sarjana yang berjudul **"Analisis Perbandingan Kinerja Model Ensemble dan Deep Learning untuk Klasifikasi ISPU Jakarta Menggunakan Explainable AI (SHAP)"** adalah hasil karya tulis asli Nama Mahasiswa dan bukan hasil terbitan sehingga peredaran karya tulis hanya berlaku di lingkungan akademik saja, serta memiliki hak cipta. Oleh karena itu, dilarang keras untuk menggandakan baik sebagian maupun seluruhnya karya tulis ini, tanpa seizin penulis.

Referensi kepustakaan diperkenankan untuk dicatat tetapi pengutipan atau peringkasan isi tulisan hanya dapat dilakukan dengan seizin penulis dan disertai ketentuan pengutipan secara ilmiah dengan menyebutkan sumbernya

Untuk keperluan perizinan pada pemilik dapat menghubungi informasi yang tertera di bawah ini:

Nama : Eriel Setiawan Dewantoro

Alamat : Jl Raya AL Jatimakmur, Jatimakmur, Pondok Gede, Bekasi, Jawa Barat

No. Telp : 085883591786

E-mail : erielsdewantoro@gmail.com

LEMBAR KONSULTASI SKRIPSI

UNIVERSITAS BINA SARANA INFORMATIKA

NIM : 17220785

Nama Lengkap : Eriel Setiawan Dewantoro

Dosen Pembimbing : Suharjanti, M.Kom

Judul Tugas Akhir : ANALISIS PERBANDINGAN KINERJA MODEL ENSEMBLE DAN DEEP LEARNING UNTUK KLASIFIKASI ISPU JAKARTA MENGGUNAKAN EXPLAINABLE AI (SHAP)

NO	Tanggal Bimbingan	Pokok Bahasan	Paraf Dosen Pembimbing I
1	27 April 2026	Pengajuan Judul dan Bab 1	
2	4 Mei 2026	Revisi Judul dan Bab 1	
3	11 Mei 2026	Pengajuan Bab 2: Tinjauan Pustaka	
4	18 Mei 2026	Revisi Bab 2: Tinjauan Pustaka	
5	5 Juni 2026	Pengajuan Bab 3: Metodologi	
6	12 Juni 2026	Revisi Bab 3: Metodologi	
7	19 Juni 2026	Pengajuan Bab 4: Pembahasan	
8	29 Juni 2026	Revisi Bab 4: Hasil Pembahasan	
9	7 Juli 2026	ACC Keseluruhan Bab	

Catatan untuk Dosen Pembimbing.
Bimbingan Skripsi
Dimulai pada tanggal : 27 April 2026
Diakhiri pada tanggal : 7 Juli 2026
Jumlah pertemuan bimbingan : 9

Disetujui oleh,
Dosen Pembimbing

Ditandatangani Digital: Suharjanti 2026-07-07 15:33:36

(Suharjanti, M.Kom)

MOTTO

"Fa-inna ma'al 'usri yusraa, inna ma'al 'usri yusraa"
"Maka sesungguhnya bersama kesulitan itu ada kemudahan, sesungguhnya bersama kesulitan itu ada kemudahan."
— QS. Al-Insyirah: 5-6

"Semua ada waktunya, semua ada gilirannya, semua ada jalannya."
— Halimah Alaydrus

Melamban bukanlah hal yang tabu Kadang itu yang kau butuh, bersandar hibahkan bebanmu Tak perlu kau berhenti kurasi Ini hanya sementara,
bukan ujung dari rencana.
— Perunggu (33x)

Dan di hariku yang paling gelap, Semoga aku akan mengingat
Bahwa ini sementara Dan akan segera pergi dengan cepat.
— The Adams (Timur)

Katakan pada dirimu, besok mungkin kita sampai, besok mungkin tercapai.
— Baskara Putra (Hindia)

PERSEMBAHAN

Segala syukur kepada Allah Swt. atas rahmat dan kemudahan-Nya. Karya sederhana ini dipersembahkan kepada jiwa-jiwa luar biasa yang selalu hadir dengan doa, kasih, serta ilmu yang mengantarkan penulis hingga mampu menyelesaikan perjalanan ini.

1. Untuk kedua orang tua tersayang, Bapak Hendra Susanto dan Mamah Erni Noviana. Tak ada upaya yang berhasil tanpa doa, dan pastilah doa tulus Ayah dan Mamah yang melancarkan setiap langkah penulis. Doa yang tak pernah putus mengalir dari bibir kalian adalah kekuatan terbesar. Semoga tumbuh kembang penulis saat ini mampu menjadi kebanggaan dan sesuai dengan apa yang diimpikan.
2. Untuk kedua abang tercinta, Mas Ekky Rivaldy Hartono dan Mas Eggy Sapto Wibowo. Terima kasih telah selalu percaya, mendukung, dan menguatkan dengan cara masing-masing. Dukungan yang diberikan menjadi salah satu alasan utama mengapa penulis mampu tetap melangkah tangguh hingga sampai di titik ini.
3. Untuk Bude Yunike Subarwati. Guru pertama di luar kedua orang tua yang dengan penuh kesabaran mengajari penulis. Setiap huruf yang tertulis dalam skripsi ini merupakan buah dari ilmu yang Bude tanamkan. Dengan penuh rasa syukur dan hormat terima kasih yang tak terhingga penulis haturkan.

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Allah Swt. atas segala rahmat, karunia, dan pertolongan-Nya sehingga skripsi ini dapat diselesaikan dengan baik. Sebagaimana firman Allah Swt. dalam QS. Al-Insyirah ayat 5–6, *"Sesungguhnya bersama kesulitan itu ada kemudahan,"* ayat tersebut menjadi pengingat bagi penulis untuk terus melangkah dalam setiap proses penyusunan skripsi ini.

Skripsi yang berjudul **"Analisis Perbandingan Kinerja Model Ensemble dan Deep Learning untuk Klasifikasi ISPU Jakarta Menggunakan Explainable AI (SHAP)"** ini disusun sebagai salah satu syarat memperoleh gelar Sarjana pada Program Studi Sistem Informasi, Universitas Bina Sarana Informatika. Penulis menyadari bahwa skripsi ini tidak akan terselesaikan tanpa doa, dukungan, bimbingan, dan bantuan dari berbagai pihak. Oleh karena itu, penulis menyampaikan terima kasih dan penghormatan setinggi-tingginya kepada :

1. Allah Swt. yang senantiasa melimpahkan rahmat, kesehatan, kekuatan, serta kemudahan dalam setiap tahapan kehidupan penulis.
2. Kedua orang tua tercinta, Bapak Hendra Susanto dan Ibu Erni Noviana, pilar pendukung utama yang tidak pernah berhenti mengalirkan doa, kasih sayang, serta menjadi sumber kekuatan terbesar penulis.
3. Kedua abang penulis, Mas Ekky Rivaldy Hartono dan Mas Eggy Sapto Wibowo, atas kepercayaan, motivasi, dan dukungan moral yang selalu diberikan di setiap situasi.
4. Bude Yunike Subarwati yang telah menjadi guru pertama di luar keluarga dan memberikan fondasi ilmu yang menjadi bekal dalam perjalanan akademik penulis.
5. Ibu Suharjanti, M.Kom., selaku dosen pembimbing yang telah meluangkan waktu, tenaga, pikiran, serta dengan penuh kesabaran memberikan arahan, bimbingan, dan masukan berharga selama proses penyusunan skripsi ini.
6. Seluruh Dosen dan Staf Program Studi Sistem Informasi Universitas Bina Sarana Informatika yang telah membekali penulis dengan ilmu pengetahuan, pengalaman, serta wawasan luas selama menempuh masa perkuliahan
7. Seluruh keluarga, sahabat, teman-teman seperjuangan, serta berbagai pihak yang tidak dapat disebutkan satu per satu atas doa dan kebersamaannya.

Apresiasi khusus juga penulis sampaikan kepada Hindia, .Feast, Perunggu, The Adams, Fourtwnty, dan Lomba Sihir, yang karya-karya musiknya telah menjadi latar suara sekaligus suntikan energi penenang selama malam-malam panjang penyusunan skripsi ini..

Penulis menyadari bahwa skripsi ini masih memiliki keterbatasan dan jauh dari kata sempurna. Oleh karena itu, penulis mengharapkan kritik dan saran yang membangun demi penyempurnaan penelitian ini di masa mendatang. Besar harapan penulis agar skripsi ini dapat memberikan manfaat, baik sebagai tambahan referensi dalam bidang *machine learning*, *deep learning*, dan *Explainable Artificial Intelligence* (XAI), maupun sebagai kontribusi bagi pengembangan penelitian terkait klasifikasi kualitas udara di Indonesia.

Akhir kata, penulis berharap semoga segala kebaikan yang telah diberikan oleh semua pihak mendapatkan balasan terbaik dari Allah Swt.

Bekasi, 7 Juli 2026



Eriel Setiawan Dewantoro

ABSTRAKSI

Eriel Setiawan Dewantoro (17220785), Analisis Perbandingan Kinerja Model Ensemble Dan Deep Learning Untuk Klasifikasi Ispu Jakarta Menggunakan Explainable Ai (SHAP)

Kualitas udara di DKI Jakarta menjadi isu penting karena tingginya aktivitas perkotaan yang berpotensi meningkatkan pencemaran udara dan berdampak pada kesehatan masyarakat. Pemanfaatan data Indeks Standar Pencemar Udara (ISPU) diperlukan untuk mendukung identifikasi kondisi udara tidak sehat melalui pendekatan klasifikasi yang akurat dan mudah diinterpretasikan. Penelitian ini bertujuan membandingkan kinerja model *ensemble learning* (*Random Forest* dan *XGBoost*) dengan *deep learning* (*Long Short-Term Memory*/*LSTM* dan *Gated Recurrent Unit*/*GRU*) dalam mengklasifikasikan status ISPU Jakarta, serta menginterpretasikan kontribusi fitur menggunakan *SHapley Additive exPlanations* (*SHAP*). Penelitian menggunakan pendekatan kuantitatif dengan desain eksperimen komputasional berbasis data sekunder ISPU DKI Jakarta periode 2020–2024 yang bersumber dari Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui Satu Data Jakarta dan diakses melalui Kaggle. Setelah proses prapemrosesan diperoleh 1.826 observasi valid yang dibagi secara kronologis menjadi data latih (2020–2023) dan data uji (2024). Evaluasi dilakukan menggunakan metrik *Precision*, *Recall*, *F1-Score*, dan *ROC-AUC*. Hasil penelitian menunjukkan bahwa *Random Forest* memberikan kinerja terbaik dengan *Precision* 0,9767, *Recall* 0,9438, *F1-Score* 0,9600, dan *ROC-AUC* 0,9822, diikuti *XGBoost* dengan *ROC-AUC* 0,9724, sedangkan *LSTM* dan *GRU* menunjukkan kinerja yang lebih rendah pada rancangan *input* sekuensial. Analisis *SHAP* menunjukkan bahwa PM2.5 merupakan fitur yang memberikan kontribusi terbesar terhadap keputusan klasifikasi, diikuti oleh PM10, O3, CO, NO2, dan SO2. Dengan demikian, model *Random Forest* terbukti paling efektif untuk klasifikasi status ISPU Jakarta pada penelitian ini, sementara penerapan *SHAP* mampu meningkatkan interpretabilitas model sehingga hasil klasifikasi tidak hanya akurat, tetapi juga memberikan informasi mengenai kontribusi setiap parameter pencemar udara dalam pengambilan keputusan.

Kata Kunci: ISPU Jakarta; Random Forest; XGBoost; LSTM; GRU; SHAP; klasifikasi kualitas udara

ABSTRACT

Eriel Setiawan Dewantoro (17220785), Analisis Perbandingan Kinerja Model Ensemble Dan Deep Learning Untuk Klasifikasi Ispu Jakarta Menggunakan Explainable Ai (SHAP)

Air quality in the Special Capital Region of Jakarta has become an important issue due to the high intensity of urban activities that contribute to air pollution and adversely affect public health. The utilization of the Air Pollution Standard Index (Indeks Standar Pencemar Udara/ISPU) data is essential to support the identification of unhealthy air quality conditions through an accurate and interpretable classification approach. This study aims to compare the performance of ensemble learning models (Random Forest and XGBoost) with deep learning models (Long Short-Term Memory/LSTM and Gated Recurrent Unit/GRU) in classifying Jakarta's ISPU status and to interpret feature contributions using SHapley Additive exPlanations (SHAP). This research employed a quantitative approach with a computational experimental design using secondary ISPU data for Jakarta from 2020 to 2024, obtained from the Jakarta Environmental Agency through the Jakarta Open Data Portal and accessed via Kaggle. After the preprocessing stage, 1,826 valid observations were obtained and chronologically divided into training data (2020–2023) and testing data (2024). Model performance was evaluated using Precision, Recall, F1-Score, and ROC-AUC metrics. The results indicate that Random Forest achieved the best performance with a Precision of 0.9767, Recall of 0.9438, F1-Score of 0.9600, and ROC-AUC of 0.9822, followed by XGBoost with a ROC-AUC of 0.9724, while LSTM and GRU exhibited lower performance under the sequential input design. SHAP analysis revealed that PM2.5 was the most influential feature in the classification process, followed by PM10, O3, CO, NO2, and SO2. Therefore, Random Forest proved to be the most effective model for classifying Jakarta's ISPU status in this study, while SHAP enhanced model interpretability by providing insights into the contribution of each air pollutant parameter to the classification decisions.

***Keywords**: Jakarta Air Pollution Standard Index (ISPU); Random Forest; XGBoost; LSTM; GRU; SHAP; air quality classification.*

DAFTAR ISI

SURAT PERNYATAAN KEASLIAN SKRIPSI PADA PROGRAM SARJANA ii

SURAT PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH UNTUK KEPENTINGAN AKADEMIS iii

SURAT PERSETUJUAN DAN PENGESAHAN SKRIPSI iv

PEDOMAN PENGGUNAAN HAK CIPTA v

LEMBAR KONSULTASI SKRIPSI vi

UNIVERSITAS BINA SARANA INFORMATIKA vi

MOTTO vii

PERSEMBAHAN viii

KATA PENGANTAR ix

ABSTRAKSI xi

DAFTAR ISI xiii

DAFTAR GAMBAR xvii

DAFTAR TABEL xix

DAFTAR LAMPIRAN xx

BAB I PENDAHULUAN 1

1.1. Latar Belakang Masalah 1

1.2. Identifikasi Permasalahan 5

1.3. Perumusan Masalah 6

1.4. Tujuan dan Manfaat 6

1.4.1. Tujuan Penelitian 6

1.4.2. Manfaat Penelitian 7

1.5. Metode Penelitian 7

1.5.1. Teknik Pengumpulan Data 7

A. Observasi 7

B. Studi Pustaka 8

1.5.2. Metode Analisis Data 8
1.6. Ruang Lingkup 9
1.7. Hipotesis 11
BAB II LANDASAN TEORI 12
2.1. Tinjauan Pustaka 12
2.1.1. Indeks Standar Pencemar Udara 12
2.1.2. Parameter Pencemar Udara 13
2.1.3. Klasifikasi Kualitas Udara 14
2.1.4. Data Sekunder dan Data Deret Waktu Harian 16
2.1.5. *Machine Learning* 17
2.1.6. *Ensemble Learning* 17
2.1.7. Random Forest 18
2.1.8. XGBoost 18
2.1.9. *Deep Learning* 19
2.1.10. Long Short-Term Memory 19
2.1.11. Gated Recurrent Unit 20
2.1.12. *Sliding Window* 20
2.1.13. Data Preprocessing 21
2.1.14. Missing Values dan Imputasi 21
2.1.15. Scaling dan Standardisasi 22
2.1.16. Evaluasi Model Klasifikasi 22
2.1.17. Target Leakage 24
2.1.18. Explainable Artificial Intelligence dan SHAP 25
2.1.19. Kerangka Konseptual Penelitian 26
2.2. Penelitian Terkait 27
2.3. Tinjauan Organisasi/Objek Penelitian 32
2.3.1. DKI Jakarta sebagai Wilayah Kajian Kualitas Udara 32

2.3.2. Sumber Data ISPU DKI Jakarta 33
2.3.3. Karakteristik Data Penelitian 33
2.3.4. Variabel Penelitian 34
2.3.5. Target Klasifikasi 34
2.3.6. Posisi Objek Penelitian terhadap Metode 35
BAB III METODOLOGI PENELITIAN 36
3.1. Tahapan Penelitian 36
3.2. Instrumen Penelitian 39
3.3. Metode Pengumpulan Data, Populasi, dan Sampel Penelitian 40
3.4. Metode Analisis Data 41
3.4.1. *Data Understanding* 41
3.4.2. Seleksi Periode dan Pembersihan Data 42
3.4.3. Pembentukan Target Biner 43
3.4.4. *Feature Engineering* 43
3.4.5. Pencegahan *Target Leakage* 44
3.4.6. Split Data Kronologis 45
3.4.7. Missing Values, Imputasi, dan *Scaling* 45
3.4.8. Pembentukan *Sequence* untuk LSTM dan GRU 46
3.4.9. Pemodelan 46
3.4.10. Evaluasi Model 47
3.4.11. Interpretasi SHAP 49
BAB IV HASIL PENELITIAN DAN PEMBAHASAN 51
4.1. Library dan Lingkungan Komputasi 51
4.2. Load Dataset dan Gambaran Dataset Mentah 53
4.3. Data Understanding dan Struktur Dataset 56
4.4. Seleksi Periode, Pembersihan, dan Data Final 1.826 Observasi 58
4.5. Distribusi Kategori ISPU Asli 61

4.6. Pembentukan Target Biner 63
4.7. Pemeriksaan Missing Values Awal 68
4.8. Feature Engineering dan Pencegahan Target Leakage 72
4.9. Imputasi, Scaling, dan Pembentukan Sequence LSTM/GRU 74
4.10. Training Random Forest, XGBoost, LSTM, dan GRU 77
4.11. Evaluasi Model 79
4.12. Pemilihan Model Terpilih 86
4.13. Interpretasi SHAP Data Uji 2024 88
4.14. Interpretasi SHAP Historis 2020-2024 92
BAB V PENUTUP 95
5.1. Kesimpulan 95
5.2. Saran 95
DAFTAR PUSTAKA 98
DAFTAR RIWAYAT HIDUP 101
SURAT PERNYATAAN KEBENARAN/KEABSAHAN DATA HASIL RISET UNTUK KARYA ILMIAH 102
BUKTI HASIL PENGECEKAN PLAGIARISME 103
LAMPIRAN 106

DAFTAR GAMBAR

Gambar III. 1 Alur Tahapan Penelitian 37
Gambar IV. 1 Cuplikan Library Python yang Digunakan dalam Eksperimen 52
Gambar IV. 2 Cuplikan Kode Python untuk Memuat Dataset Mentah 54
Gambar IV. 3 Screenshot Dataset Mentah ispu_dki_all.csv 55
Gambar IV. 4 Cuplikan Kode Python Pemeriksaan Struktur Dataset 56
Gambar IV. 5 Screenshot Output Pemeriksaan Struktur Dataset 57
Gambar IV. 6 Cuplikan Kode Python Seleksi Periode dan Pembersihan Data 59
Gambar IV. 7 Screenshot Output Seleksi Periode dan Data Final Pemodelan 59
Gambar IV. 8 Screenshot Shape Data Final Pemodelan 1.826 Observasi 60
Gambar IV. 9 Cuplikan Kode Python Distribusi Kategori ISPU Asli 62
Gambar IV. 10 Screenshot Output Distribusi Kategori ISPU Asli 62
Gambar IV. 11 Cuplikan Kode Python Pembentukan Target Biner 64
Gambar IV. 12 Screenshot Output Pemetaan Target Biner 65
Gambar IV. 13 Screenshot Output Distribusi Target Biner 67
Gambar IV. 14 Cuplikan Kode Python Perhitungan Missing Values 68
Gambar IV. 15 Screenshot Output Tabel Missing Values per Polutan 69
Gambar IV. 16 Screenshot Output Heatmap Missing Values per Tahun dan Polutan 70
Gambar IV. 17 Cuplikan Kode Python Proses Imputasi Train-Only 70
Gambar IV. 18 Screenshot Output Validasi Setelah Imputasi 71
Gambar IV. 19 Cuplikan Kode Python Feature Engineering dan Pencegahan Target Leakage 72
Gambar IV. 20 Output Daftar Fitur Final 73
Gambar IV. 21 Cuplikan Kode Python Split Kronologis 74
Gambar IV. 22 Screenshot Output Ringkasan Split Kronologis 75
Gambar IV. 23 Cuplikan Kode Python Scaling dan Pembentukan Sequence 76
Gambar IV. 24 Cuplikan Kode Python Training Empat Model 77
Gambar IV. 25 Cuplikan Kode Python Evaluasi Model 79
Gambar IV. 26 Screenshot Output Tabel Evaluasi Empat Model 80
Gambar IV. 27 Screenshot Output Confusion Matrix Empat Model 83
Gambar IV. 28 Screenshot Output Grafik Perbandingan Kinerja Model 84

Gambar IV. 29 ROC Curve Empat Model pada Data Uji 2024..... 85
Gambar IV. 30 Precision-Recall Curve Empat Model pada Data Uji 2024 86
Gambar IV. 31 Cuplikan Kode Python Pemilihan Model untuk SHAP 87
Gambar IV. 32 Cuplikan Kode Python SHAP Data Uji 2024 88
Gambar IV. 33 Screenshot Output Tabel Mean Absolute SHAP Data Uji 2024 89
Gambar IV. 34 SHAP Feature Importance pada Data Uji 2024 90
Gambar IV. 35 SHAP Summary Plot Data Uji 2024..... 91
Gambar IV. 36 Cuplikan Kode Python SHAP Historis 2020-2024..... 92
Gambar IV. 37 Screenshot Output Tabel Dominasi SHAP Historis 93
Gambar IV. 38 Gambar IV.38 Heatmap SHAP Historis per Tahun dan Polutan..... 94

BINA SARANA INFORMATIKA
UNIVERSITAS

DAFTAR TABEL

Tabel II. 1 Kategori ISPU dan Rentang Nilai 13
Tabel II. 2 Definisi Operasional Target Biner 15
Tabel II. 3 Penelitian Terkait 30

Tabel III. 1 Kriteria Data Penelitian..... 40
Tabel III. 2 Daftar Kolom Dataset Awal dan Perannya dalam Penelitian 42
Tabel III. 3 Daftar Fitur Final dan Variabel Target Penelitian 44

Tabel IV. 1 Library Utama yang Digunakan dalam Eksperimen..... 53
Tabel IV. 2 Ringkasan Dataset Mentah 55
Tabel IV. 3 Peran Kolom Dataset dalam Penelitian 57
Tabel IV. 4 Ringkasan Seleksi Periode dan Pembersihan Data..... 60
Tabel IV. 5 Distribusi Kategori ISPU Valid pada Data Final 1.826 Observasi..... 63
Tabel IV. 6 Pemetaan Target Biner..... 66
Tabel IV. 7 Distribusi Target Biner 67
Tabel IV. 8 Missing Values pada Parameter Polutan 69
Tabel IV. 9 Ringkasan Hasil Setelah Imputasi 71
Tabel IV. 10 Ringkasan Fitur Final dan Kolom Dikecualikan 73
Tabel IV. 11 Ringkasan Split Data Latih dan Data Uji..... 75
Tabel IV. 12 Ringkasan Input Sequence LSTM dan GRU..... 76
Tabel IV. 13 Ringkasan Input Pemodelan 77
Tabel IV. 14 Hasil Evaluasi Kinerja Model..... 80
Tabel IV. 15 Ringkasan Confusion Matrix Empat Model pada Data Uji 2024..... 82
Tabel IV. 16 Dasar Pemilihan Model Terpilih..... 87
Tabel IV. 17 Ringkasan Mean Absolute SHAP Data Uji 2024 88
Tabel IV. 18 Ringkasan Dominasi SHAP Historis 2020-2024..... 93

DAFTAR LAMPIRAN

Lampiran. 1 Data Awal Penelitian (5.539 Observasi) 106
Lampiran. 2 Data Final Penelitian (1.826 Observasi)..... 106
Lampiran. 3 Notebook Eksperimen Penelitian 107

UNIVERSITAS BINA SARANA INFORMATIKA

BAB I

PENDAHULUAN

1.1. Latar Belakang Masalah

Kualitas udara merupakan aspek penting dalam kesehatan lingkungan perkotaan karena udara ambien yang tercemar dapat meningkatkan risiko gangguan pernapasan, menurunkan kenyamanan aktivitas masyarakat, dan memperbesar beban kesehatan publik. Pedoman kualitas udara global menempatkan *Particulate Matter* 2.5 (PM2.5), *Particulate Matter* 10 (PM10), Ozon (O3), Nitrogen Dioksida (NO2), Sulfur Dioksida (SO2), dan Karbon Monoksida (CO) sebagai parameter penting dalam penilaian risiko kesehatan akibat pencemaran udara (*World Health Organization*, 2021). Kondisi tersebut relevan bagi DKI Jakarta sebagai wilayah metropolitan dengan intensitas transportasi, aktivitas perkantoran, permukiman padat, serta sumber emisi perkotaan yang tinggi. Oleh karena itu, pemantauan dan analisis kualitas udara tidak cukup hanya dipandang sebagai kegiatan pencatatan lingkungan, tetapi juga sebagai dasar penyusunan informasi peringatan dini dan kebijakan pengendalian pencemaran udara.

Di Indonesia, mutu udara ambien dikomunikasikan melalui Indeks Standar Pencemar Udara (ISPU). Berdasarkan Peraturan Menteri Lingkungan Hidup dan Kehutanan Nomor 14 Tahun 2020, ISPU merupakan angka tanpa satuan yang menggambarkan kondisi mutu udara ambien di lokasi tertentu berdasarkan dampaknya terhadap kesehatan manusia, nilai estetika, dan makhluk hidup lainnya (Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia, 2020). Dalam dataset penelitian ini, parameter yang tersedia dan digunakan terdiri dari *Particulate Matter* 2.5 (PM2.5), *Particulate Matter* 10 (PM10), Sulfur Dioksida (SO2), Karbon Monoksida (CO), Ozon (O3), dan Nitrogen Dioksida (NO2). Keenam parameter tersebut menjadi dasar analisis karena masing-masing merepresentasikan karakter pencemar udara yang berbeda.

PM2.5 adalah partikulat halus berdiameter aerodinamis tidak lebih dari 2,5 mikrometer, sedangkan PM10 adalah partikulat berdiameter aerodinamis tidak lebih dari 10 mikrometer. Ukuran PM2.5 yang lebih kecil membuatnya lebih mudah masuk ke saluran pernapasan bagian dalam, sehingga parameter ini penting dalam kajian risiko kualitas udara perkotaan. Sulfur Dioksida (SO2) adalah gas yang terbentuk dari pembakaran bahan bakar yang mengandung sulfur. Karbon Monoksida (CO) adalah gas hasil pembakaran tidak sempurna dari bahan bakar berbasis karbon. Ozon (O3) permukaan adalah polutan sekunder di troposfer yang terbentuk melalui reaksi fotokimia antara oksida nitrogen dan senyawa organik volatil dengan bantuan radiasi matahari. Nitrogen Dioksida (NO2) adalah gas reaktif yang terbentuk terutama dari proses pembakaran bersuhu tinggi, termasuk emisi kendaraan bermotor dan aktivitas pembakaran lainnya. Penjelasan parameter ini penting agar penelitian tidak hanya dipahami sebagai percobaan algoritma, tetapi juga sebagai analisis data lingkungan yang memiliki makna substantif.

Data yang digunakan dalam penelitian ini merupakan data sekunder ISPU DKI Jakarta yang bersumber dari Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui portal Satu Data Jakarta dan diakses dalam bentuk dataset terstruktur melalui Kaggle. Portal data pemerintah menjelaskan bahwa data ISPU DKI Jakarta diperoleh dari pengukuran Stasiun Pemantau Kualitas Udara di Provinsi DKI Jakarta (Pemerintah Provinsi DKI Jakarta, 2025). Dataset mentah yang diperiksa memiliki 5.539 baris dan 11 kolom dengan rentang tanggal 1 Januari 2010 sampai 28 Februari 2025. Namun, penelitian ini membatasi periode analisis pada 1 Januari 2020 sampai 31 Desember 2024, sehingga data yang digunakan berada pada lima tahun kalender penuh.

Pembatasan periode 2020-2024 dilakukan karena periode tersebut merepresentasikan fase pandemi, transisi, dan pasca-pandemi. Tahun 2020-2021 berkaitan dengan pembatasan mobilitas masyarakat, sedangkan tahun 2022-2024 berkaitan dengan pemulihan aktivitas perkotaan dan normalisasi mobilitas. Fokus waktu ini memberikan dasar ilmiah untuk menguji

apakah karakter kontribusi polutan terhadap status kualitas udara tidak sehat mengalami perbedaan antara masa pembatasan mobilitas dan masa setelah aktivitas masyarakat kembali meningkat. Tahun 2025 tidak digunakan karena data yang tersedia belum mencakup satu siklus tahunan penuh, sedangkan data sebelum 2020 tidak menjadi fokus karena penelitian diarahkan pada periode perubahan mobilitas yang berkaitan dengan pandemi dan pasca-pandemi.

Setelah pemotongan periode 2020-2024, pemeriksaan awal terhadap dataset menunjukkan terdapat 1.827 observasi harian. Satu baris dengan kategori TIDAK ADA DATA dikeluarkan dari data pemodelan karena kategori tersebut bukan status mutu udara. Dengan demikian, jumlah observasi yang digunakan untuk pemodelan adalah 1.826 hari. Target penelitian dibentuk sebagai klasifikasi biner, yaitu kelas Tidak Sehat+ dan kelas Bukan Tidak Sehat+. Kelas Tidak Sehat+ terdiri dari kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT, sedangkan kelas Bukan Tidak Sehat+ terdiri dari kategori BAIK dan SEDANG. Penamaan kelas pembanding mengikuti kategori asli pada kolom categori agar definisi target tetap konsisten dengan struktur dataset. Dalam konteks ini, SANGAT TIDAK SEHAT tetap dipahami sebagai kategori asli ISPU, sedangkan Tidak Sehat+ merupakan definisi operasional penelitian dan bukan kategori resmi baru dalam regulasi ISPU.

Target biner tersebut digunakan sebagai dasar pemodelan agar keluaran penelitian tetap berada pada kerangka klasifikasi status ISPU. Dengan demikian, model tidak diarahkan untuk memperkirakan nilai ISPU numerik, tetapi untuk membedakan hari yang termasuk Tidak Sehat+ dan Bukan Tidak Sehat+ secara terukur. Evaluasi model dilakukan menggunakan *Precision, Recall, F1-Score*, dan *Receiver Operating Characteristic-Area Under the Curve* (ROC-AUC) agar kemampuan model dalam membedakan kedua kelas dapat dinilai secara komprehensif.

Penelitian terdahulu yang dekat dengan konteks penelitian ini menunjukkan bahwa pembelajaran mesin (*machine learning*) dan pembelajaran mendalam (*deep learning*) telah banyak digunakan dalam analisis kualitas udara. (Hasna et al., 2024) membahas penggunaan

Random Forest untuk klasifikasi ISPU DKI Jakarta, sedangkan (Banjarnahor et al., 2025) membandingkan *Support Vector Machine* dan Random Forest pada kategori indeks kualitas udara Jakarta. (Karmoude et al., 2025) menunjukkan bahwa *machine learning* banyak digunakan dalam kajian kualitas udara, sementara (Radjabaycolle et al., 2025) memperlihatkan pemanfaatan LSTM dan SHAP pada studi kualitas udara Jakarta. Selain itu, (Yenkikar et al., 2025) memperkuat relevansi SHAP sebagai pendekatan interpretabilitas pada indeks kualitas udara. Berdasarkan penelitian tersebut, masih terdapat ruang untuk membandingkan Random Forest, XGBoost, LSTM, dan GRU dalam satu kerangka klasifikasi biner Tidak Sehat+ pada periode 2020-2024 serta melengkapi evaluasi model dengan interpretasi kontribusi fitur menggunakan SHAP.

Model ensemble yang digunakan dalam penelitian ini adalah Random Forest dan XGBoost. Random Forest bekerja dengan membangun banyak pohon keputusan dan menggabungkan hasilnya untuk meningkatkan stabilitas klasifikasi. XGBoost membangun model pohon secara bertahap dengan memperbaiki kesalahan model sebelumnya, sehingga sering digunakan pada data tabular yang memiliki hubungan tidak linear. Model pembelajaran mendalam (*deep learning*) yang digunakan adalah Long Short-Term Memory (LSTM) dan Gated Recurrent Unit (GRU). LSTM dan GRU digunakan karena keduanya dirancang untuk membaca data berurutan. Pada model LSTM dan GRU, jendela geser (*sliding window*) 14 hari digunakan dengan skema X[i-window:i] → y[i], yaitu data empat belas hari sebelumnya menjadi masukan untuk mengklasifikasikan status hari target berikutnya.

Selain membandingkan performa model, penelitian ini menempatkan interpretabilitas model sebagai komponen utama. Interpretabilitas diperlukan karena model klasifikasi kualitas udara sebaiknya tidak hanya menghasilkan label Tidak Sehat+ atau Bukan Tidak Sehat+, tetapi juga memberikan penjelasan mengenai kontribusi parameter polutan dan fitur waktu terhadap keputusan model. Untuk kebutuhan tersebut, penelitian ini menggunakan SHapley Additive exPlanations (SHAP). SHAP digunakan untuk mengukur kontribusi fitur terhadap keputusan

klasifikasi model, bukan untuk membuktikan hubungan sebab-akibat. Dengan demikian, hasil interpretasi dibaca sebagai kontribusi fitur menurut model yang dianalisis.

Berdasarkan uraian tersebut, penelitian ini diarahkan untuk membandingkan performa model Random Forest, XGBoost, LSTM, dan GRU dalam klasifikasi status ISPU DKI Jakarta, serta mendiagnosis kontribusi fitur polutan dan fitur waktu menggunakan SHAP. Fokus penelitian berada pada keterhubungan antara data ISPU 2020-2024, target klasifikasi Tidak Sehat+, skema evaluasi klasifikasi, dan interpretabilitas model. Dengan demikian, penelitian ini tidak hanya bertujuan memilih model dengan performa terbaik, tetapi juga menyusun dasar analisis yang mampu menjelaskan fitur pencemar udara dan konteks waktu yang berkontribusi terhadap status kualitas udara tidak sehat di Jakarta.

1.2. Identifikasi Permasalahan

Berdasarkan latar belakang yang telah diuraikan, permasalahan dalam penelitian ini dapat diidentifikasi sebagai berikut:

1. Data ISPU DKI Jakarta perlu dianalisis secara lebih operasional untuk membentuk model yang mampu membedakan hari Tidak Sehat+ dan Bukan Tidak Sehat+ secara terukur.
2. Periode 2020-2024 mencakup fase pandemi, transisi, dan pasca-pandemi, sehingga kontribusi polutan terhadap status kualitas udara perlu dianalisis dalam kerangka waktu yang jelas.
3. Penelitian terdahulu dalam konteks kualitas udara Jakarta telah menunjukkan pemanfaatan model pembelajaran mesin (*machine learning*) maupun pembelajaran mendalam (*deep learning*) untuk klasifikasi atau prediksi kualitas udara. Namun, kajian yang secara terpadu membandingkan Random Forest, XGBoost, LSTM, dan GRU pada target klasifikasi biner Tidak Sehat+ dan Bukan Tidak Sehat+ dengan pembagian data kronologis serta metrik evaluasi yang sama masih terbatas. Kondisi tersebut menunjukkan perlunya pengujian keempat model dalam satu kerangka eksperimen agar perbandingan kinerja yang dihasilkan lebih adil dan dapat dipertanggungjawabkan.

4. Model klasifikasi kualitas udara tidak cukup hanya dinilai berdasarkan performa, karena kontribusi fitur polutan terhadap keputusan model perlu dijelaskan agar hasil penelitian dapat dipahami secara ilmiah.
5. Diperlukan pendekatan interpretabilitas model menggunakan SHapley Additive exPlanations (SHAP) untuk mendiagnosis kontribusi fitur polutan dan fitur waktu terhadap keputusan klasifikasi status Tidak Sehat+.

1.3. Perumusan Masalah

Berdasarkan identifikasi permasalahan tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Pengembangan model klasifikasi biner status ISPU DKI Jakarta periode 2020-2024 untuk membedakan kelas Tidak Sehat+ dan Bukan Tidak Sehat+ dengan membandingkan kinerja Random Forest, XGBoost, LSTM, dan GRU.
2. Pengembangan analisis interpretabilitas model menggunakan SHAP untuk menjelaskan kontribusi fitur polutan dan fitur waktu terhadap keputusan klasifikasi status Tidak Sehat+.

1.4. Tujuan dan Manfaat

1.4.1. Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Membangun dan membandingkan model Random Forest, XGBoost, LSTM, dan GRU untuk klasifikasi biner status ISPU Tidak Sehat+ dan Bukan Tidak Sehat+ pada data ISPU DKI Jakarta periode 2020-2024.
2. Mengevaluasi performa model menggunakan metrik klasifikasi yang mencakup Precision, Recall, F1-Score, dan ROC-AUC.
3. Menerapkan SHAP pada model berbasis ensemble yang dipilih setelah proses evaluasi untuk menginterpretasikan kontribusi fitur polutan dan fitur waktu terhadap hasil klasifikasi status Tidak Sehat+.

1.4.2. Manfaat Penelitian

Manfaat penelitian ini disusun berdasarkan pihak yang memperoleh kegunaan langsung dari hasil pengembangan model dan analisis interpretabilitas.

1. Bagi penulis, penelitian ini menjadi sarana penerapan ilmu pengolahan data, pembelajaran mesin, pembelajaran mendalam, dan kecerdasan buatan terjelaskan pada studi kasus kualitas udara.
2. Bagi objek penelitian, hasil penelitian dapat menjadi bahan kajian berbasis data untuk memahami klasifikasi status ISPU Jakarta serta kontribusi parameter pencemar terhadap kondisi Tidak Sehat+.
3. Bagi pembaca dan peneliti selanjutnya, penelitian ini dapat menjadi referensi mengenai perbandingan model ensemble dan pembelajaran mendalam, pembagian data kronologis, pencegahan kebocoran target, serta penggunaan SHAP pada klasifikasi kualitas udara.

1.5. Metode Penelitian

Penelitian ini menggunakan metode kuantitatif dengan pendekatan eksperimental komputasional. Pendekatan kuantitatif digunakan karena penelitian memanfaatkan data numerik polutan ISPU, sedangkan pendekatan eksperimental digunakan karena penelitian membandingkan beberapa algoritma dalam skenario pemodelan yang sama. Seluruh proses dilakukan menggunakan Python dalam lingkungan Google Colaboratory agar tahapan penelitian dapat ditelusuri dan direproduksi.

Tahapan penelitian dimulai dari pemahaman data, pemotongan periode 2020-2024, pembersihan data, pembentukan target biner, rekayasa fitur polutan dan fitur waktu, pembagian data berbasis waktu, pelatihan model, evaluasi model, dan interpretasi SHAP.

1.5.1. Teknik Pengumpulan Data

A. Observasi

Observasi dilakukan terhadap data sekunder berupa dataset publik ISPU DKI Jakarta. Data utama yang digunakan bersumber dari Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui

portal Satu Data Jakarta dan diakses dalam bentuk dataset terstruktur melalui Kaggle. Data tersebut memuat kolom tanggal, stasiun pemantauan, PM2.5, PM10, SO2, CO, O3, NO2, max, critical, dan categori. Penelitian ini tidak menggunakan wawancara karena seluruh analisis didasarkan pada data sekunder kuantitatif dan studi pustaka.

B. Studi Pustaka

Studi pustaka dilakukan dengan menelaah regulasi ISPU, dokumen data terbuka, dan artikel ilmiah yang relevan dengan klasifikasi kualitas udara, model ensemble, pembelajaran mendalam (*deep learning*), dan interpretabilitas SHAP. Literatur utama dipilih berdasarkan kedekatan dengan penelitian, terutama penelitian yang menggunakan data kualitas udara Jakarta, Random Forest untuk klasifikasi ISPU, komparasi model pembelajaran mesin (*machine learning*) pada kualitas udara Jakarta, serta SHAP untuk interpretasi model kualitas udara.

1.5.2. Metode Analisis Data

Metode analisis data dalam penelitian ini dilakukan melalui tahapan berikut:

1. Pemahaman data (*data understanding*), yaitu memahami struktur dataset, rentang tanggal, jumlah baris, jumlah kolom, serta makna setiap variabel.
2. Prapemrosesan data (*data preprocessing*), yaitu memfilter periode 1 Januari 2020 sampai 31 Desember 2024 dan mengeluarkan kategori TIDAK ADA DATA dari data pemodelan.
3. Penanganan nilai kosong dan imputasi (*missing values* dan imputasi), yaitu memeriksa nilai kosong, membentuk indikator *missing values*, kemudian mengisi nilai kosong pada kolom polutan menggunakan interpolasi berbasis waktu untuk celah pendek, median bulanan dari data latih, dan median global dari data latih sebagai langkah akhir imputasi.
4. Rekayasa fitur (*feature engineering*), yaitu membentuk fitur polutan utama, fitur waktu, indikator akhir pekan, indikator pasca-pandemi, serta indikator *missing values*. Fitur waktu yang digunakan meliputi tahun, bulan, hari dalam minggu, indikator akhir pekan, dan indikator pasca-pandemi agar model memiliki konteks temporal yang sesuai dengan periode pandemi, transisi, dan pasca-pandemi.

5. Pembentukan target (*target engineering*), yaitu mengubah kategori ISPU menjadi target biner Tidak Sehat+ dan Bukan Tidak Sehat+. Kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT diberi label positif, sedangkan BAIK dan SEDANG diberi label pembanding.
6. Pencegahan kebocoran target (*target leakage*), yaitu tidak menggunakan kolom max dan critical sebagai fitur model karena kedua kolom tersebut merupakan informasi turunan yang sangat dekat dengan pembentukan kategori ISPU.
7. Pembagian data kronologis, yaitu pembagian data dilakukan secara kronologis, yaitu data 2020-2023 sebagai data latih dan data 2024 sebagai data uji.
8. Pemodelan (*modeling*), yaitu melatih Random Forest dan XGBoost pada data tabular, serta melatih LSTM dan GRU dengan jendela geser (*sliding window*) 14 hari untuk membaca pola urutan waktu.
9. Evaluasi model (*model evaluation*), yaitu membandingkan model menggunakan Precision, Recall, F1-Score, dan ROC-AUC.
10. Analisis interpretabilitas (*explainability analysis*), yaitu menggunakan SHAP pada model berbasis ensemble yang dipilih setelah proses evaluasi untuk menjelaskan kontribusi fitur terhadap keputusan klasifikasi kelas Tidak Sehat+.

1.6. Ruang Lingkup

Agar penelitian tetap terarah, ruang lingkup penelitian ini dibatasi sebagai berikut:

1. Data yang digunakan adalah data sekunder ISPU DKI Jakarta yang bersumber dari DLH DKI Jakarta melalui Satu Data Jakarta dan diakses melalui Kaggle.
2. Dataset awal mencakup rentang 1 Januari 2010 sampai 28 Februari 2025. Penelitian ini membatasi analisis pada periode 1 Januari 2020 sampai 31 Desember 2024 karena fokus penelitian diarahkan untuk membandingkan karakter kualitas udara pada masa pandemi, transisi, dan pasca-pandemi. Data tahun 2010-2019 tidak digunakan karena berada di luar

fokus periode penelitian, sedangkan data tahun 2025 tidak digunakan karena belum mencakup satu tahun penuh.

3. Variabel *input* utama dibatasi pada enam parameter polutan, yaitu PM2.5, PM10, SO2, CO, O3, dan NO2, serta fitur pendukung berupa tahun, bulan, hari dalam minggu, indikator akhir pekan, indikator pasca-pandemi, dan indikator *missing values*.
4. Kolom max dan critical tidak digunakan sebagai fitur model karena berpotensi menyebabkan kebocoran target (*target leakage*).
5. Target penelitian adalah klasifikasi biner status ISPU, yaitu Tidak Sehat+ dan Bukan Tidak Sehat+. Tidak Sehat+ terdiri dari kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT, sedangkan Bukan Tidak Sehat+ terdiri dari kategori BAIK dan SEDANG.
6. Model yang dibandingkan adalah Random Forest, XGBoost, LSTM, dan GRU. LSTM dan GRU menggunakan pendekatan jendela geser (*sliding window*) 14 hari dengan skema X[i-window:i] → y[i] untuk memanfaatkan informasi urutan waktu dari empat belas hari sebelumnya.
7. Evaluasi model menggunakan metrik klasifikasi, yaitu Precision, Recall, F1-Score, dan ROC-AUC.
8. Analisis interpretabilitas dilakukan menggunakan SHAP pada model berbasis ensemble yang dipilih setelah proses evaluasi, sehingga interpretasi difokuskan pada kontribusi fitur terhadap keputusan klasifikasi.
9. Penelitian tidak memasukkan variabel meteorologi eksternal seperti suhu, kelembapan, curah hujan, arah angin, atau kecepatan angin karena variabel tersebut tidak tersedia pada dataset utama yang digunakan.
10. Implementasi penelitian dilakukan menggunakan Python dalam lingkungan Google Colaboratory, dengan pustaka utama Pandas, NumPy, Scikit-learn, XGBoost, TensorFlow/Keras, Matplotlib, Seaborn, dan SHAP.

1.7. Hipotesis

Hipotesis penelitian dirumuskan secara operasional berdasarkan tujuan pengembangan model dan interpretasi fitur.

H0(1): Tidak terdapat perbedaan kinerja yang menonjol antara model ensemble dan model pembelajaran mendalam dalam klasifikasi status ISPU Tidak Sehat+ dan Bukan Tidak Sehat+ berdasarkan Precision, Recall, F1-Score, dan ROC-AUC.

H1(1): Terdapat perbedaan kinerja antara model ensemble dan model pembelajaran mendalam, dengan dugaan model ensemble memberikan kinerja lebih baik karena data penelitian berbentuk tabular.

H0(2): Tidak terdapat fitur polutan atau fitur waktu yang dominan dalam keputusan klasifikasi model berdasarkan nilai rata-rata absolut SHAP.

H1(2): Terdapat fitur polutan atau fitur waktu yang dominan dalam keputusan klasifikasi model berdasarkan nilai rata-rata absolut SHAP.

Penerimaan atau penolakan hipotesis dilakukan berdasarkan hasil evaluasi model pada data uji 2024 dan hasil interpretasi SHAP pada model ensemble terpilih.

BAB II

LANDASAN TEORI

2.1. Tinjauan Pustaka

Tinjauan pustaka pada penelitian ini disusun sebagai dasar teoritis bagi pembahasan Indeks Standar Pencemar Udara (ISPU), parameter pencemar udara, klasifikasi kualitas udara, model pembelajaran mesin, model pembelajaran mendalam, evaluasi klasifikasi, pencegahan kebocoran target, serta interpretabilitas model menggunakan SHapley Additive exPlanations (SHAP). Landasan teori ini diperlukan agar penelitian tidak hanya dipahami sebagai penerapan algoritma, tetapi juga sebagai kajian data lingkungan yang memiliki konteks kesehatan, kebijakan publik, dan metodologi komputasional.

2.1.1. Indeks Standar Pencemar Udara

Indeks Standar Pencemar Udara atau ISPU merupakan indikator yang digunakan untuk menyampaikan kondisi mutu udara ambien kepada masyarakat dalam bentuk angka tanpa satuan. Berdasarkan Peraturan Menteri Lingkungan Hidup dan Kehutanan Republik Indonesia Nomor 14 Tahun 2020, ISPU menggambarkan kondisi mutu udara ambien di lokasi tertentu berdasarkan dampaknya terhadap kesehatan manusia, nilai estetika, dan makhluk hidup lainnya (Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia, 2020). Dengan adanya ISPU, informasi kualitas udara dapat dikomunikasikan secara lebih sederhana karena nilai parameter pencemar udara yang bersifat teknis diterjemahkan ke dalam kategori mutu udara.

Kategori ISPU ditetapkan berdasarkan rentang angka resmi dalam Peraturan Menteri Lingkungan Hidup dan Kehutanan Nomor P.14/Menlhk/Setjen/Kum.1/7/2020 tentang Indeks Standar Pencemar Udara. Rentang tersebut digunakan untuk menjelaskan kategori kualitas udara yang muncul pada dataset sebelum target penelitian dibentuk.

Tabel II. 1 Kategori ISPU dan Rentang Nilai

Kategori ISPU	Status Warna	Rentang Nilai ISPU	Keterangan Penelitian
Baik	Hijau	1-50	Kategori asli ISPU dan termasuk Bukan Tidak Sehat+ pada target biner.
Sedang	Biru	51-100	Kategori asli ISPU dan termasuk Bukan Tidak Sehat+ pada target biner.
Tidak Sehat	Kuning	101-200	Kategori asli ISPU dan termasuk Tidak Sehat+ pada target biner.
Sangat Tidak Sehat	Merah	201-300	Kategori asli ISPU dan termasuk Tidak Sehat+ pada target biner.
Berbahaya	Hitam	>=301	Kategori resmi ISPU, tetapi tidak muncul pada data penelitian periode 2020-2024.

Sumber: Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia (2020), diolah oleh penulis (2026)

Dalam penelitian ini, ISPU digunakan sebagai dasar pembentukan target klasifikasi. Status kualitas udara tidak diperlakukan sebagai nilai numerik yang diprediksi melalui regresi, melainkan sebagai kategori yang diklasifikasikan ke dalam dua kelompok, yaitu Tidak Sehat+ dan Bukan Tidak Sehat+. Kelompok Tidak Sehat+ merupakan gabungan dari kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT, sedangkan kelompok Bukan Tidak Sehat+ merupakan gabungan dari kategori BAIK dan SEDANG. Penggabungan kategori tersebut dilakukan agar model diarahkan untuk mengenali kondisi kualitas udara yang berpotensi lebih berisiko terhadap kesehatan masyarakat.

Istilah Tidak Sehat+ dalam penelitian ini bukan merupakan kategori resmi baru dalam regulasi ISPU, melainkan definisi operasional penelitian untuk kebutuhan klasifikasi biner. Dengan demikian, istilah tersebut digunakan untuk membedakan hari dengan kondisi kualitas udara yang perlu mendapat perhatian lebih tinggi dari hari dengan kualitas udara yang masih berada pada kategori baik atau sedang. Istilah prediksi pada penelitian ini juga dimaknai sebagai prediksi status atau kelas kualitas udara, bukan prediksi nilai numerik ISPU.

2.1.2. Parameter Pencemar Udara

Parameter pencemar udara merupakan variabel utama yang digunakan untuk menilai kualitas udara. Pada penelitian ini, parameter yang digunakan terdiri dari Particulate Matter 2.5

(PM2.5), Particulate Matter 10 (PM10), Sulfur Dioksida (SO2), Karbon Monoksida (CO), Ozon (O3), dan Nitrogen Dioksida (NO2). Keenam parameter tersebut dipilih karena tersedia dalam dataset ISPU DKI Jakarta dan merepresentasikan karakter pencemar udara yang berbeda. Pedoman kualitas udara *global* menempatkan Particulate Matter 2.5 (PM2.5), Particulate Matter 10 (PM10), Ozon (O3), Nitrogen Dioksida (NO2), Sulfur Dioksida (SO2), dan Karbon Monoksida (CO) sebagai parameter penting dalam penilaian risiko kesehatan akibat pencemaran udara (World Health Organization, 2021).

PM2.5 merupakan partikulat halus dengan diameter aerodinamis tidak lebih dari 2,5 mikrometer. Ukurannya yang sangat kecil membuat partikel ini dapat masuk lebih dalam ke saluran pernapasan sehingga sering menjadi perhatian utama dalam kajian kualitas udara dan kesehatan lingkungan. PM10 merupakan partikulat dengan diameter aerodinamis tidak lebih dari 10 mikrometer. Meskipun ukurannya lebih besar dibandingkan PM2.5, PM10 tetap relevan karena dapat masuk ke sistem pernapasan dan menunjukkan kontribusi pencemar berbasis debu, aktivitas lalu lintas, maupun sumber partikulat lain.

Sulfur Dioksida (SO2) merupakan gas yang umumnya berkaitan dengan pembakaran bahan bakar yang mengandung sulfur. Karbon Monoksida (CO) merupakan gas hasil pembakaran tidak sempurna dari bahan bakar berbasis karbon. Ozon (O3) permukaan merupakan polutan sekunder yang terbentuk melalui reaksi fotokimia antara senyawa prekursor dengan bantuan sinar matahari. Nitrogen Dioksida (NO2) merupakan gas reaktif yang banyak dikaitkan dengan proses pembakaran bersuhu tinggi, termasuk emisi kendaraan bermotor dan aktivitas perkotaan lainnya. Dalam penelitian ini, parameter polutan tidak hanya dipandang sebagai angka *input* model, tetapi juga sebagai representasi kondisi lingkungan yang dapat membantu menjelaskan status kualitas udara.

2.1.3. Klasifikasi Kualitas Udara

Klasifikasi merupakan pendekatan analisis data yang bertujuan memetakan sekumpulan fitur *input* ke dalam kelas atau kategori tertentu. Dalam konteks kualitas udara, klasifikasi dapat

digunakan untuk menentukan apakah kondisi udara berada pada kelas baik, sedang, tidak sehat, atau kategori lain sesuai definisi yang digunakan. Berbeda dengan regresi yang menghasilkan nilai numerik, klasifikasi menghasilkan label kelas sebagai keluaran model.

Penelitian ini menggunakan pendekatan klasifikasi biner. Target yang digunakan adalah status Tidak Sehat+ dan Bukan Tidak Sehat+. Kelas Tidak Sehat+ menjadi kelas positif karena merepresentasikan kondisi kualitas udara yang lebih berisiko, sedangkan Bukan Tidak Sehat+ menjadi kelas pembanding. Pendekatan ini selaras dengan tujuan penelitian, yaitu membangun model yang mampu membedakan hari dengan status kualitas udara tidak sehat dari hari yang tidak termasuk kategori tersebut.

Kategori asli tetap ditampilkan pada BAB IV sebagai bagian dari *data understanding*, sedangkan pemodelan menggunakan target biner agar fokus penelitian diarahkan pada pemisahan kondisi Tidak Sehat+ dan Bukan Tidak Sehat+. Kategori TIDAK ADA DATA tidak digunakan dalam pemodelan karena tidak merepresentasikan status kualitas udara yang dapat dipelajari model.

$$\text{Proporsi Kelas} = (\text{Jumlah Observasi Kelas} / \text{Total Observasi}) \times 100\%$$

Rumus proporsi kelas digunakan untuk membaca distribusi kategori asli, distribusi target biner, dan proporsi kelas pada pembagian data latih serta data uji. Nilai persentase yang dihasilkan membantu menjelaskan apakah komposisi kelas relatif seimbang atau cenderung didominasi oleh salah satu kelas.

Tabel II. 2 Definisi Operasional Target Biner

Kategori Asli Dataset	Definisi Operasional	Peran dalam Pemodelan
BAIK	Bukan Tidak Sehat+	Kelas negatif
SEDANG	Bukan Tidak Sehat+	Kelas negatif
TIDAK SEHAT	Tidak Sehat+	Kelas positif
SANGAT TIDAK SEHAT	Tidak Sehat+	Kelas positif
TIDAK ADA DATA	Dikeluarkan	Tidak digunakan dalam pemodelan

Sumber: Diolah oleh penulis (2026)

(Liu et al., 2024) menunjukkan bahwa klasifikasi kelas kualitas udara dapat dilakukan menggunakan metode *machine learning* berdasarkan data pemantauan kualitas udara. Literatur tersebut memperkuat posisi penelitian ini bahwa data pencemar udara dapat digunakan untuk membangun model klasifikasi status kualitas udara. Namun, penelitian ini tetap memiliki batasan yang jelas karena tidak diarahkan untuk memprediksi nilai numerik ISPU, melainkan untuk membedakan status Tidak Sehat+ dan Bukan Tidak Sehat+.

2.1.4. Data Sekunder dan Data Deret Waktu Harian

Data sekunder adalah data yang tidak dikumpulkan langsung oleh peneliti melalui pengukuran lapangan, melainkan diperoleh dari sumber yang telah tersedia. Pada penelitian ini, data yang digunakan merupakan data sekunder ISPU DKI Jakarta yang bersumber dari Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui Satu Data Jakarta dan diakses dalam bentuk dataset terstruktur melalui Kaggle. Penggunaan data sekunder sesuai dengan karakter penelitian yang berfokus pada analisis komputasional terhadap data historis kualitas udara.

Data ISPU memiliki karakter deret waktu harian karena setiap observasi berkaitan dengan tanggal tertentu. Karakter ini penting karena kualitas udara dapat dipengaruhi oleh pola temporal, seperti perubahan aktivitas masyarakat, hari kerja dan akhir pekan, serta perubahan periode pandemi, transisi, dan pasca-pandemi. Oleh karena itu, selain fitur polutan utama, penelitian ini juga menggunakan fitur waktu seperti tahun, bulan, hari dalam minggu, indikator akhir pekan, indikator pasca-pandemi, dan indikator *missing values*.

Meskipun data memiliki urutan waktu, penelitian ini tidak diarahkan sebagai peramalan nilai ISPU numerik. Urutan waktu digunakan untuk menjaga validitas pembagian data secara kronologis dan untuk membentuk masukan sekuensial pada model Long Short-Term Memory (LSTM) dan Gated Recurrent Unit (GRU). Dengan demikian, pendekatan deret waktu dalam penelitian ini tetap berada dalam kerangka klasifikasi status kualitas udara.

2.1.5. *Machine Learning*

Machine learning merupakan cabang kecerdasan buatan yang memungkinkan sistem mempelajari pola dari data tanpa harus diprogram secara eksplisit untuk setiap aturan keputusan. Pada penelitian kualitas udara, *machine learning* dapat digunakan untuk mempelajari hubungan antara parameter pencemar udara, fitur waktu, dan status kualitas udara. (Karmoude et al., 2025) menjelaskan bahwa metode *machine learning* banyak digunakan dalam kajian kualitas udara karena mampu menangani pola data yang kompleks dan tidak selalu linear. Dalam penelitian ini, *machine learning* digunakan untuk membangun model klasifikasi berdasarkan data tabular yang terdiri dari parameter polutan dan fitur pendukung waktu. Model *machine learning* yang digunakan adalah Random Forest dan XGBoost. Keduanya termasuk dalam kelompok model ensemble yang menggabungkan beberapa model dasar untuk meningkatkan stabilitas dan kemampuan prediksi.

2.1.6. *Ensemble Learning*

Ensemble learning adalah pendekatan pemodelan yang menggabungkan beberapa model untuk menghasilkan klasifikasi yang lebih stabil dibandingkan model tunggal. Prinsip utama dari pendekatan ini adalah bahwa gabungan beberapa model dapat mengurangi kelemahan satu model tertentu, baik dari sisi variansi maupun bias. Dalam klasifikasi kualitas udara, pendekatan ensemble banyak digunakan karena data lingkungan sering memiliki hubungan antarvariabel yang tidak linear.

Dalam penelitian ini, pendekatan ensemble direpresentasikan oleh Random Forest dan XGBoost. Random Forest menggunakan mekanisme bagging, sedangkan XGBoost menggunakan mekanisme boosting. Keduanya relevan untuk data tabular karena mampu membaca pola dari fitur polutan dan fitur waktu tanpa mengharuskan hubungan antarvariabel berbentuk linear. (Fahim et al., 2025) menunjukkan bahwa teknik ensemble dapat digunakan untuk meningkatkan klasifikasi indeks kualitas udara, terutama ketika model perlu mengevaluasi hubungan antara parameter pencemar dan kelas kualitas udara.

2.1.7. Random Forest

Random Forest merupakan algoritma ensemble yang membangun banyak pohon keputusan kemudian menggabungkan hasil prediksi dari pohon-pohon tersebut. Pada masalah klasifikasi, keputusan akhir Random Forest umumnya ditentukan berdasarkan suara mayoritas dari sejumlah pohon keputusan. Pendekatan ini membantu meningkatkan stabilitas model karena keputusan tidak bergantung hanya pada satu pohon.

Random Forest sering digunakan pada data tabular karena mampu menangani hubungan nonlinear antarfitur, relatif kuat terhadap variasi data, dan dapat memberikan gambaran mengenai kontribusi fitur melalui ukuran kepentingan fitur. Dalam konteks ISPU, Random Forest relevan karena data yang digunakan terdiri dari parameter polutan dan fitur waktu yang bersifat terstruktur.

(Hasna et al., 2024) menggunakan Random Forest untuk klasifikasi ISPU DKI Jakarta tahun 2022. (Banjarnahor et al., 2025) juga membandingkan Random Forest dengan Support Vector Machine untuk kategori kualitas udara Jakarta. Kedua penelitian tersebut menunjukkan bahwa Random Forest telah digunakan dalam konteks kualitas udara Jakarta, sehingga pemakaian Random Forest pada penelitian ini memiliki dasar empiris yang dekat dengan objek penelitian.

2.1.8. XGBoost

Extreme Gradient Boosting (XGBoost) merupakan algoritma ensemble berbasis pohon keputusan yang bekerja dengan prinsip *boosting*. Berbeda dengan Random Forest yang membangun banyak pohon secara relatif independen, XGBoost membangun pohon secara bertahap dengan memperbaiki kesalahan dari model sebelumnya. Pendekatan ini memungkinkan XGBoost menangkap pola yang kompleks pada data tabular.

XGBoost banyak digunakan karena memiliki mekanisme regularisasi, mampu menangani hubungan nonlinear, dan menunjukkan performa kompetitif pada berbagai masalah klasifikasi. Dalam penelitian ini, XGBoost digunakan sebagai salah satu model ensemble untuk

dibandingkan dengan Random Forest, LSTM, dan GRU. (Rajagukguk et al., 2025) membandingkan XGBoost, Random Forest, dan Logistic Regression untuk klasifikasi ISPU Jakarta. (Sajiwo et al., 2024) juga menggunakan XGBoost untuk klasifikasi ISPU DKI Jakarta dengan pendekatan penanganan data tidak seimbang. Kedua penelitian tersebut memperkuat relevansi XGBoost dalam studi klasifikasi kualitas udara Jakarta.

2.1.9. *Deep Learning*

Deep learning merupakan pendekatan pembelajaran mesin yang menggunakan jaringan saraf berlapis untuk mempelajari pola data yang kompleks. Berbeda dengan model pembelajaran mesin konvensional yang umumnya bekerja pada data tabular secara langsung, model *deep learning* dapat dirancang untuk membaca struktur data tertentu, termasuk data berurutan.

Dalam penelitian ini, model *deep learning* yang digunakan adalah Long Short-Term Memory (LSTM) dan Gated Recurrent Unit (GRU). Keduanya dipilih karena mampu membaca pola urutan waktu dari data harian. Namun, pemakaian LSTM dan GRU pada penelitian ini tetap diarahkan untuk klasifikasi status ISPU, bukan untuk memprediksi nilai numerik ISPU. Data empat belas hari sebelumnya digunakan sebagai masukan untuk mengklasifikasikan kelas status pada hari target berikutnya dengan skema X[i-window:i] → y[i].

(Jalali et al., 2025) menunjukkan bahwa pendekatan berbasis kecerdasan buatan dapat digunakan dalam aplikasi kualitas udara, termasuk klasifikasi dan model berbasis pembelajaran mendalam. Sementara itu, (Radjabaycolle et al., 2025) menggunakan LSTM dan SHAP pada studi kualitas udara Jakarta. Literatur tersebut menjadi dasar bahwa model sekuensial dapat digunakan dalam kajian kualitas udara, meskipun penelitian ini tetap membatasi keluaran model pada kelas Tidak Sehat+ dan Bukan Tidak Sehat+.

2.1.10. Long Short-Term Memory

Long Short-Term Memory atau LSTM merupakan salah satu jenis jaringan saraf berulang yang dirancang untuk menangani data berurutan. LSTM memiliki mekanisme gerbang yang membantu model menyimpan, melupakan, dan memperbarui informasi dari urutan data

sebelumnya. Mekanisme tersebut membuat LSTM sering digunakan pada data yang memiliki pola temporal.

Dalam penelitian ini, LSTM digunakan untuk membaca urutan data ISPU harian melalui pendekatan *sliding window* 14 hari. Artinya, data empat belas hari sebelumnya menjadi masukan untuk mengklasifikasikan status kualitas udara pada hari target berikutnya dengan skema X[i-window:i] → y[i]. Dengan cara ini, LSTM tidak hanya membaca kondisi polutan pada satu hari, tetapi juga pola historis jangka pendek yang mendahului status tersebut.

Meskipun LSTM sering ditemukan dalam penelitian peramalan deret waktu, penggunaan LSTM pada penelitian ini diposisikan sebagai model klasifikasi sekuensial. Oleh karena itu, pembahasan LSTM pada penelitian ini tidak diarahkan pada prediksi nilai ISPU, melainkan pada kemampuan model membaca pola urutan waktu untuk membedakan status Tidak Sehat+ dan Bukan Tidak Sehat+.

2.1.11. Gated Recurrent Unit

Gated Recurrent Unit atau GRU merupakan varian jaringan saraf berulang yang juga dirancang untuk data berurutan. GRU memiliki struktur gerbang yang lebih sederhana dibandingkan LSTM, sehingga secara umum dapat menjadi alternatif model sekuensial yang lebih ringan. Walaupun lebih sederhana, GRU tetap mampu mempertahankan informasi penting dari urutan data sebelumnya.

Dalam penelitian ini, GRU digunakan dengan pendekatan yang sama seperti LSTM, yaitu menggunakan *sliding window* 14 hari. Tujuan penggunaan GRU adalah membandingkan kemampuan model sekuensial yang lebih sederhana dengan LSTM serta model ensemble berbasis data tabular. Dengan demikian, perbandingan model mencakup dua kelompok utama, yaitu model ensemble dan model pembelajaran mendalam berbasis urutan waktu.

2.1.12. *Sliding Window*

Sliding window adalah teknik pembentukan data masukan dengan mengambil sejumlah observasi historis sebagai satu jendela *input*. Pada data harian, pendekatan ini memungkinkan

model membaca informasi dari beberapa hari sebelumnya untuk mengklasifikasikan kondisi pada hari target berikutnya. Teknik ini relevan untuk LSTM dan GRU karena kedua model tersebut membutuhkan data berbentuk urutan.

Dalam penelitian ini, ukuran jendela yang digunakan adalah 14 hari. Dengan demikian, data empat belas hari sebelumnya digunakan sebagai masukan untuk mengklasifikasikan status ISPU pada hari target berikutnya dengan skema X[i-window:i] → y[i]. Pemilihan jendela ini bertujuan memberi konteks historis jangka pendek kepada model tanpa mengubah arah penelitian menjadi peramalan nilai ISPU. *Output* yang diprediksi tetap berupa kelas biner, yaitu Tidak Sehat+ atau Bukan Tidak Sehat+.

2.1.13. Data Preprocessing

Data preprocessing merupakan tahap penyiapan data sebelum model dilatih dan dievaluasi. Pada penelitian berbasis data sekunder, preprocessing mencakup seleksi periode, pembersihan kategori yang tidak valid, pembentukan target penelitian, penanganan *missing values*, imputasi, *scaling*, dan *feature engineering*. Tahap ini diperlukan agar data yang masuk ke model sesuai dengan tujuan analisis dan tidak memuat informasi yang dapat menimbulkan bias evaluasi.

Dalam konteks klasifikasi status ISPU, preprocessing juga mencakup pemisahan antara kolom yang digunakan sebagai fitur, kolom yang menjadi sumber target, dan kolom yang harus dikecualikan. Pemisahan tersebut penting agar model tidak menggunakan informasi yang secara langsung sudah merepresentasikan label target.

2.1.14. Missing Values dan Imputasi

Missing values adalah nilai yang tidak tersedia pada suatu kolom data. Nilai kosong dapat muncul karena gangguan pencatatan, keterbatasan alat pemantauan, perubahan sistem, atau faktor teknis lain. Jika tidak ditangani, *missing values* dapat mengganggu proses pelatihan model dan menurunkan kualitas interpretasi hasil.

Imputasi digunakan untuk mengisi nilai kosong dengan pendekatan tertentu. Pada data numerik, median dan interpolasi dapat digunakan sesuai karakter data dan kebutuhan analisis. Selain

mengisi nilai kosong, indikator *missing values* dapat dibentuk untuk menandai bahwa suatu nilai pada awalnya tidak tersedia. Indikator tersebut membantu model membedakan nilai observasi asli dan nilai yang berasal dari proses pengisian. Apabila suatu variabel memiliki *missing values* sangat besar, interpretasi terhadap variabel tersebut tetap perlu dibatasi.

$$\text{Persentase Missing} = (\text{Jumlah Missing} / \text{Jumlah Observasi}) \times 100\%$$

Rumus tersebut digunakan untuk membaca tabel *missing values* pada BAB IV. Persentase *missing values* membantu menunjukkan tingkat kelengkapan data pada setiap parameter polutan, sehingga pembaca dapat memahami kualitas data sebelum dan sesudah imputasi.

2.1.15. Scaling dan Standardisasi

Scaling atau standardisasi adalah proses menyamakan skala fitur numerik agar berada pada rentang atau distribusi yang lebih sebanding. Salah satu bentuk standardisasi yang umum digunakan adalah z-score, yaitu mengurangi nilai fitur dengan rata-rata kemudian membaginya dengan simpangan baku. Proses ini penting terutama untuk model berbasis jaringan saraf seperti LSTM dan GRU karena model tersebut sensitif terhadap perbedaan skala antarf fitur. Sebaliknya, model berbasis pohon keputusan seperti Random Forest dan XGBoost relatif tidak terlalu sensitif terhadap skala fitur karena pemisahan data dilakukan berdasarkan aturan percabangan.

$$z = (x - \mu) / \sigma$$

Dalam rumus tersebut, μ menunjukkan rata-rata data latih, sedangkan σ menunjukkan simpangan baku data latih.

2.1.16. Evaluasi Model Klasifikasi

Evaluasi model diperlukan untuk menilai kemampuan model dalam membedakan kelas target. Karena penelitian ini merupakan klasifikasi biner, evaluasi dilakukan menggunakan Precision, Recall, F1-Score, dan Receiver Operating Characteristic-Area Under the Curve (ROC-AUC). Keempat metrik tersebut digunakan agar penilaian model tidak hanya bergantung pada jumlah

prediksi benar secara umum, tetapi juga memperhatikan kemampuan model dalam mengenali kelas Tidak Sehat+.

Precision mengukur proporsi prediksi positif yang benar-benar termasuk kelas positif. Dalam konteks penelitian ini, Precision menunjukkan seberapa banyak prediksi Tidak Sehat+ yang benar-benar merupakan hari Tidak Sehat+. Rumus Precision adalah Precision = TP / (TP + FP), dengan TP sebagai *true positive* dan FP sebagai *false positive*.

Recall mengukur proporsi kelas positif yang berhasil dikenali oleh model. Dalam konteks penelitian ini, Recall menunjukkan kemampuan model mendeteksi hari Tidak Sehat+ dari seluruh hari yang memang termasuk Tidak Sehat+. Rumus Recall adalah Recall = TP / (TP + FN), dengan FN sebagai *false negative*.

F1-Score merupakan rata-rata harmonis antara Precision dan Recall. Metrik ini berguna ketika penelitian perlu melihat keseimbangan antara ketepatan prediksi positif dan kemampuan mendeteksi kelas positif. Rumus F1-Score adalah F1-Score = 2 × (Precision × Recall) / (Precision + Recall). ROC-AUC mengukur kemampuan model membedakan kelas positif dan negatif pada berbagai ambang batas klasifikasi. Pada penelitian ini, ROC-AUC digunakan sebagai metrik tambahan untuk melihat kemampuan diskriminatif model terhadap status Tidak Sehat+ dan Bukan Tidak Sehat+.

Confusion matrix merupakan tabel yang memperlihatkan perbandingan antara kelas aktual dan kelas prediksi. Dalam konteks penelitian ini, true positive (TP) berarti hari Tidak Sehat+ diprediksi sebagai Tidak Sehat+, true negative (TN) berarti hari Bukan Tidak Sehat+ diprediksi sebagai Bukan Tidak Sehat+, false positive (FP) berarti hari Bukan Tidak Sehat+ diprediksi sebagai Tidak Sehat+, dan false negative (FN) berarti hari Tidak Sehat+ diprediksi sebagai Bukan Tidak Sehat+.

ROC curve menunjukkan kemampuan model memisahkan kelas positif dan kelas negatif pada berbagai threshold. *Precision-Recall curve* digunakan untuk membaca hubungan antara Precision dan Recall pada kelas positif, terutama ketika distribusi kelas tidak sepenuhnya

seimbang. Selain itu, distribusi kelas yang tidak seimbang dapat membuat model lebih condong mengenali kelas mayoritas. Pembobotan kelas digunakan agar kelas minoritas atau kelas positif tetap memperoleh perhatian selama proses pelatihan model. Dalam penelitian ini, kelas positif adalah Tidak Sehat+.

Secara operasional, ROC curve dibentuk dari pasangan True Positive Rate (TPR) dan False Positive Rate (FPR) pada berbagai threshold prediksi. TPR menunjukkan proporsi kelas positif yang berhasil dikenali, sedangkan FPR menunjukkan proporsi kelas negatif yang keliru diprediksi sebagai kelas positif.

$$TPR = TP / (TP + FN)$$

$$FPR = FP / (FP + TN)$$

ROC-AUC merupakan luas area di bawah ROC curve. Nilai ini digunakan untuk merangkum kemampuan diskriminasi model berdasarkan probabilitas prediksi kelas positif.

$$class_weight_i = n_samples / (n_classes \times n_i)$$

$$scale_pos_weight = \text{jumlah kelas negatif / jumlah kelas positif}$$

Pada rumus *class_weight* balanced, n_samples menunjukkan jumlah data latih, n_classes menunjukkan jumlah kelas, dan n_i menunjukkan jumlah observasi pada kelas ke-i. Sementara itu, *scale_pos_weight* digunakan pada XGBoost untuk memberi bobot lebih besar pada kelas positif ketika jumlah kelas positif lebih sedikit daripada kelas negatif. Dalam penelitian ini, pembobotan kelas digunakan agar model tetap memperhatikan kelas positif Tidak Sehat+ pada data yang tidak seimbang.

2.1.17. Target Leakage

Target leakage merupakan kondisi ketika fitur *input* mengandung informasi yang terlalu dekat dengan target sehingga model dapat memperoleh performa tinggi secara tidak wajar. Kondisi ini berbahaya karena model seolah-olah tampak akurat, padahal prediksi yang dihasilkan tidak mencerminkan kemampuan generalisasi yang sebenarnya.

Dalam penelitian ini, kolom max dan critical tidak digunakan sebagai fitur model karena kedua kolom tersebut sangat dekat dengan pembentukan kategori ISPU. Kolom max menunjukkan nilai parameter dominan, sedangkan critical berkaitan dengan parameter pencemar kritis yang menentukan status. Jika kedua kolom tersebut digunakan sebagai fitur, model berisiko mempelajari informasi yang secara langsung berkaitan dengan label target. Oleh karena itu, pencegahan *target leakage* dilakukan dengan hanya menggunakan parameter polutan utama, fitur waktu, indikator akhir pekan, indikator pasca-pandemi, dan indikator *missing values*.

Keputusan ini penting agar evaluasi model lebih dapat dipertanggungjawabkan. Model diharapkan mempelajari pola parameter dan konteks waktu, bukan memanfaatkan kolom yang secara langsung atau tidak langsung sudah memuat informasi target.

2.1.18. Explainable Artificial Intelligence dan SHAP

Explainable Artificial Intelligence atau XAI merupakan pendekatan yang bertujuan menjelaskan cara model menghasilkan prediksi. Dalam penelitian kualitas udara, interpretabilitas penting karena model tidak cukup hanya memberikan label prediksi, tetapi juga perlu menjelaskan fitur apa yang berkontribusi terhadap prediksi tersebut. (Agbehadji & Obagbuwa, 2025) menempatkan interpretabilitas model sebagai bagian penting dalam kajian risiko polusi udara dan kesehatan pernapasan.

SHAP atau *SHapley Additive exPlanations* merupakan salah satu metode interpretabilitas yang digunakan untuk mengukur kontribusi setiap fitur terhadap prediksi model. SHAP didasarkan pada konsep nilai Shapley, yaitu pendekatan yang menilai kontribusi suatu fitur dengan mempertimbangkan peran fitur tersebut dalam berbagai kombinasi fitur. Dengan demikian, SHAP dapat memberikan penjelasan baik pada tingkat lokal maupun *global*. Penjelasan lokal menunjukkan kontribusi fitur pada satu prediksi tertentu, sedangkan penjelasan *global* menunjukkan pola kontribusi fitur pada keseluruhan data.

Secara formal, nilai Shapley untuk fitur ke-j dapat dituliskan sebagai berikut.

$$\varphi_j = \Sigma_{S \subseteq F \setminus \{j\}} \left(|S|! \, (|F|-|S|-1)! \, / \, |F|! \right) \left[f(S \cup \{j\}) - f(S) \right]$$

Dalam rumus tersebut, F menyatakan himpunan seluruh fitur, S menyatakan subset fitur tanpa fitur ke-j, dan f menyatakan fungsi model. Pada penelitian ini, rumus tersebut digunakan sebagai dasar konsep SHAP, sedangkan perhitungan aktual dilakukan menggunakan pustaka SHAP di Python, bukan dihitung secara manual.

Mean absolute SHAP merupakan ringkasan kontribusi fitur yang diperoleh dengan menghitung rata-rata nilai absolut SHAP pada seluruh observasi. Rumus ringkasnya dituliskan sebagai berikut.

$$\text{Mean Absolute SHAP}_j = (1/n)\ \Sigma\ |\text{SHAP}_{ij}|$$

Dalam rumus tersebut, n menunjukkan jumlah observasi, sedangkan SHAP_ij menunjukkan nilai SHAP fitur ke-j pada observasi ke-i.

Nilai tersebut menunjukkan rata-rata kontribusi absolut fitur ke-j pada seluruh observasi. Nilai yang lebih besar menunjukkan kontribusi rata-rata fitur yang lebih besar terhadap keputusan model, bukan hubungan sebab-akibat.

SHAP value menunjukkan arah dan besar kontribusi suatu fitur pada satu observasi terhadap keputusan model. Nilai SHAP positif dapat mendorong prediksi ke arah kelas positif, sedangkan nilai negatif dapat mendorong prediksi ke arah kelas pembanding. (Yenkikar et al., 2025) menunjukkan penggunaan SHAP untuk membaca interpretabilitas indeks kualitas udara. Dalam penelitian ini, kelas positif adalah Tidak Sehat+.

Dalam penelitian ini, SHAP digunakan pada model berbasis ensemble yang dipilih setelah evaluasi model untuk menginterpretasikan kontribusi fitur polutan dan fitur waktu terhadap prediksi status Tidak Sehat+. Pemakaian SHAP tidak dimaksudkan untuk menggantikan evaluasi model, melainkan melengkapi evaluasi performa dengan penjelasan kontribusi fitur yang lebih mudah dipahami.

2.1.19. Kerangka Konseptual Penelitian

Berdasarkan teori yang telah dijelaskan, penelitian ini menempatkan data ISPU DKI Jakarta sebagai data lingkungan harian yang dapat dianalisis menggunakan pendekatan klasifikasi.

Fitur polutan utama dan fitur waktu digunakan untuk membentuk representasi data, sedangkan target biner Tidak Sehat+ dan Bukan Tidak Sehat+ digunakan untuk mengarahkan model pada kemampuan mengenali status kualitas udara yang lebih berisiko.

Model Random Forest dan Extreme Gradient Boosting (XGBoost) mewakili pendekatan ensemble learning pada data tabular, sedangkan LSTM dan GRU mewakili pendekatan deep learning pada data berurutan. Evaluasi model menggunakan Precision, Recall, F1-Score, dan ROC-AUC agar performa klasifikasi dapat dinilai secara terukur. Setelah model dievaluasi, SHAP digunakan pada model berbasis ensemble yang dipilih setelah evaluasi model untuk menjelaskan kontribusi fitur. Dengan alur tersebut, penelitian ini memiliki dua keluaran utama, yaitu perbandingan performa model dan interpretasi kontribusi fitur terhadap status Tidak Sehat+.

Tabel dan visualisasi pada BAB IV merupakan hasil penerapan alur metodologi pada BAB III. Dengan demikian, distribusi kategori, target biner, pemeriksaan missing values, evaluasi model, dan interpretasi SHAP pada BAB IV dibaca sebagai keluaran empiris dari proses pengolahan data dan eksperimen yang dijelaskan sebelumnya.

2.2. Penelitian Terkait

Kajian terdahulu digunakan untuk menunjukkan posisi penelitian ini terhadap studi sebelumnya. Literatur yang dipilih berfokus pada klasifikasi ISPU atau AQI, kualitas udara Jakarta atau kota besar, penggunaan model Random Forest, XGBoost, LSTM, GRU, serta interpretabilitas model menggunakan SHAP atau XAI. Dengan demikian, pembahasan penelitian terdahulu tetap berada dalam ruang lingkup penelitian dan tidak melebar ke prediksi nilai ISPU secara regresi.

(Hasna et al., 2024) menerapkan Random Forest untuk klasifikasi ISPU DKI Jakarta tahun 2022. Penelitian tersebut relevan karena menggunakan objek ISPU DKI Jakarta dan model Random Forest. Namun, penelitian ini berbeda karena membandingkan empat model,

yaitu Random Forest, XGBoost, LSTM, dan GRU, dengan target klasifikasi biner Tidak Sehat+ dan Bukan Tidak Sehat+ pada periode 2020-2024.

(Banjarnahor et al., 2025) membandingkan Support Vector Machine dan Random Forest untuk prediksi kategori indeks kualitas udara Jakarta dengan parameter PM10, PM2.5, SO2, CO, O3, dan NO2. Penelitian tersebut relevan karena memiliki kedekatan objek dan parameter dengan penelitian ini. Perbedaannya, penelitian ini tidak menggunakan SVM dan tidak berfokus pada kategori multikelas, tetapi membentuk target biner agar model diarahkan pada pengenalan kondisi Tidak Sehat+.

(Radjabaycolle et al., 2025) menggunakan LSTM dan SHAP dalam studi kualitas udara Jakarta. Penelitian tersebut relevan karena menunjukkan pemanfaatan model sekuensial dan interpretabilitas pada konteks kualitas udara Jakarta. Namun, penelitian ini memperluas pembandingan dengan memasukkan Random Forest, XGBoost, LSTM, dan GRU dalam satu kerangka eksperimen, serta membatasi SHAP pada model berbasis ensemble yang dipilih setelah evaluasi model untuk interpretasi kontribusi fitur.

(Rajagukguk et al., 2025) membandingkan XGBoost, Random Forest, dan Logistic Regression untuk klasifikasi ISPU Jakarta. Kajian tersebut memiliki kedekatan langsung dengan penelitian ini karena sama-sama membahas ISPU Jakarta dan menggunakan model ensemble. Perbedaannya, penelitian ini tidak memasukkan Logistic Regression, tetapi menambahkan LSTM dan GRU sebagai model pembelajaran mendalam berbasis urutan waktu.

(Sajiwo et al., 2024) membahas klasifikasi ISPU DKI Jakarta menggunakan XGBoost dengan teknik SMOTE untuk menangani data tidak seimbang. Kajian tersebut relevan karena menggunakan XGBoost dan objek ISPU DKI Jakarta. Namun, penelitian ini tidak memosisikan SMOTE sebagai fokus utama, melainkan membandingkan model ensemble dan pembelajaran mendalam dengan pembagian data kronologis.

(Fahim et al., 2025) meneliti klasifikasi Air Quality Index menggunakan teknik ensemble *machine learning*. Kajian tersebut relevan untuk memperkuat penggunaan model

ensemble dan metrik evaluasi klasifikasi seperti F1-Score serta ROC-AUC. Perbedaannya, penelitian ini berfokus pada ISPU DKI Jakarta dengan target biner Tidak Sehat+ dan Bukan Tidak Sehat+.

(Liu et al., 2024) membahas klasifikasi kelas kualitas udara menggunakan metode *machine learning* berdasarkan data pemantauan. Studi tersebut mendukung konsep bahwa kualitas udara dapat dimodelkan sebagai masalah klasifikasi kelas. Dalam penelitian ini, konsep tersebut diterapkan pada data ISPU DKI Jakarta dengan fokus pada pemisahan kelas Tidak Sehat+ dan Bukan Tidak Sehat+.

(Jalali et al., 2025) membahas aplikasi kecerdasan buatan untuk kualitas udara, termasuk klasifikasi dan penggunaan pendekatan XAI. Literatur ini relevan sebagai penguat bahwa model pembelajaran mesin, pembelajaran mendalam, dan interpretabilitas dapat dikombinasikan dalam studi kualitas udara. Namun, penelitian ini tetap menjaga ruang lingkup pada klasifikasi status ISPU, bukan peramalan nilai numerik kualitas udara.

(Yenkikar et al., 2025) membahas pemanfaatan SHAP untuk interpretabilitas prediksi indeks kualitas udara. Penelitian tersebut mendukung penggunaan SHAP sebagai metode untuk membaca kontribusi fitur terhadap keluaran model. Dalam penelitian ini, SHAP digunakan untuk menjelaskan kontribusi parameter polutan dan fitur waktu terhadap prediksi status Tidak Sehat+.

(Agbehadji & Obagbuwa, 2025) melakukan tinjauan sistematis mengenai Explainable Artificial Intelligence dan *machine learning* dalam kajian risiko polusi udara serta kesehatan pernapasan. Kajian tersebut menempatkan interpretabilitas model sebagai bagian penting dalam analisis polusi udara. Pada penelitian ini, konsep tersebut diterapkan melalui SHAP agar model klasifikasi tidak hanya dievaluasi performanya, tetapi juga dijelaskan kontribusi fiturnya.

(Karmoude et al., 2025) meninjau penggunaan *machine learning* dalam kajian kualitas udara. Literatur ini digunakan untuk memperkuat landasan umum bahwa metode komputasional memiliki peran penting dalam analisis kualitas udara. Namun, penelitian ini

tetap memiliki fokus yang lebih spesifik, yaitu membandingkan Random Forest, XGBoost, LSTM, dan GRU untuk klasifikasi status ISPU DKI Jakarta.

Tabel II. 3 Penelitian Terkait

Penelitian Terkait	Fokus, Metode, Relevansi, dan Pembeda
1. (Hasna et al., 2024)	Membahas klasifikasi ISPU DKI Jakarta tahun 2022 menggunakan Random Forest. Relevan karena objek dan modelnya dekat dengan penelitian ini, sedangkan penelitian ini memperluas pembandingan dengan XGBoost, LSTM, dan GRU pada target biner Tidak Sehat+.
2. (Banjarnahor et al., 2025)	Membahas kategori kualitas udara Jakarta menggunakan SVM dan Random Forest dengan parameter PM10, PM2.5, SO2, CO, O3, dan NO2. Relevan dari sisi objek Jakarta dan parameter polutan, tetapi penelitian ini tidak memakai SVM dan tidak diarahkan pada multikelas.
3. (Radjabaycolle et al., 2025)	Membahas studi kualitas udara Jakarta dengan LSTM dan SHAP. Relevan untuk model sekuensial dan interpretabilitas, sedangkan penelitian ini menambahkan komparasi ensemble dan GRU serta memakai SHAP pada model berbasis ensemble yang dipilih setelah evaluasi model.
4. (Rajagukguk et al., 2025)	Membandingkan XGBoost, Random Forest, dan *Logistic Regression* untuk klasifikasi ISPU Jakarta. Sangat dekat karena membahas ISPU Jakarta, RF, dan XGBoost. Penelitian ini tidak memakai *Logistic Regression*, tetapi menambahkan LSTM dan GRU.
5. (Sajiwo et al., 2024)	Membahas klasifikasi ISPU DKI Jakarta menggunakan XGBoost dan SMOTE. Relevan untuk XGBoost dan ISPU DKI Jakarta, tetapi penelitian ini tidak memusatkan pembahasan pada SMOTE, melainkan pada komparasi model dengan pembagian data kronologis.
6. (Fahim et al., 2025)	Membahas klasifikasi AQI berbasis ensemble *machine learning*. Relevan untuk mendukung penggunaan ensemble dan metrik klasifikasi seperti F1-Score serta ROC-AUC, sedangkan penelitian ini memakai data ISPU DKI Jakarta dengan target biner.
7. (Klosterman, 2021)	Membahas klasifikasi kelas kualitas udara menggunakan machine learning berdasarkan data pemantauan. Relevan untuk memperkuat konsep kualitas udara sebagai masalah klasifikasi kelas yang dalam penelitian ini dioperasionalkan sebagai Tidak Sehat+ dan Bukan Tidak Sehat+.

Penelitian Terkait	Fokus, Metode, Relevansi, dan Pembeda
8. (Bhattacharya, 2022)	Membahas sistem AI untuk kualitas udara, termasuk klasifikasi, *deep learning*, dan XAI. Relevan sebagai penghubung ML, DL, dan interpretabilitas, tetapi penelitian ini membatasi keluaran pada klasifikasi status, bukan *forecasting* nilai.
9. (VASILEV, 2023)	Membahas interpretabilitas indeks kualitas udara menggunakan Random Forest, ARIMA, dan SHAP. Relevan untuk mendukung pemakaian SHAP dalam menjelaskan kontribusi fitur, sedangkan penelitian ini menerapkannya pada model berbasis ensemble yang dipilih setelah evaluasi model dalam klasifikasi ISPU.
10. (Awasthi et al., 2025)	Menyajikan tinjauan sistematis XAI dan ML untuk polusi udara dan risiko kesehatan. Relevan untuk menguatkan pentingnya interpretabilitas model polusi udara, sedangkan penelitian ini menerapkan SHAP secara spesifik pada data ISPU DKI Jakarta.
11.(Thampi, 2022)	Meninjau perkembangan ML untuk prediksi dan analisis kualitas udara. Relevan sebagai dasar umum penggunaan ML/DL pada kualitas udara, sedangkan penelitian ini lebih spesifik pada ISPU DKI Jakarta dan target Tidak Sehat+.

Sumber: Diolah oleh penulis (2026)

Berdasarkan penelitian terkait tersebut, dapat disimpulkan bahwa studi mengenai kualitas udara telah banyak menggunakan Random Forest, XGBoost, LSTM, dan SHAP. Namun, masih terdapat ruang penelitian untuk membandingkan model ensemble dan pembelajaran mendalam dalam satu kerangka eksperimen yang sama pada data ISPU DKI Jakarta periode 2020-2024. Selain itu, belum banyak penelitian yang secara khusus membentuk target biner Tidak Sehat+ dan Bukan Tidak Sehat+ dengan pembagian data kronologis serta interpretabilitas SHAP pada model berbasis ensemble yang dipilih setelah evaluasi model. Oleh karena itu, penelitian ini ditempatkan sebagai kajian komparatif yang menggabungkan performa klasifikasi dan interpretabilitas fitur pada konteks ISPU DKI Jakarta.

2.3. Tinjauan Organisasi/Objek Penelitian

Objek penelitian ini adalah data Indeks Standar Pencemar Udara DKI Jakarta. Data tersebut merepresentasikan kondisi kualitas udara harian berdasarkan parameter pencemar yang dipantau di wilayah DKI Jakarta. Karena penelitian ini menggunakan data sekunder, pembahasan objek penelitian tidak diarahkan pada struktur organisasi internal instansi, melainkan pada sumber data, karakteristik data, parameter yang digunakan, dan batasan objek yang dianalisis.

2.3.1. DKI Jakarta sebagai Wilayah Kajian Kualitas Udara

DKI Jakarta merupakan wilayah metropolitan dengan aktivitas transportasi, perkantoran, permukiman padat, dan mobilitas masyarakat yang tinggi. Karakter tersebut membuat kualitas udara di Jakarta menjadi isu penting dalam kajian lingkungan perkotaan. Pemantauan kualitas udara menjadi diperlukan karena perubahan aktivitas masyarakat dapat memengaruhi konsentrasi pencemar udara.

Periode 2020-2024 dipilih karena mencakup fase pandemi, transisi, dan pasca-pandemi. Tahun 2020-2021 berkaitan dengan pembatasan mobilitas masyarakat, sedangkan tahun 2022-2024 berkaitan dengan pemulihan aktivitas perkotaan dan normalisasi mobilitas. Periode tersebut

memberikan konteks temporal yang relevan untuk mempelajari status kualitas udara DKI Jakarta dalam kondisi sosial yang berubah.

2.3.2. Sumber Data ISPU DKI Jakarta

Data yang digunakan dalam penelitian ini merupakan data sekunder ISPU DKI Jakarta yang bersumber dari Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui portal Satu Data Jakarta dan diakses dalam bentuk dataset terstruktur melalui Kaggle. Portal data pemerintah menjelaskan bahwa data ISPU DKI Jakarta diperoleh dari pengukuran Stasiun Pemantau Kualitas Udara di Provinsi DKI Jakarta (Pemerintah Provinsi DKI Jakarta, 2025).

Pemanfaatan Kaggle dalam penelitian ini diposisikan sebagai media akses terhadap dataset terstruktur, bukan sebagai produsen utama data. Sumber substantif data tetap merujuk pada Dinas Lingkungan Hidup Provinsi DKI Jakarta dan Satu Data Jakarta. Hal ini penting agar sumber data penelitian dijelaskan secara transparan dan tidak menimbulkan kesan bahwa data berasal dari hasil pengukuran mandiri peneliti.

2.3.3. Karakteristik Data Penelitian

Dataset awal yang diperiksa mencakup rentang 1 Januari 2010 sampai 28 Februari 2025. Namun, penelitian ini membatasi periode analisis pada 1 Januari 2020 sampai 31 Desember 2024. Data tahun 2010-2019 tidak digunakan karena berada di luar fokus pandemi, transisi, dan pasca-pandemi. Data tahun 2025 juga tidak digunakan karena belum mencakup satu tahun penuh.

Setelah pemotongan periode 2020-2024 dan pengeluaran kategori TIDAK ADA DATA, data pemodelan yang digunakan berjumlah 1.826 hari valid. Kategori TIDAK ADA DATA dikeluarkan karena bukan merupakan status mutu udara yang dapat dimasukkan ke dalam target klasifikasi. Dengan demikian, data yang digunakan dalam pemodelan hanya mencakup hari-hari yang memiliki status kualitas udara yang dapat dipetakan ke dalam kelas Tidak Sehat+ atau Bukan Tidak Sehat+.

2.3.4. Variabel Penelitian

Variabel utama dalam penelitian ini terdiri dari parameter polutan PM2.5, PM10, SO2, CO, O3, dan NO2. Keenam parameter tersebut digunakan sebagai fitur utama karena menjadi indikator pencemar udara yang tersedia pada dataset. Selain itu, penelitian ini menggunakan fitur pendukung berupa tahun, bulan, hari dalam minggu, indikator akhir pekan, indikator pasca-pandemi, dan indikator *missing values*.

Indikator akhir pekan digunakan untuk memberi informasi apakah suatu observasi terjadi pada hari kerja atau akhir pekan. Indikator pasca-pandemi digunakan untuk memberikan konteks periode setelah fase pembatasan mobilitas. Indikator *missing values* digunakan agar proses imputasi tetap memiliki jejak dalam data, sehingga model tidak sepenuhnya mengabaikan informasi bahwa suatu nilai sebelumnya kosong dan telah diisi melalui metode imputasi.

Kolom max dan critical tidak digunakan sebagai fitur model. Keputusan ini dilakukan untuk mencegah *target leakage* karena kedua kolom tersebut memiliki hubungan yang sangat dekat dengan pembentukan kategori ISPU. Dengan tidak menggunakan kedua kolom tersebut, model diharapkan mempelajari pola dari parameter polutan dan fitur waktu, bukan dari informasi yang terlalu dekat dengan label target.

2.3.5. Target Klasifikasi

Target penelitian ini adalah status klasifikasi biner yang terdiri dari Tidak Sehat+ dan Bukan Tidak Sehat+. Kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT dikelompokkan sebagai Tidak Sehat+, sedangkan kategori BAIK dan SEDANG dikelompokkan sebagai Bukan Tidak Sehat+. Pengelompokan ini dilakukan agar model fokus mengenali kondisi kualitas udara yang lebih berisiko terhadap kesehatan masyarakat.

Pembentukan target biner juga membantu penelitian menjadi lebih operasional. Alih-alih hanya memprediksi kategori kualitas udara secara umum, model diarahkan untuk menjawab apakah suatu hari termasuk dalam kondisi Tidak Sehat+ atau tidak. Dengan demikian, keluaran model memiliki makna yang lebih langsung dalam konteks kewaspadaan kualitas udara.

2.3.6. Posisi Objek Penelitian terhadap Metode

Objek penelitian berupa data ISPU DKI Jakarta memiliki karakter tabular dan temporal. Karakter tabular terlihat dari parameter polutan dan fitur waktu yang tersusun dalam kolom-kolom terstruktur. Karakter temporal terlihat dari urutan tanggal yang membentuk observasi harian. Oleh karena itu, penelitian ini membandingkan dua pendekatan model, yaitu model ensemble untuk data tabular dan model pembelajaran mendalam untuk data berurutan.

Random Forest dan XGBoost digunakan untuk membaca hubungan antarfitur pada data tabular. LSTM dan GRU digunakan untuk membaca pola urutan waktu dengan pendekatan *sliding window* 14 hari. Evaluasi dilakukan menggunakan Precision, Recall, F1-Score, dan ROC-AUC. Setelah model dievaluasi, SHAP digunakan pada model berbasis ensemble yang dipilih setelah evaluasi model untuk menjelaskan kontribusi fitur terhadap prediksi status Tidak Sehat+.

Dengan demikian, objek penelitian, metode pemodelan, dan evaluasi yang digunakan membentuk alur metodologis yang konsisten. Data ISPU DKI Jakarta menyediakan parameter polutan dan fitur waktu; model klasifikasi digunakan untuk membedakan status Tidak Sehat+ dan Bukan Tidak Sehat+; metrik klasifikasi digunakan untuk menilai performa; dan SHAP digunakan untuk menjelaskan kontribusi fitur yang membentuk keputusan model.

BAB III

METODOLOGI PENELITIAN

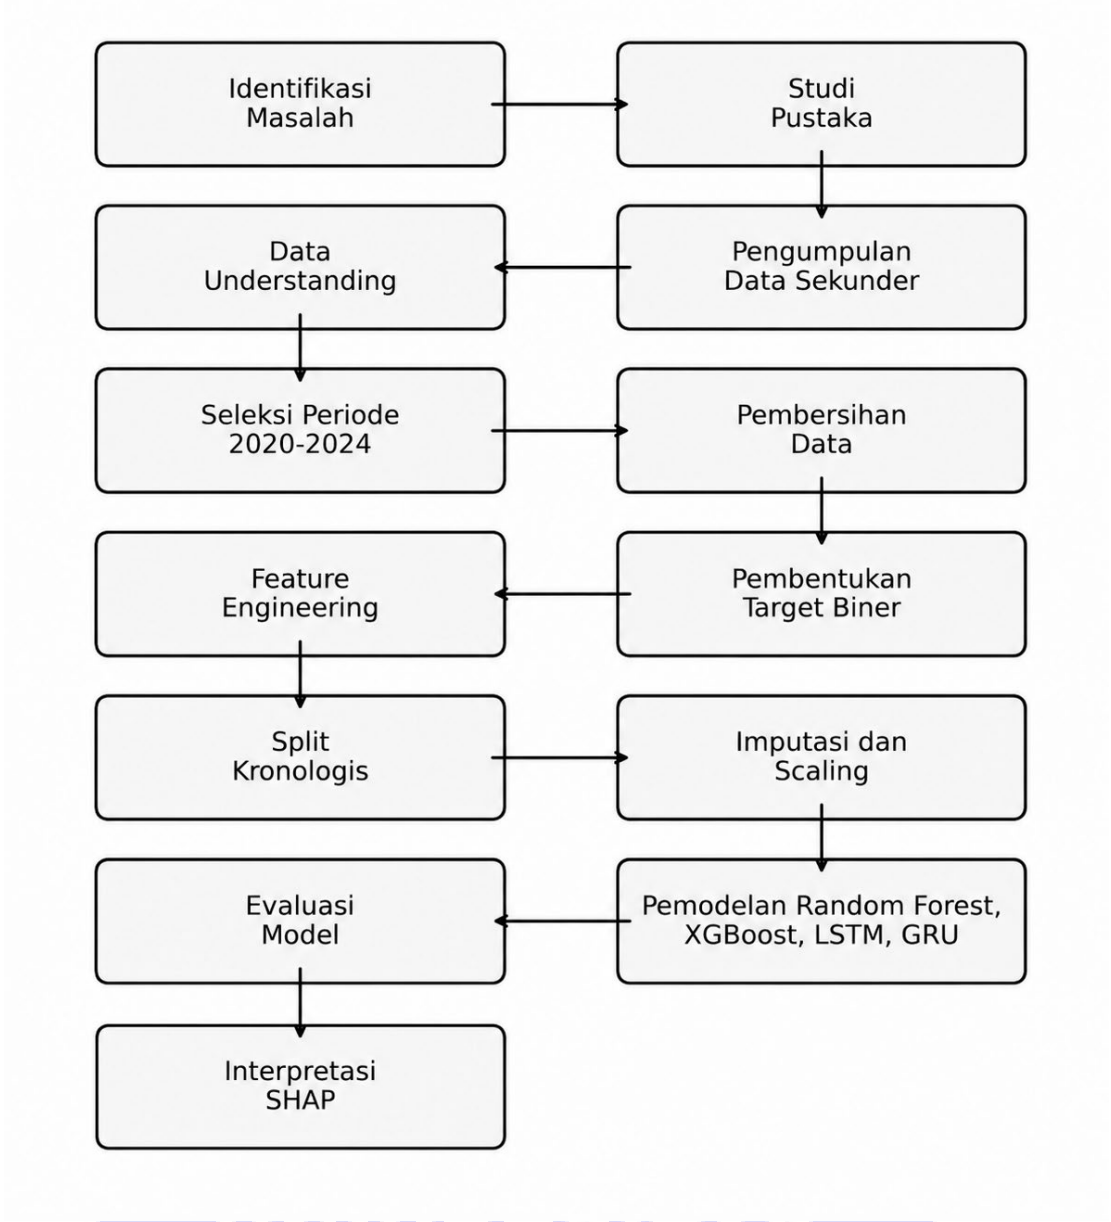
Bab ini menjelaskan proses penelitian yang dilakukan untuk mengklasifikasikan status Indeks Standar Pencemar Udara (ISPU) DKI Jakarta. Metodologi disusun sebagai alur kerja eksperimen komputasional, mulai dari pengumpulan data sekunder, pemahaman data, pengolahan fitur, pembentukan target, pembagian data, pemodelan, evaluasi, sampai penyiapan *output* untuk BAB IV.

Dataset awal yang digunakan terdiri dari 5.538 baris dan 11 kolom dengan rentang tanggal 1 Januari 2010 sampai 28 Februari 2025. Penelitian membatasi data pada periode 1 Januari 2020 sampai 31 Desember 2024. Setelah seleksi periode, data berjumlah 1.827 observasi. Satu baris dengan kategori TIDAK ADA DATA dikeluarkan, sehingga data pemodelan final berjumlah 1.826 observasi harian.

3.1. Tahapan Penelitian

Tahapan penelitian dirancang agar setiap keputusan teknis dapat ditelusuri dari data mentah sampai *output* analisis. Alur penelitian disajikan dalam bentuk gambar agar tahapan penelitian dapat dibaca sebagai proses yang berurutan, mulai dari pengumpulan data hingga penyiapan *output* untuk BAB IV.

Model yang digunakan dalam alur penelitian adalah Random Forest, Extreme Gradient Boosting (XGBoost), Long Short-Term Memory (LSTM), dan Gated Recurrent Unit (GRU). Interpretasi model dilakukan dengan SHapley Additive exPlanations (SHAP).



Gambar III. 1 Alur Tahapan Penelitian

Sumber: Diadaptasi dari kerangka penelitian kualitas udara Jakarta berbasis LSTM-SHAP (Radjabaycolle et al., 2025), diolah oleh penulis (2026).

Tahap identifikasi masalah diarahkan pada kebutuhan membandingkan kinerja model klasifikasi status ISPU DKI Jakarta dan membaca kontribusi fitur melalui SHAP. Tahap ini menghasilkan batasan bahwa penelitian tidak memprediksi nilai ISPU numerik, melainkan mengklasifikasikan status harian menjadi Tidak Sehat+ dan Bukan Tidak Sehat+.

Studi pustaka digunakan untuk menetapkan dasar konseptual mengenai ISPU, parameter polutan, klasifikasi, model ensemble, model *deep learning* berbasis

TensorFlow/Keras, evaluasi klasifikasi, serta SHAP. Hasil tahap ini menjadi dasar pemilihan Random Forest, XGBoost, LSTM, GRU, metrik Precision, Recall, F1-Score, ROC-AUC, dan interpretasi mean absolute SHAP.

Pengumpulan data sekunder dilakukan menggunakan dataset ispu_dki_all.csv. Dataset awal berisi 5.538 baris dan 11 kolom pada rentang 1 Januari 2010 sampai 28 Februari 2025. Pada tahap *data understanding*, *notebook* memeriksa nama kolom, tipe data, rentang tanggal, jumlah stasiun, distribusi kategori ISPU asli, serta *missing values* awal. Pemeriksaan tersebut menunjukkan bahwa dataset memuat lima stasiun pemantauan dan sebelas kolom utama, yaitu tanggal, stasiun, PM2.5, PM10, SO2, CO, O3, NO2, max, critical, dan categori.

Seleksi periode dilakukan dengan membatasi data pada 1 Januari 2020 sampai 31 Desember 2024 sehingga jumlah data menjadi 1.827 observasi. Periode 2020-2021 merepresentasikan fase pandemi dan pembatasan aktivitas, sedangkan 2022-2024 merepresentasikan fase transisi dan pasca-pandemi. Data tahun 2025 tidak digunakan karena belum mencakup satu tahun penuh, sementara data 2010-2019 berada di luar fokus periode penelitian. Satu baris berkategori TIDAK ADA DATA dikeluarkan karena tidak dapat dipetakan ke kelas target, sehingga data final untuk pemodelan berjumlah 1.826 observasi harian.

Pembentukan target biner dilakukan dari kolom categori. Kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT dipetakan menjadi Tidak Sehat+, sedangkan BAIK dan SEDANG dipetakan menjadi Bukan Tidak Sehat+. Hasilnya adalah 616 hari Tidak Sehat+ dan 1.210 hari Bukan Tidak Sehat+. Setelah itu, *feature engineering* membentuk 17 fitur final yang terdiri dari enam polutan, fitur waktu, indikator akhir pekan, indikator pasca-pandemi, dan indikator *missing values*. Kolom max, critical, categori, target_tidak_sehat, target_label, dan stasiun tidak digunakan sebagai fitur model.

Split data dilakukan secara kronologis. Data 2020-2023 digunakan sebagai data latih sebanyak 1.460 observasi, sedangkan data 2024 digunakan sebagai data uji sebanyak 366

observasi. Imputasi dilakukan setelah split dengan parameter dari data latih, kemudian *scaling* diterapkan untuk kebutuhan model. PM2.5 pada tahun 2020 memiliki 366 nilai kosong dari 366 hari sehingga informasi ini dicatat sebagai batasan interpretasi. Untuk LSTM dan GRU, data dibentuk menjadi sekuens 14 hari sebelumnya dengan skema X[i-window:i] → y[i].

Pemodelan dilakukan menggunakan Random Forest, XGBoost, LSTM, dan GRU. Random Forest dan XGBoost menggunakan fitur tabular pada hari target, sedangkan LSTM dan GRU menggunakan konteks historis 14 hari sebelumnya. Evaluasi model dilakukan pada data uji dengan Precision, Recall, F1-Score, ROC-AUC, *confusion matrix*, *ROC curve*, dan *Precision-Recall curve*. BAB III hanya menjelaskan prosedur perhitungan, sedangkan hasil nilai evaluasi disajikan pada BAB IV.

Interpretasi SHAP dihitung pada model berbasis ensemble yang dipilih setelah proses evaluasi. SHAP pada data uji 2024 digunakan untuk membaca kontribusi fitur pada periode evaluasi generalisasi, sedangkan SHAP historis 2020-2024 digunakan sebagai analisis diagnostik retrospektif untuk membaca pola kontribusi fitur sepanjang periode penelitian, bukan sebagai evaluasi generalisasi model. *Output* penelitian disiapkan dalam bentuk tabel, gambar, data hasil pengolahan, dan lampiran pendukung yang menjadi dasar penyajian BAB IV.

3.2. Instrumen Penelitian

Instrumen penelitian yang digunakan meliputi komputer atau laptop, lingkungan Google Colaboratory atau Jupyter *Notebook*, bahasa pemrograman Python, dataset ispu_dki_all.csv, dan *notebook* eksperimen *Notebook*_Eksperimen_ISPU.ipynb. Pengolahan data dilakukan dengan Pandas dan NumPy. Pemodelan Random Forest dilakukan dengan Scikit-learn, XGBoost dilakukan dengan pustaka XGBoost, sedangkan LSTM dan GRU dilakukan dengan TensorFlow/Keras. Visualisasi dibuat dengan Matplotlib dan Seaborn, sedangkan interpretabilitas model dilakukan dengan SHAP.

Notebook eksperimen digunakan untuk menjalankan proses penelitian secara berurutan, mulai dari pembacaan dataset sampai penyimpanan tabel dan gambar. *Output notebook* disimpan pada folder *output* yang berisi tabel berformat CSV dan gambar berformat PNG agar dapat digunakan kembali pada BAB IV.

3.3. Metode Pengumpulan Data, Populasi, dan Sampel Penelitian

Metode pengumpulan data yang digunakan adalah dokumentasi data sekunder. Data utama berupa dataset ISPU DKI Jakarta yang bersumber dari Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui portal Satu Data Jakarta dan diakses dalam bentuk dataset terstruktur melalui Kaggle. Dataset memuat kolom tanggal, stasiun, Particulate Matter 2.5 (PM2.5), Particulate Matter 10 (PM10), Sulfur Dioksida (SO2), Karbon Monoksida (CO), Ozon (O3), Nitrogen Dioksida (NO2), max, critical, dan categori.

Populasi penelitian adalah seluruh data harian pada dataset awal, yaitu 5.538 baris dan 11 kolom dengan rentang 1 Januari 2010 sampai 28 Februari 2025. Sampel penelitian adalah data periode 1 Januari 2020 sampai 31 Desember 2024 yang memenuhi kriteria kategori kualitas udara. Setelah filter periode, jumlah observasi menjadi 1.827 baris. Setelah kategori TIDAK ADA DATA dikeluarkan, data final untuk pemodelan menjadi 1.826 observasi.

Tabel III. 1 Kriteria Data Penelitian

No	Aspek	Keterangan
1	Populasi penelitian	Seluruh data harian ISPU DKI Jakarta pada dataset awal periode 1 Januari 2010 sampai 28 Februari 2025.
2	Jumlah data awal	5.538 baris dan 11 kolom.
3	Sampel/data penelitian	Data periode 1 Januari 2020 sampai 31 Desember 2024 setelah kategori TIDAK ADA DATA dikeluarkan.
4	Jumlah data periode penelitian	1.827 observasi sebelum pengeluaran TIDAK ADA DATA.
5	Jumlah data pemodelan final	1.826 observasi harian valid.
6	Kriteria inklusi	Data berada pada periode 2020-2024 dan memiliki kategori BAIK, SEDANG, TIDAK SEHAT, atau SANGAT TIDAK SEHAT.

No	Aspek	Keterangan
7	Kriteria eksklusi	Data tahun 2010-2019, data tahun 2025, dan satu baris kategori TIDAK ADA DATA.
8	Pembagian data	Data latih 1 Januari 2020 sampai 31 Desember 2023 sebanyak 1.460 observasi; data uji 1 Januari 2024 sampai 31 Desember 2024 sebanyak 366 observasi.

Sumber: Diolah oleh penulis (2026)

3.4. Metode Analisis Data

Metode analisis data dilakukan melalui tahapan operasional yang sama dengan *notebook* eksperimen. Tahapan tersebut mencakup pemahaman data, seleksi periode, pembersihan data, pembentukan target, pembentukan fitur, pencegahan *target leakage*, pembagian data kronologis, imputasi, *scaling*, pembentukan sequence, pemodelan, evaluasi, interpretasi SHAP, dan penyimpanan *output*. Hasil numerik akhir dari model tidak dibahas pada BAB III karena menjadi bagian dari BAB IV.

3.4.1. *Data Understanding*

Tahap *data understanding* dilakukan terhadap dataset awal berisi 5.538 baris dan 11 kolom. Rentang tanggal awal adalah 1 Januari 2010 sampai 28 Februari 2025, dengan 5 stasiun unik. Kolom yang diperiksa meliputi tanggal, stasiun, enam polutan, max, critical, dan categori.

Tabel III. 2 Daftar Kolom Dataset Awal dan Perannya dalam Penelitian

Kolom	Arti Kolom	Peran	Alasan
tanggal	Tanggal observasi harian	Sumber fitur waktu	Dipakai untuk urutan kronologis, seleksi periode, split data, dan pembentukan fitur waktu.
stasiun	Nama stasiun pemantauan	Dikecualikan	Penelitian memosisikan data sebagai deret harian ISPU DKI Jakarta, bukan perbandingan antarstasiun.
PM2.5	Particulate Matter 2.5	Fitur model	Parameter polutan utama.
PM10	Particulate Matter 10	Fitur model	Parameter polutan utama.
SO2	Sulfur Dioksida	Fitur model	Parameter polutan utama.
CO	Karbon Monoksida	Fitur model	Parameter polutan utama.
O3	Ozon	Fitur model	Parameter polutan utama.
NO2	Nitrogen Dioksida	Fitur model	Parameter polutan utama.
max	Nilai ISPU maksimum harian	Dikecualikan	Berisiko menyebabkan target leakage karena sangat dekat dengan penentuan kategori.
critical	Parameter dominan penentu ISPU	Dikecualikan	Berisiko menyebabkan target leakage karena memuat informasi parameter penentu kategori.
categori	Kategori ISPU asli	Sumber target	Dipakai untuk membentuk target biner, tetapi tidak menjadi fitur model.

Sumber: Diolah oleh penulis (2026)

Pada periode 2020-2024 sebelum kategori TIDAK ADA DATA dikeluarkan, distribusi kategori terdiri dari SEDANG 1.160 hari, TIDAK SEHAT 609 hari, BAIK 50 hari, SANGAT TIDAK SEHAT 7 hari, dan TIDAK ADA DATA 1 hari. Pemeriksaan ini digunakan untuk memastikan bahwa target biner dibentuk dari kategori yang valid.

3.4.2. Seleksi Periode dan Pembersihan Data

Seleksi periode dilakukan terhadap dataset awal yang terdiri dari 5.538 baris dan 11 kolom. Data dibatasi pada rentang 1 Januari 2020 sampai 31 Desember 2024 karena periode tersebut mencakup fase pandemi atau pembatasan aktivitas pada 2020-2021 serta fase transisi dan pasca-pandemi pada 2022-2024. Data 2025 tidak digunakan karena belum mencakup satu tahun penuh, sedangkan data 2010-2019 berada di luar fokus periode penelitian.

Setelah filter periode diterapkan pada *notebook*, jumlah observasi menjadi 1.827 baris. Satu baris berkategori TIDAK ADA DATA dikeluarkan karena tidak dapat dipetakan menjadi

kelas target yang valid. Dengan demikian, data final yang digunakan untuk pemodelan berjumlah 1.826 observasi harian.

3.4.3. Pembentukan Target Biner

Target penelitian dibentuk dari kolom categori. Kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT diberi label positif Tidak Sehat+, sedangkan kategori BAIK dan SEDANG diberi label Bukan Tidak Sehat+. Pada data pemodelan final, kelas Tidak Sehat+ berjumlah 616 hari (33,73%), sedangkan kelas Bukan Tidak Sehat+ berjumlah 1.210 hari (66,27%).

$$\text{Proporsi Kelas} = \text{Jumlah Observasi Kelas} / 1.826 \times 100\%$$

Berdasarkan rumus tersebut, kelas Tidak Sehat+ dihitung sebagai 616/1.826 × 100% = 33,73%, sedangkan kelas Bukan Tidak Sehat+ dihitung sebagai 1.210/1.826 × 100% = 66,27%. Perhitungan ini digunakan untuk menjelaskan komposisi target, bukan sebagai hasil performa model.

Dalam *notebook*, target numerik disimpan sebagai target_tidak_sehat, sedangkan label teks disimpan sebagai target_label. Kedua variabel ini hanya digunakan untuk kebutuhan pemodelan, evaluasi, tabel, dan visualisasi.

3.4.4. *Feature Engineering*

Fitur akhir yang digunakan berjumlah 17 fitur. Fitur tersebut terdiri dari enam polutan utama, yaitu PM2.5, PM10, SO2, CO, O3, dan NO2; fitur waktu yang terdiri dari Tahun, Bulan, Hari dalam Minggu, Indikator Akhir Pekan, dan Indikator Pasca-Pandemi; serta indikator *missing values* untuk masing-masing polutan. Daftar fitur final adalah PM2.5, PM10, SO2, CO, O3, NO2, Tahun, Bulan, Hari dalam Minggu, Indikator Akhir Pekan, Indikator Pasca-Pandemi, Indikator Missing PM2.5, Indikator Missing PM10, Indikator Missing SO2, Indikator Missing CO, Indikator Missing O3, Indikator Missing NO2.

Indikator Akhir Pekan bernilai 1 untuk Sabtu atau Minggu dan 0 untuk hari lain. Indikator Pasca-Pandemi bernilai 1 untuk tahun 2022-2024 dan 0 untuk tahun 2020-2021.

Indikator *missing values* dibentuk sebelum imputasi agar model tetap memiliki informasi bahwa nilai tertentu sebelumnya kosong.

Tabel III. 3 Daftar Fitur Final dan Variabel Target Penelitian

Kelompok	Variabel	Peran dalam Penelitian	Keterangan
Fitur polutan	PM2.5, PM10, SO2, CO, O3, NO2	Fitur model	Enam parameter polutan utama; bagian dari 17 fitur final.
Fitur waktu	Tahun, Bulan, Hari dalam Minggu, Indikator Akhir Pekan, Indikator Pasca-Pandemi	Fitur model	Lima fitur konteks waktu; bagian dari 17 fitur final.
Indikator missing values	Indikator Missing PM2.5, PM10, SO2, CO, O3, NO2	Fitur model	Enam indikator untuk menandai nilai yang awalnya kosong; bagian dari 17 fitur final.
Target/label	target_tidak_sehat	Target numerik	Bukan fitur model; bernilai 1 untuk Tidak Sehat+ dan 0 untuk Bukan Tidak Sehat+.
Target/label	target_label	Label teks/visualisasi	Bukan fitur model; digunakan untuk tabel, grafik, dan narasi hasil.

Sumber: Diolah oleh penulis (2026)

Tabel III.3 menegaskan bahwa fitur model berjumlah 17, yaitu enam fitur polutan, lima fitur waktu, dan enam indikator missing values. Variabel target_tidak_sehat dan target_label dicantumkan untuk menjelaskan keluaran penelitian, tetapi keduanya bukan fitur model.

3.4.5. Pencegahan *Target Leakage*

Kolom max dan critical tidak digunakan sebagai fitur model. Kolom max menunjukkan nilai indeks maksimum harian, sedangkan critical menunjukkan parameter pencemar yang menjadi penentu nilai tersebut. Karena keduanya terlalu dekat dengan pembentukan kategori ISPU, penggunaan kedua kolom tersebut sebagai fitur dapat menyebabkan *target leakage*.

Fitur model dibatasi pada polutan utama, fitur waktu, dan indikator *missing values*. Kolom categori, target_tidak_sehat, dan target_label juga tidak digunakan sebagai fitur karena berperan sebagai sumber target atau label pemodelan.

Kolom stasiun tidak digunakan sebagai fitur model karena penelitian memosisikan data sebagai deret harian ISPU DKI Jakarta berdasarkan struktur dataset yang dianalisis, bukan sebagai perbandingan antarstasiun pemantauan. Oleh karena itu, fitur model difokuskan pada parameter polutan, fitur waktu, dan indikator *missing values*.

3.4.6. Split Data Kronologis

Data dibagi secara kronologis berdasarkan tahun. Data latih mencakup 1 Januari 2020 sampai 31 Desember 2023 sebanyak 1.460 observasi dengan proporsi Tidak Sehat+ 36,1%. Data uji mencakup 1 Januari 2024 sampai 31 Desember 2024 sebanyak 366 observasi dengan proporsi Tidak Sehat+ 24,3%. Pembagian ini membuat model dilatih pada periode yang lebih awal dan diuji pada tahun setelahnya.

Pembagian acak tidak digunakan karena data memiliki struktur waktu harian. Dengan pembagian kronologis, evaluasi model lebih sesuai dengan kondisi penggunaan ketika model dilatih menggunakan data historis dan diuji pada periode yang lebih baru.

3.4.7. Missing Values, Imputasi, dan *Scaling*

Pemeriksaan nilai kosong pada periode 2020-2024 menunjukkan PM2.5 sebanyak 369 nilai (20,21%); PM10 sebanyak 200 nilai (10,95%); SO2 sebanyak 46 nilai (2,52%); CO sebanyak 27 nilai (1,48%); O3 sebanyak 23 nilai (1,26%); NO2 sebanyak 14 nilai (0,77%). Khusus PM2.5, tahun 2020 memiliki 366 nilai kosong dari 366 hari, sehingga interpretasi kontribusi PM2.5 pada tahun tersebut harus dibaca dengan hati-hati.

$$\text{Persentase Missing} = (\text{Jumlah Missing} / 1.826) \times 100\%$$

Sebagai contoh, PM2.5 dihitung sebagai $369/1.826 \times 100\% = 20,21\%$, sedangkan PM10 dihitung sebagai $200/1.826 \times 100\% = 10,95\%$. Perhitungan tersebut digunakan untuk membaca kualitas data dan tingkat kelengkapan parameter polutan sebelum imputasi.

Imputasi dilakukan setelah data dibagi secara kronologis. Pada data latih, nilai kosong polutan diisi melalui interpolasi berbasis waktu untuk celah pendek, median bulanan dari data

latih, dan median global dari data latih. Parameter median dari data latih kemudian diterapkan pada data uji. Pendekatan ini digunakan agar informasi dari data uji tidak ikut membentuk nilai imputasi evaluasi.

Scaling dilakukan menggunakan StandardScaler yang dilatih hanya pada data latih. Hasil *scaling* digunakan untuk LSTM dan GRU, sedangkan Random Forest dan XGBoost menggunakan data tabular tanpa *scaling* karena kedua model berbasis pohon tidak sensitif terhadap skala fitur seperti model jaringan saraf.

Detail parameter median bulanan dan median global untuk imputasi train-only disimpan pada Lampiran A.5 dalam file A5_parameter_imputasi_train.csv. Parameter mean dan standard deviation StandardScaler dari data latih disimpan pada Lampiran A.6 dalam file A6_scaler_mean_std_train.csv.

3.4.8. Pembentukan *Sequence* untuk LSTM dan GRU

LSTM dan GRU menggunakan *sliding window* 14 hari dengan skema X[i-window:i] → y[i]. Artinya, data 14 hari sebelumnya menjadi *input* untuk mengklasifikasikan status pada hari target berikutnya. Jumlah sequence data latih dihitung dari 1.460 observasi data latih dikurangi ukuran window 14 hari, sehingga diperoleh 1.460 - 14 = 1.446 sequence. Sequence tersebut dibagi secara kronologis menjadi 1.156 sequence untuk pelatihan internal dan 290 sequence untuk validasi. Data uji sequence berjumlah 366 target karena 14 hari terakhir data latih digunakan sebagai konteks awal untuk memprediksi hari pertama data uji.

Empat belas hari terakhir dari data latih digunakan sebagai konteks awal untuk memprediksi hari pertama pada data uji. Dengan cara ini, LSTM dan GRU tetap dievaluasi pada periode target yang sama dengan Random Forest dan XGBoost.

3.4.9. Pemodelan

Pemodelan dilakukan terhadap empat algoritma, yaitu Random Forest, XGBoost, LSTM, dan GRU. Random Forest dan XGBoost dilatih menggunakan data tabular pada hari

target hasil imputasi. LSTM dan GRU dilatih menggunakan data sekuensial hasil *scaling* dan *sliding window* 14 hari dengan TensorFlow/Keras.

Catatan metodologis perlu diberikan karena *input* model tidak sepenuhnya identik. Random Forest dan XGBoost menggunakan fitur tabular pada hari target, sedangkan LSTM dan GRU menggunakan konteks historis 14 hari sebelumnya untuk mengklasifikasikan hari target berikutnya. Oleh karena itu, perbandingan performa dibaca sebagai perbandingan dua pendekatan *input* yang berbeda, yaitu pendekatan tabular dan pendekatan sekuensial, bukan sebagai perbandingan *input* yang sepenuhnya sama.

Pada model ensemble, penanganan ketidakseimbangan kelas dilakukan melalui class_weight pada Random Forest dan scale_pos_weight pada XGBoost. Pada LSTM dan GRU, class weight dihitung dari data pelatihan internal. Seluruh model menghasilkan prediksi kelas dan probabilitas kelas Tidak Sehat+ pada data uji tahun 2024.

$$class_weight_i = n_samples / (n_classes \times n_i)$$

$$scale_pos_weight = \text{jumlah kelas negatif / jumlah kelas positif}$$

Berdasarkan data latih, kelas Bukan Tidak Sehat+ berjumlah 933 observasi dan kelas Tidak Sehat+ berjumlah 527 observasi. Dengan demikian, *scale_pos_weight* untuk XGBoost dihitung sebagai 933/527 ≈ 1,77. Rumus *class_weight* balanced menghasilkan bobot sekitar 0,78 untuk kelas negatif Bukan Tidak Sehat+ dan 1,39 untuk kelas positif Tidak Sehat+. Pembobotan kelas ini merupakan bagian dari proses pelatihan model, bukan hasil evaluasi performa.

3.4.10. Evaluasi Model

Evaluasi dilakukan pada data uji tahun 2024 sebanyak 366 observasi. Kelas positif pada penelitian ini adalah Tidak Sehat+, sedangkan kelas pembanding adalah Bukan Tidak Sehat+. Setiap model menghasilkan prediksi kelas dan probabilitas prediksi yang digunakan untuk mengevaluasi kemampuan model dalam membedakan kedua kelas target.

Confusion matrix digunakan untuk memperoleh nilai true positive, false positive, true negative, dan false negative. Dalam konteks penelitian ini, true positive menunjukkan hari Tidak Sehat+ yang berhasil diprediksi sebagai Tidak Sehat+, sedangkan false negative menunjukkan hari Tidak Sehat+ yang keliru diprediksi sebagai Bukan Tidak Sehat+. Nilai tersebut digunakan untuk menghitung Precision, Recall, dan F1-Score. Probabilitas prediksi digunakan untuk menghitung ROC-AUC.

Komponen confusion matrix dalam penelitian ini didefinisikan sebagai berikut: TP adalah hari dengan kategori aktual Tidak Sehat+ yang diprediksi sebagai Tidak Sehat+; TN adalah hari dengan kategori aktual Bukan Tidak Sehat+ yang diprediksi sebagai Bukan Tidak Sehat+; FP adalah hari dengan kategori aktual Bukan Tidak Sehat+ yang diprediksi sebagai Tidak Sehat+; dan FN adalah hari dengan kategori aktual Tidak Sehat+ yang diprediksi sebagai Bukan Tidak Sehat+.

Secara operasional, TP, FP, TN, dan FN diperoleh dari perbandingan antara target aktual dan prediksi kelas pada 366 observasi data uji. Precision, Recall, dan F1-Score dihitung dari komponen *confusion matrix* tersebut, sedangkan ROC-AUC dihitung dari probabilitas prediksi kelas Tidak Sehat+.

Precision = TP / (TP + FP)

Recall = TP / (TP + FN)

F1-Score = 2 × (Precision × Recall) / (Precision + Recall)

ROC-AUC dijelaskan sebagai ukuran luas area di bawah ROC curve yang dihitung dari probabilitas prediksi kelas Tidak Sehat+.

Pada notebook, ROC-AUC dihitung dari probabilitas prediksi kelas Tidak Sehat+ pada 366 observasi data uji tahun 2024. Perhitungan ROC curve dilakukan melalui pasangan TPR dan FPR pada berbagai threshold, sedangkan nilai akhir ROC-AUC tetap disajikan pada BAB IV.

Tahap evaluasi pada bab ini dijelaskan sebagai prosedur pengukuran kinerja model yang diterapkan secara konsisten terhadap Random Forest, XGBoost, LSTM, dan GRU. Nilai hasil evaluasi disajikan pada BAB IV sebagai bagian dari pembahasan hasil penelitian.

3.4.11. Interpretasi SHAP

Interpretasi dilakukan menggunakan SHAP pada model berbasis ensemble yang dipilih setelah proses evaluasi. SHAP dihitung untuk setiap fitur dan setiap observasi sehingga kontribusi fitur dapat dibaca baik pada tingkat observasi maupun secara global.

Mean absolute SHAP diperoleh dari rata-rata nilai absolut SHAP pada seluruh observasi. Nilai ini digunakan untuk menyusun peringkat kontribusi fitur tanpa membaca arah kontribusi sebagai hubungan sebab-akibat. Dengan demikian, SHAP pada penelitian ini menjelaskan pola kontribusi fitur terhadap keputusan model, bukan membuktikan penyebab perubahan kualitas udara.

$$\text{Mean Absolute SHAP}_j = (1/n)\ \Sigma\ |\text{SHAP}_{ij}|$$

Dalam rumus tersebut, $SHAP_{ij}$ menunjukkan nilai SHAP fitur ke-j pada observasi ke-i. Pada SHAP data uji 2024, n adalah jumlah observasi data uji, yaitu 366 observasi. Pada SHAP historis, nilai mean absolute SHAP diringkas per tahun dan per polutan untuk diagnosis retrospektif periode 2020-2024.

Secara operasional, nilai SHAP dihitung untuk setiap pasangan fitur dan observasi, kemudian nilai absolutnya dirata-ratakan untuk setiap fitur. Hasil akhir peringkat kontribusi fitur tidak ditampilkan pada BAB III karena menjadi bagian dari pembahasan hasil pada BAB IV.

SHAP pada data uji 2024 digunakan untuk interpretasi pada periode evaluasi generalisasi karena data tahun 2024 tidak digunakan untuk melatih model. Selain itu, SHAP historis 2020-2024 disajikan sebagai diagnosis retrospektif untuk membaca pola kontribusi rata-rata polutan sepanjang periode penelitian dengan tetap memperhatikan batasan kualitas

data, terutama *missing values* PM2.5 tahun 2020. Untuk SHAP historis, *notebook* membentuk model diagnostik berbasis konfigurasi model ensemble yang dipilih setelah evaluasi, kemudian melatihnya pada data periode 2020–2024 yang telah diimputasi; hasilnya digunakan untuk diagnosis retrospektif, bukan untuk evaluasi generalisasi.

UNIVERSITAS BINA SARANA INFORMATIKA

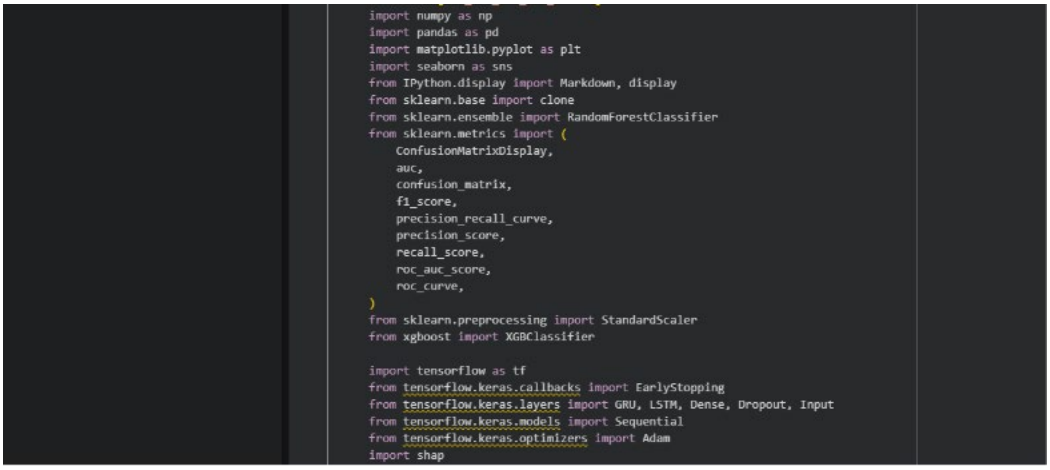
BAB IV

HASIL PENELITIAN DAN PEMBAHASAN

Bab ini menyajikan hasil penelitian berdasarkan tahapan eksperimen yang telah dirancang pada BAB III. Penyajian hasil dilakukan secara berurutan mulai dari lingkungan komputasi, pemuatan dataset, pemahaman struktur data, seleksi periode, pembersihan data, pembentukan target biner, penanganan nilai kosong, feature engineering, pembagian data, pelatihan model, evaluasi model, hingga interpretasi kontribusi fitur menggunakan SHAP. Urutan tersebut digunakan agar seluruh hasil penelitian dapat ditelusuri dari proses komputasi yang dijalankan pada notebook sampai pada output yang ditampilkan dalam bentuk tabel dan visualisasi.

4.1. Library dan Lingkungan Komputasi

Eksperimen penelitian ini dijalankan menggunakan bahasa pemrograman Python pada lingkungan notebook berbasis Google Colab. Lingkungan notebook dipilih karena mendukung eksekusi kode secara bertahap, dokumentasi proses eksperimen, serta penyimpanan output dalam bentuk tabel maupun gambar. Notebook eksperimen digunakan sebagai media utama untuk melakukan pemuatan data, pembersihan data, pembentukan fitur, pelatihan model, evaluasi, dan interpretasi SHAP.



```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from IPython.display import Markdown, display
from sklearn.base import clone
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import (
    ConfusionMatrixDisplay,
    auc,
    confusion_matrix,
    f1_score,
    precision_recall_curve,
    precision_score,
    recall_score,
    roc_auc_score,
    roc_curve,
)
from sklearn.preprocessing import StandardScaler
from xgboost import XGBClassifier

import tensorflow as tf
from tensorflow.keras.callbacks import EarlyStopping
from tensorflow.keras.layers import GRU, LSTM, Dense, Dropout, Input
from tensorflow.keras.models import Sequential
from tensorflow.keras.optimizers import Adam
import shap
```

Gambar IV. 1 Cuplikan Library Python yang Digunakan dalam Eksperimen

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Gambar IV.1 memperlihatkan library Python yang digunakan untuk mendukung seluruh tahapan eksperimen. Library pandas digunakan untuk membaca dataset, mengelola struktur data berbentuk DataFrame, menghitung ringkasan data, dan menyimpan output tabel. Library numpy digunakan untuk operasi numerik, sedangkan matplotlib dan seaborn digunakan untuk membangun visualisasi seperti grafik distribusi kategori, heatmap missing values, confusion matrix, ROC curve, Precision-Recall curve, dan grafik SHAP feature importance.

Tahap pemodelan menggunakan beberapa library machine learning dan deep learning. Library scikit-learn digunakan untuk preprocessing, scaling, pemodelan Random Forest, serta penghitungan metrik evaluasi seperti Precision, Recall, F1-Score, ROC-AUC, dan confusion matrix. Library xgboost digunakan untuk membangun model XGBoost sebagai model ensemble pembanding. Sementara itu, tensorflow.keras digunakan untuk membangun model LSTM dan GRU karena kedua model tersebut memerlukan arsitektur neural network berbasis sequence. Library shap digunakan untuk menjelaskan kontribusi fitur terhadap keputusan model terpilih.

Tabel IV. 1 Library Utama yang Digunakan dalam Eksperimen

Library	Fungsi dalam Penelitian
pandas	Membaca dataset, mengolah DataFrame, menghitung ringkasan data, dan menyimpan tabel output.
numpy	Mendukung operasi numerik dan manipulasi array.
matplotlib	Membuat visualisasi grafik dasar.
seaborn	Membuat visualisasi statistik seperti heatmap, barplot, dan confusion matrix.
scikit-learn	Melakukan preprocessing, scaling, pemodelan Random Forest, dan evaluasi metrik klasifikasi.
xgboost	Membangun model XGBoost sebagai model ensemble pembanding.
tensorflow.keras	Membangun model LSTM dan GRU berbasis deep learning.
shap	Menginterpretasikan kontribusi fitur terhadap keputusan model terpilih.

Sumber: Diolah oleh penulis (2026)

Tabel IV.1 menunjukkan bahwa eksperimen tidak hanya berfokus pada proses pemodelan, tetapi juga mencakup pengolahan data, visualisasi, evaluasi, dan interpretasi model. Penggunaan beberapa library tersebut disesuaikan dengan kebutuhan penelitian. Library berbasis machine learning digunakan untuk membangun model klasifikasi, sedangkan SHAP digunakan untuk menjawab kebutuhan interpretasi kontribusi fitur yang menjadi bagian penting dalam penelitian ini. Notebook eksperimen dapat ditelusuri melalui tautan khusus berikut: [https://drive.google.com/file/d/1zoZmP6O0RCxMeGiFhYcaEb8zaPdGfwP4/view?usp=drive_link].

4.2. Load Dataset dan Gambaran Dataset Mentah

Dataset yang digunakan dalam penelitian ini adalah data Indeks Standar Pencemar Udara (ISPU) DKI Jakarta yang tersimpan dalam file ispu_dki_all.csv. Dataset tersebut merupakan data sekunder yang memuat observasi harian kualitas udara berdasarkan beberapa parameter polutan. Sumber data asli dicantumkan secara langsung agar dataset yang digunakan dapat ditelusuri. Dataset terstruktur diperoleh dari Kaggle melalui tautan

https://www.kaggle.com/datasets/senadu34/air-quality-index-in-jakarta-2010-2021/data. Sumber pemerintah yang relevan berasal dari Portal Satu Data Jakarta melalui tautan https://satudata.jakarta.go.id/search?q=ispu&halaman=all&kategori=dataset&topik=all&organisasi=all&status=all&sort=desc&page_no=1&show_filter=true&lang=id. Secara substantif, data ISPU tersebut berkaitan dengan data kualitas udara yang dikelola oleh Dinas Lingkungan Hidup Provinsi DKI Jakarta. File dataset mentah yang digunakan dalam eksperimen dapat diakses melalui tautan berikut: [https://drive.google.com/file/d/10GA-CjmIl_6htHX4n-c6XeveHduLhQ9J/view?usp=drive_link].



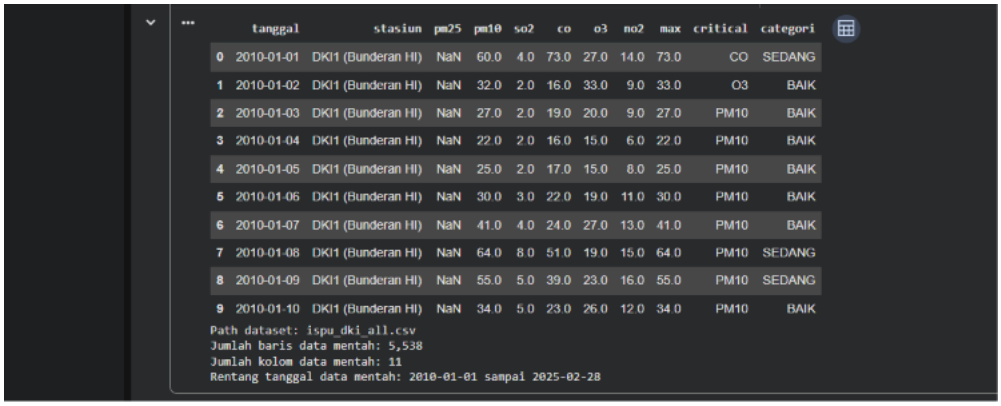
```
raw_df = pd.read_csv(dataset_path)
raw_df["tanggal"] = pd.to_datetime(raw_df["tanggal"], errors="coerce")

display(raw_df.head(10))
print(f"Path dataset: {dataset_path}")
print(f"Jumlah baris data mentah: {raw_df.shape[0]:,}")
print(f"Jumlah kolom data mentah: {raw_df.shape[1]:,}")
print(f"Rentang tanggal data mentah: {raw_df['tanggal'].min().date()} sampai {raw_df['tanggal'].max().date()}")
```

Gambar IV. 2 Cuplikan Kode Python untuk Memuat Dataset Mentah

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Gambar IV.2 memperlihatkan proses awal pemuatan dataset ke dalam notebook. File ispu_dki_all.csv dibaca menggunakan fungsi read_csv() dari library pandas, kemudian kolom tanggal dikonversi ke format waktu menggunakan pd.to_datetime(). Konversi ini penting karena kolom tanggal tidak hanya berfungsi sebagai informasi administratif, tetapi juga digunakan untuk seleksi periode penelitian, pengurutan data secara kronologis, pembentukan fitur waktu, dan pembagian data latih serta data uji. Setelah data berhasil dimuat, notebook menampilkan beberapa baris awal dataset menggunakan head() dan memeriksa jumlah baris, jumlah kolom, serta rentang tanggal dataset.



	tanggal	stasiun	pm25	pm10	so2	co	o3	no2	max	critical	categori
0	2010-01-01	DKI1 (Bunderan HI)	NaN	60.0	4.0	73.0	27.0	14.0	73.0	CO	SEDANG
1	2010-01-02	DKI1 (Bunderan HI)	NaN	32.0	2.0	16.0	33.0	9.0	33.0	O3	BAIK
2	2010-01-03	DKI1 (Bunderan HI)	NaN	27.0	2.0	19.0	20.0	9.0	27.0	PM10	BAIK
3	2010-01-04	DKI1 (Bunderan HI)	NaN	22.0	2.0	16.0	15.0	6.0	22.0	PM10	BAIK
4	2010-01-05	DKI1 (Bunderan HI)	NaN	25.0	2.0	17.0	15.0	8.0	25.0	PM10	BAIK
5	2010-01-06	DKI1 (Bunderan HI)	NaN	30.0	3.0	22.0	19.0	11.0	30.0	PM10	BAIK
6	2010-01-07	DKI1 (Bunderan HI)	NaN	41.0	4.0	24.0	27.0	13.0	41.0	PM10	BAIK
7	2010-01-08	DKI1 (Bunderan HI)	NaN	64.0	8.0	51.0	19.0	15.0	64.0	PM10	SEDANG
8	2010-01-09	DKI1 (Bunderan HI)	NaN	55.0	5.0	39.0	23.0	16.0	55.0	PM10	SEDANG
9	2010-01-10	DKI1 (Bunderan HI)	NaN	34.0	5.0	23.0	26.0	12.0	34.0	PM10	BAIK

```
Path dataset: ispu_dki_all.csv
Jumlah baris data mentah: 5,538
Jumlah kolom data mentah: 11
Rentang tanggal data mentah: 2010-01-01 sampai 2025-02-28
```

Gambar IV. 3 Screenshot Dataset Mentah ispu_dki_all.csv
Sumber: Diolah oleh penulis (2026)

Output pada Gambar IV.3 menunjukkan bahwa dataset mentah terdiri atas kolom tanggal, stasiun pemantauan, enam parameter polutan, nilai maksimum, parameter kritis, dan kategori ISPU asli. Enam parameter polutan yang tersedia adalah PM2.5, PM10, SO2, CO, O3, dan NO2. Kolom-kolom polutan tersebut menjadi kandidat fitur utama dalam pemodelan karena merepresentasikan kondisi kualitas udara. Kolom categori digunakan sebagai sumber pembentukan target klasifikasi, sedangkan kolom max dan critical tidak digunakan sebagai fitur model karena keduanya berhubungan langsung dengan pembentukan kategori ISPU.

Tabel IV. 2 Ringkasan Dataset Mentah

Komponen	Nilai
Jumlah baris	5.538
Jumlah kolom	11
Tanggal awal	2010-01-01
Tanggal akhir	2025-02-28
Kolom tersedia	tanggal, stasiun, pm25, pm10, so2, co, o3, no2, max, critical, categori

Sumber: Diolah oleh penulis (2026)

Tabel IV.2 menunjukkan bahwa dataset mentah terdiri dari 5.538 baris dan 11 kolom dengan rentang tanggal mulai 1 Januari 2010 sampai 28 Februari 2025. Jumlah observasi tersebut diperoleh dari pemeriksaan dimensi data menggunakan atribut shape pada DataFrame. Nilai 5.538 menunjukkan jumlah baris observasi harian yang tersedia sebelum seleksi periode penelitian dilakukan, sedangkan nilai 11 menunjukkan jumlah kolom yang tersedia pada dataset

mentah. Karena periode penelitian dibatasi pada tahun 2020 sampai 2024, tidak seluruh baris pada dataset mentah digunakan dalam pemodelan.

4.3. Data Understanding dan Struktur Dataset

Tahap data understanding dilakukan untuk memastikan bahwa dataset memiliki struktur kolom yang sesuai dengan kebutuhan penelitian. Pemeriksaan ini mencakup kelengkapan nama kolom, tipe data, jumlah nilai non-null, dan peran setiap kolom dalam alur penelitian. Tahap ini penting karena kesalahan dalam memahami peran kolom dapat menyebabkan fitur yang tidak semestinya masuk ke dalam model, terutama kolom yang berpotensi menyebabkan target leakage.



```
[5]
✓ 0s
    expected_columns = {"tanggal", "stasiun", "pm25", "pm10", "so2", "co", "o3", "no2", "max", "critical", "categori"}
    missing_columns = expected_columns.difference(raw_df.columns)
    if missing_columns:
        raise ValueError(f"Kolom dataset belum sesuai: {sorted(missing_columns)}")

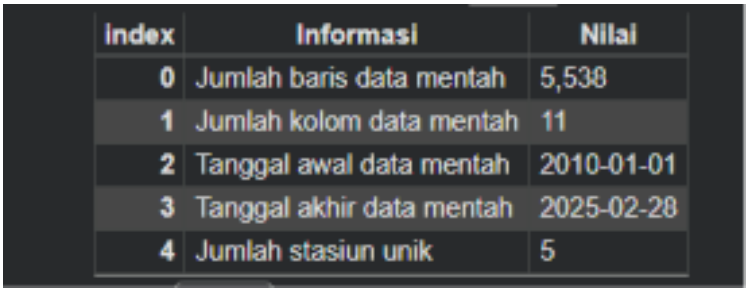
    data_structure = pd.DataFrame({
        "Informasi": [
            "Jumlah baris data mentah",
            "Jumlah kolom data mentah",
            "Tanggal awal data mentah",
            "Tanggal akhir data mentah",
            "Jumlah stasiun unik",
        ],
        "Nilai": [
            f"{raw_df.shape[0]:,}",
            f"{raw_df.shape[1]:,}",
            raw_df["tanggal"].min().date(),
            raw_df["tanggal"].max().date(),
            raw_df["stasiun"].nunique(dropna=True),
        ],
    })
    save_table(data_structure, "01_ringkasan_struktur_data.csv")
    display(data_structure)

    df_period_raw = (
        raw_df.loc[(raw_df["tanggal"] >= START_DATE) & (raw_df["tanggal"] <= END_DATE)]
        .copy()
        .sort_values("tanggal")
        .reset_index(drop=True)
    )
```

Gambar IV. 4 Cuplikan Kode Python Pemeriksaan Struktur Dataset

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.4 digunakan untuk memeriksa apakah seluruh kolom yang dibutuhkan tersedia di dalam dataset. Pemeriksaan dilakukan dengan membandingkan daftar kolom yang diharapkan dengan kolom aktual pada DataFrame. Jika terdapat kolom yang tidak tersedia, proses analisis perlu dihentikan atau diperbaiki karena dapat memengaruhi tahapan berikutnya. Selain itu, notebook juga memeriksa jumlah nilai non-null pada setiap kolom untuk melihat kelengkapan data awal sebelum analisis missing values dilakukan secara lebih rinci.



index	Informasi	Nilai
0	Jumlah baris data mentah	5,538
1	Jumlah kolom data mentah	11
2	Tanggal awal data mentah	2010-01-01
3	Tanggal akhir data mentah	2025-02-28
4	Jumlah stasiun unik	5

Gambar IV. 5 Screenshot Output Pemeriksaan Struktur Dataset

Sumber: Diolah oleh penulis (2026)

Output pada Gambar IV.5 menunjukkan bahwa dataset memiliki 11 kolom utama. Kolom tanggal berperan sebagai dasar pengurutan waktu, seleksi periode, pembentukan fitur temporal, dan split kronologis. Kolom stasiun memuat informasi lokasi pemantauan, tetapi tidak digunakan sebagai fitur model karena penelitian ini tidak diarahkan untuk membandingkan kualitas udara antarstasiun. Enam kolom polutan digunakan sebagai fitur utama karena mewakili parameter kualitas udara. Kolom categori digunakan sebagai sumber pembentukan target biner, sedangkan max dan critical dikeluarkan dari fitur model untuk menghindari target leakage.

Tabel IV. 3 Peran Kolom Dataset dalam Penelitian

Kolom	Peran dalam Penelitian	Keputusan Penggunaan
tanggal	Dasar seleksi periode, pengurutan kronologis, pembentukan fitur waktu, dan split data.	Digunakan secara tidak langsung.
stasiun	Informasi lokasi stasiun pemantauan.	Tidak digunakan sebagai fitur karena penelitian tidak membandingkan antarstasiun.
pm25	Parameter polutan PM2.5.	Digunakan sebagai fitur model.
pm10	Parameter polutan PM10.	Digunakan sebagai fitur model.
so2	Parameter polutan sulfur dioksida.	Digunakan sebagai fitur model.
co	Parameter polutan karbon monoksida.	Digunakan sebagai fitur model.
o3	Parameter polutan ozon.	Digunakan sebagai fitur model.

Kolom	Peran dalam Penelitian	Keputusan Penggunaan
no2	Parameter polutan nitrogen dioksida.	Digunakan sebagai fitur model.
max	Nilai maksimum parameter pembentuk kategori ISPU.	Tidak digunakan karena berpotensi menyebabkan target leakage.
critical	Parameter kritis yang berkaitan dengan pembentukan kategori ISPU.	Tidak digunakan karena berpotensi menyebabkan target leakage.
categori	Kategori ISPU asli.	Digunakan sebagai sumber target, tetapi tidak digunakan sebagai fitur model.

Sumber: Diolah oleh penulis (2026)

Tabel IV.3 menegaskan bahwa tidak semua kolom pada dataset mentah digunakan sebagai input model. Kolom polutan digunakan sebagai fitur utama, sedangkan kolom target dan kolom yang terlalu dekat dengan proses pembentukan target dikeluarkan dari daftar fitur. Keputusan untuk tidak menggunakan max dan critical dilakukan untuk menjaga validitas pemodelan. Apabila kedua kolom tersebut dimasukkan sebagai fitur, model berpotensi mempelajari informasi yang sudah sangat dekat dengan label kategori ISPU, sehingga performa evaluasi dapat terlihat tinggi tetapi tidak merepresentasikan kemampuan generalisasi yang wajar. File pendukung untuk struktur dataset awal dapat disediakan melalui tautan berikut: [https://drive.google.com/file/d/1xFKfjtj0mlLO_lId6zAe3rrAV1EsjALO/view?usp=sharing].

4.4. Seleksi Periode, Pembersihan, dan Data Final 1.826 Observasi

Seleksi periode dilakukan untuk menyesuaikan dataset dengan batasan penelitian, yaitu 1 Januari 2020 sampai 31 Desember 2024. Dataset mentah awalnya memuat 5.538 baris dengan rentang tahun 2010 sampai 2025. Karena penelitian ini hanya menganalisis periode 2020-2024, notebook memfilter kolom tanggal agar hanya observasi dalam rentang tersebut yang digunakan. Setelah proses seleksi periode, ditemukan satu baris dengan kategori TIDAK ADA DATA. Baris tersebut dikeluarkan karena tidak dapat dipetakan ke dalam kelas target biner yang valid.



```
[6]
✓ 0s
df_period = df_period_raw.copy()
df_period = df_period.sort_values("tanggal").reset_index(drop=True)

analysis_df = df_period.loc[df_period["categori"] != "TIDAK ADA DATA"].copy()
analysis_df = analysis_df.reset_index(drop=True)

period_summary = pd.DataFrame({
    "Informasi": [
        "Tanggal awal penelitian",
        "Tanggal akhir penelitian",
        "Jumlah observasi periode 2020-2024",
        "Jumlah observasi valid untuk pemodelan",
        "Kategori yang dikeluarkan",
    ],
    "Nilai": [
        df_period["tanggal"].min().date(),
        df_period["tanggal"].max().date(),
        f"{len(df_period):,}",
        f"{len(analysis_df):,}",
        "TIDAK ADA DATA",
    ],
})
save_table(period_summary, "03_ringkasan_seleksi_periode.csv")
display(period_summary)

assert df_period["tanggal"].min() == pd.Timestamp(START_DATE)
```

Gambar IV. 6 Cuplikan Kode Python Seleksi Periode dan Pembersihan Data

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.6 bekerja dengan cara memilih baris yang nilai tanggalnya berada di antara 2020-01-01 dan 2024-12-31. Data hasil filter disalin ke DataFrame baru agar proses pembersihan tidak mengubah dataset mentah. Selanjutnya, data dengan kategori TIDAK ADA DATA dikeluarkan menggunakan kondisi pada kolom categori. Tahap ini menghasilkan data final yang digunakan untuk pembentukan target biner, pemeriksaan nilai kosong, feature engineering, split data, pemodelan, dan evaluasi.

Hasil Seleksi Periode dan Pembersihan Data

Tahap	Jumlah Observasi	Rentang Tanggal	Keterangan
Dataset awal	5538	1 Januari 2010 - 28 Februari 2025	Data mentah
Setelah seleksi periode 2020-2024	1827	1 Januari 2020 - 31 Desember 2024	Data sesuai periode penelitian
Setelah mengeluarkan TIDAK ADA DATA	1826	1 Januari 2020 - 31 Desember 2024	Data final pemodelan

Gambar IV. 7 Screenshot Output Seleksi Periode dan Data Final Pemodelan

Sumber: Diolah oleh penulis (2026)

Gambar IV.7 menunjukkan perubahan jumlah observasi setelah seleksi periode dan pembersihan data. Dataset awal berjumlah 5.538 baris. Setelah dibatasi pada periode 2020-2024, jumlah data menjadi 1.827 observasi. Satu baris kategori TIDAK ADA DATA kemudian dikeluarkan sehingga data final pemodelan berjumlah 1.826 observasi. Dengan demikian,

seluruh tahapan pemodelan dan evaluasi setelah tahap ini menggunakan 1.826 observasi sebagai data valid.



	Informasi	Nilai
0	Tanggal awal penelitian	2020-01-01
1	Tanggal akhir penelitian	2024-12-31
2	Jumlah observasi periode 2020-2024	1,827
3	Jumlah observasi valid untuk pemodelan	1,826
4	Kategori yang dikeluarkan	TIDAK ADA DATA

Gambar IV. 8 Screenshot Shape Data Final Pemodelan 1.826 Observasi

Sumber: Diolah oleh penulis dari output notebook (2026)

Output pada Gambar IV.8 memperkuat hasil seleksi periode dengan menampilkan bentuk akhir DataFrame yang digunakan untuk pemodelan. Informasi shape data final menunjukkan bahwa jumlah observasi yang dipakai dalam eksperimen adalah 1.826 baris. Data final tersebut dapat ditelusuri pada file khusus berikut: [https://drive.google.com/file/d/1KwAZ1qfPZPVIafdAB4Ly_rRqr9a9KXtT/view?usp=drive_link]. Sementara itu, data hasil filter periode sebelum pengeluaran kategori TIDAK ADA DATA dapat dicantumkan melalui tautan berikut: [https://drive.google.com/file/d/1rXm_5iphoGwPe9o_TQtDN1RS9zz0Rt9H/view?usp=drive_link].

Tabel IV. 4 Ringkasan Seleksi Periode dan Pembersihan Data

Tahap	Jumlah Observasi	Keterangan
Dataset awal	5.538	Data harian ISPU pada rentang 2010-01-01 sampai 2025-02-28.
Filter periode 2020-2024	1.827	Data yang berada pada rentang 2020-01-01 sampai 2024-12-31.
Pengeluaran kategori TIDAK ADA DATA	1.826	Satu baris tidak valid dikeluarkan karena tidak dapat digunakan sebagai target.

Tahap	Jumlah Observasi	Keterangan
Data final pemodelan	1.826	Data valid untuk target biner, pemodelan, evaluasi, dan SHAP.

Sumber: Diolah oleh penulis (2026)

Tabel IV.4 memperlihatkan bahwa proporsi data periode penelitian terhadap dataset mentah adalah 1.827 dibagi 5.538 kemudian dikalikan 100%, sehingga menghasilkan 32,99%. Setelah satu observasi kategori TIDAK ADA DATA dikeluarkan, jumlah data final diperoleh dari 1.827 dikurangi 1, yaitu 1.826 observasi. Angka 1.826 tersebut menjadi penyebut utama dalam perhitungan distribusi target, persentase missing values, dan ringkasan data final pada tahapan berikutnya.

4.5. Distribusi Kategori ISPU Asli

Distribusi kategori ISPU asli diperlukan untuk memahami komposisi kelas sebelum kategori tersebut dipetakan menjadi target biner. Pada notebook, distribusi awal dihitung dari data periode 2020-2024, kemudian hasil final yang digunakan untuk pemodelan dihitung setelah baris TIDAK ADA DATA dikeluarkan. Dengan cara ini, pembahasan tetap menunjukkan kondisi kategori asli, tetapi perhitungan proporsi yang menjadi dasar pemodelan menggunakan 1.826 observasi valid.

```
[7]
✓ 0s
analysis_df["target_tidak_sehat"] = analysis_df["categori"].isin(target_positive_categories).astype(int)
analysis_df["target_label"] = analysis_df["target_tidak_sehat"].map({
    0: "Bukan Tidak Sehat+",
    1: "Tidak Sehat+",
})

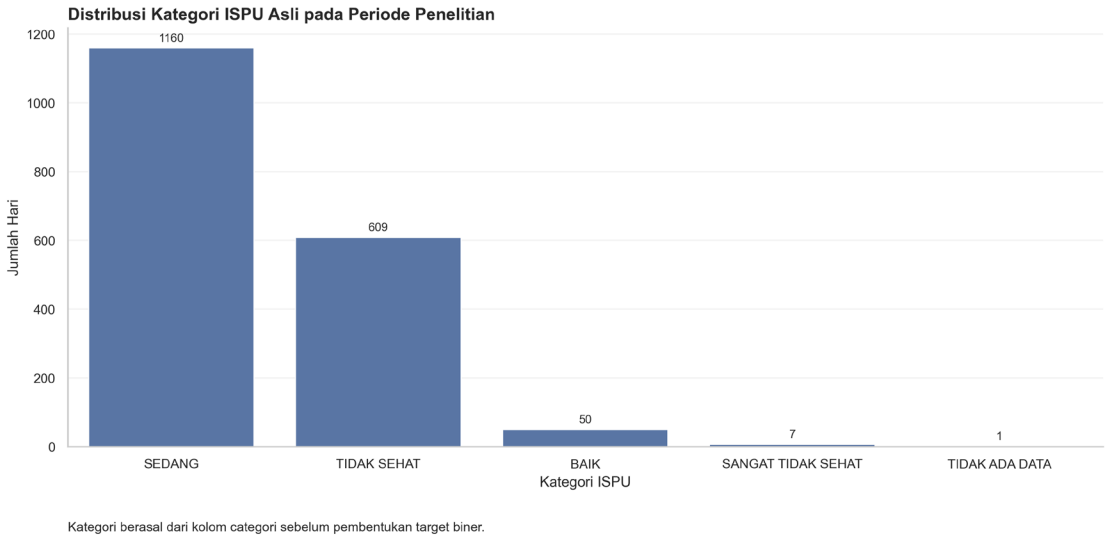
target_counts = (
    analysis_df["target_label"]
    .value_counts()
    .rename_axis("Target Klasifikasi")
    .reset_index(name="Jumlah Hari")
)
target_counts["Persentase"] = (target_counts["Jumlah Hari"] / target_counts["Jumlah Hari"].sum() * 100).round(2)
save_table(target_counts, "04_distribusi_target_biner.csv")
display(target_counts)

fig, ax = plt.subplots(figsize=(10, 6))
sns.barplot(data=target_counts, x="Target Klasifikasi", y="Jumlah Hari", ax=ax)
ax.set_title("Distribusi Target Biner ISPU", loc="left", fontweight="bold")
clean_axes(ax, xlabel="Target", ylabel="Jumlah Hari")
add_bar_labels(ax)
add_note(ax, "Tidak Sehat+ adalah kelas positif; Bukan Tidak Sehat+ adalah kelas pembanding.")
plt.tight_layout()
save_figure(fig, "02_distribusi_target_biner.png")
plt.show()
```

Gambar IV. 9 Cuplikan Kode Python Distribusi Kategori ISPU Asli

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.9 menghitung frekuensi kategori ISPU menggunakan fungsi value_counts() pada kolom categori. Frekuensi tersebut kemudian diubah menjadi persentase dengan membagi jumlah hari pada setiap kategori terhadap total observasi yang dianalisis. Pada data final pemodelan, kategori TIDAK ADA DATA sudah tidak dimasukkan sehingga proporsi kategori valid dihitung terhadap 1.826 observasi.



Gambar IV. 10 Screenshot Output Distribusi Kategori ISPU Asli

Sumber: Diolah oleh penulis (2026)

Gambar IV.10 masih memperlihatkan distribusi kategori awal pada periode 2020-2024 yang mencakup satu baris TIDAK ADA DATA. Informasi tersebut berguna untuk menunjukkan bahwa baris tidak valid memang ada pada data hasil seleksi periode. Namun, karena tahap pemodelan hanya menggunakan kategori yang valid, perhitungan akhir pada Tabel IV.5 menggunakan 1.826 observasi setelah TIDAK ADA DATA dikeluarkan.

Tabel IV. 5 Distribusi Kategori ISPU Valid pada Data Final 1.826 Observasi

Kategori ISPU	Jumlah Hari	Perhitungan Persentase	Persentase
SEDANG	1.160	1.160 / 1.826 × 100%	63,53%
TIDAK SEHAT	609	609 / 1.826 × 100%	33,35%
BAIK	50	50 / 1.826 × 100%	2,74%
SANGAT TIDAK SEHAT	7	7 / 1.826 × 100%	0,38%

Sumber: Diolah oleh penulis (2026)

Tabel IV.5 menunjukkan bahwa kategori SEDANG merupakan kategori paling dominan pada data final, yaitu 1.160 hari. Persentase kategori SEDANG dihitung dengan membagi 1.160 terhadap total 1.826 observasi, kemudian dikalikan 100%, sehingga menghasilkan 63,53%. Kategori TIDAK SEHAT berjumlah 609 hari; perhitungannya adalah 609 dibagi 1.826 kemudian dikalikan 100%, sehingga menghasilkan 33,35%. Kategori BAIK berjumlah 50 hari; perhitungannya adalah 50 dibagi 1.826 kemudian dikalikan 100%, sehingga menghasilkan 2,74%. Kategori SANGAT TIDAK SEHAT berjumlah 7 hari; perhitungannya adalah 7 dibagi 1.826 kemudian dikalikan 100%, sehingga menghasilkan 0,38%. Hasil ini menunjukkan bahwa kategori SEDANG mendominasi data final, sedangkan kategori TIDAK SEHAT tidak lagi dihitung dalam distribusi ini.

4.6. Pembentukan Target Biner

Pembentukan target biner dilakukan karena penelitian ini berfokus pada klasifikasi kondisi kualitas udara yang perlu mendapat perhatian. Kategori Tidak Sehat+ dan Bukan Tidak Sehat+. Kelas Tidak Sehat+ dibentuk dari kategori asli TIDAK SEHAT dan SANGAT TIDAK

SEHAT, sedangkan kelas Bukan Tidak Sehat+ dibentuk dari kategori asli BAIK dan SEDANG. Penamaan kelas Bukan Tidak Sehat+ digunakan sebagai kelas pembanding agar definisi target tetap konsisten dengan struktur kategori pada kolom categori. Dalam konteks ini, SANGAT TIDAK SEHAT tetap dipahami sebagai kategori asli ISPU, sedangkan Tidak Sehat+ merupakan definisi operasional penelitian dan bukan kategori resmi baru dalam regulasi ISPU. BAIK dan SEDANG dipetakan menjadi kelas Bukan Tidak Sehat+, sedangkan kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT dipetakan menjadi kelas Tidak Sehat+. Istilah Tidak Sehat+ merupakan definisi operasional penelitian untuk menggabungkan kategori yang menunjukkan kondisi udara tidak sehat atau lebih buruk, bukan kategori resmi baru dalam regulasi ISPU.



```
[7]
✓ 0s
    analysis_df["target_tidak_sehat"] = analysis_df["categori"].isin(target_positive_categories).astype(int)
    analysis_df["target_label"] = analysis_df["target_tidak_sehat"].map({
        0: "Bukan Tidak Sehat+",
        1: "Tidak Sehat+",
    })

    target_counts = (
        analysis_df["target_label"]
        .value_counts()
        .rename_axis("Target Klasifikasi")
        .reset_index(name="Jumlah Hari")
    )
    target_counts["Persentase"] = (target_counts["Jumlah Hari"] / target_counts["Jumlah Hari"].sum() * 100).round(2)
    save_table(target_counts, "04_distribusi_target_biner.csv")
    display(target_counts)

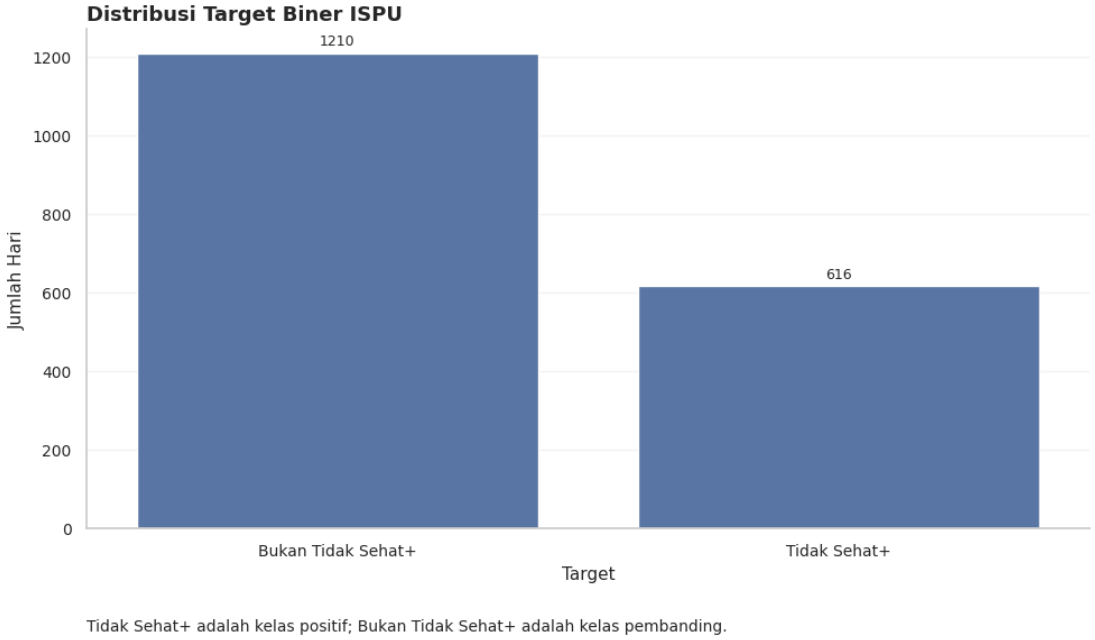
    fig, ax = plt.subplots(figsize=(10, 6))
    sns.barplot(data=target_counts, x="Target Klasifikasi", y="Jumlah Hari", ax=ax)
    ax.set_title("Distribusi Target Biner ISPU", loc="left", fontweight="bold")
    clean_axes(ax, xlabel="Target", ylabel="Jumlah Hari")
    add_bar_labels(ax)
    add_note(ax, "Tidak Sehat+ adalah kelas positif; Bukan Tidak Sehat+ adalah kelas pembanding.")
    plt.tight_layout()
    save_figure(fig, "02_distribusi_target_biner.png")
    plt.show()
```

Gambar IV. 11 Cuplikan Kode Python Pembentukan Target Biner

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.11 membentuk aturan pemetaan dari kategori asli ISPU ke dua kelas target biner. Kategori BAIK dan SEDANG diberi nilai 0 sebagai kelas Bukan Tidak Sehat+, sedangkan kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT diberi nilai 1 sebagai kelas Tidak Sehat+. Kolom target_tidak_sehat digunakan sebagai target numerik dalam pelatihan model, sedangkan target_label digunakan untuk menampilkan nama kelas target pada tabel dan grafik. Karena kategori TIDAK ADA DATA telah dikeluarkan pada tahap

pembersihan data, kategori tersebut tidak masuk ke dalam DataFrame pemodelan dan tidak menjadi bagian dari distribusi target biner.



Gambar IV. 12 Screenshot Output Pemetaan Target Biner

Sumber: Diolah oleh penulis (2026)

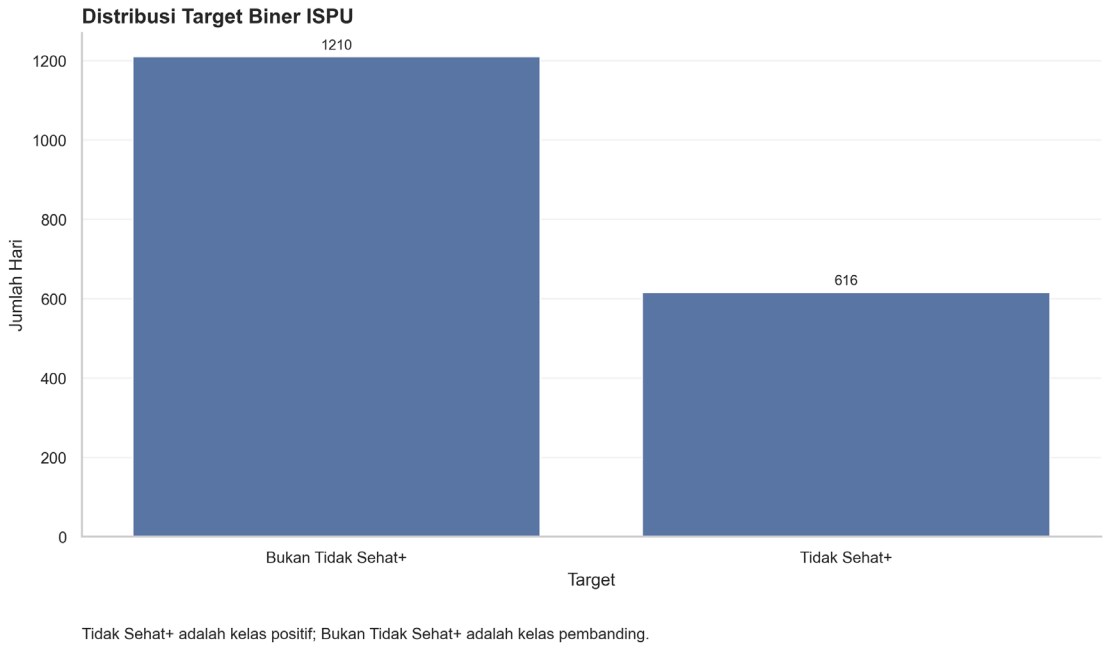
Gambar IV.12 memperlihatkan aturan pemetaan dari kategori ISPU asli ke target biner penelitian. Pemetaan ini menjaga agar target model tetap bermakna secara substantif. Kelas positif berisi kategori yang mengindikasikan kualitas udara tidak sehat atau lebih buruk, sedangkan kelas negatif berisi kategori yang belum masuk ke kondisi tidak sehat.

Tabel IV. 6 Pemetaan Target Biner

Kategori Asli	**Target Biner**	**Nilai Target**	Keterangan
BAIK	Bukan Tidak Sehat+	0	Kelas pembanding/negatif
SEDANG	Bukan Tidak Sehat+	0	Kelas pembanding/negatif
TIDAK SEHAT	Tidak Sehat+	1	Kelas positif
SANGAT TIDAK SEHAT	Tidak Sehat+	1	Kelas positif; tetap kategori asli ISPU
TIDAK ADA DATA	Dikeluarkan	-	Tidak digunakan dalam pemodelan

Sumber: Diolah oleh penulis (2026)

Tabel IV.6 tidak menambah kategori ISPU baru, tetapi menjelaskan bagaimana empat kategori asli yang valid dikelompokkan menjadi dua kelas target biner. Kategori BAIK dan SEDANG menjadi kelas Bukan Tidak Sehat+ karena keduanya berperan sebagai kelas pembanding, sedangkan TIDAK SEHAT dan SANGAT TIDAK SEHAT menjadi kelas Tidak Sehat+ karena keduanya mewakili kondisi kualitas udara yang menjadi perhatian utama model. File mapping target biner dapat dilampirkan melalui tautan berikut: [https://drive.google.com/file/d/1jm-xBNlS_cq_xAgYImqOpsAGbynojXUe/view?usp=drive_link].



Gambar IV. 13 Screenshot Output Distribusi Target Biner

Sumber: Diolah oleh penulis (2026)

Gambar IV.13 menampilkan distribusi target setelah pemetaan biner dilakukan. Kelas Bukan Tidak Sehat+ terlihat lebih besar daripada kelas Tidak Sehat+, sehingga data target tidak sepenuhnya seimbang. Kondisi ini menjadi dasar mengapa evaluasi model tidak hanya dibaca dari satu metrik, tetapi menggunakan Precision, Recall, F1-Score, dan ROC-AUC secara bersamaan.

Tabel IV. 7 Distribusi Target Biner

Target Biner	Jumlah Hari	Perhitungan Persentase	Persentase
Bukan Tidak Sehat+	1.210	1.210 / 1.826 × 100%	66,27%
Tidak Sehat+	616	616 / 1.826 × 100%	33,73%

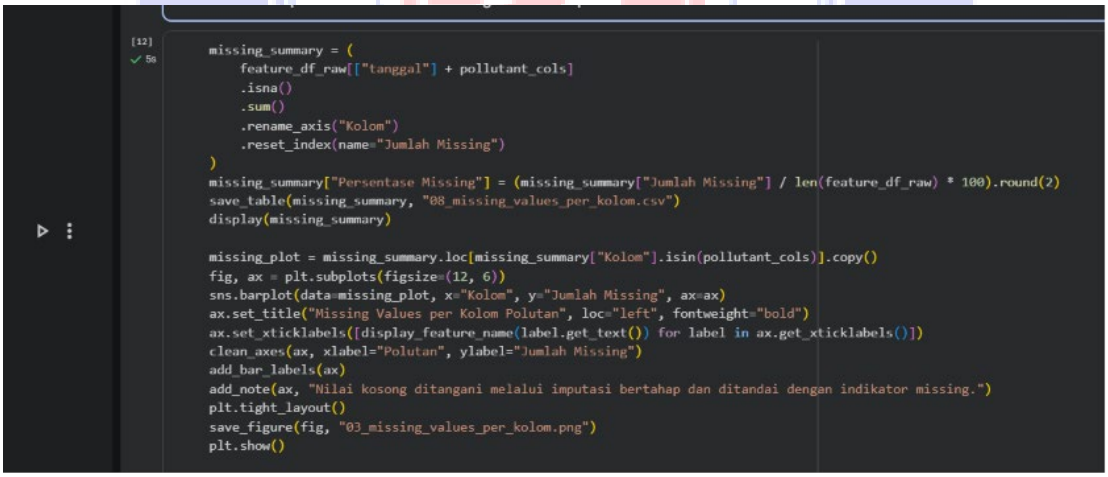
Sumber: Diolah oleh penulis (2026)

Tabel IV.7 menunjukkan bahwa kelas Bukan Tidak Sehat+ berjumlah 1.210 observasi. Persentasenya dihitung dengan membagi 1.210 terhadap total 1.826 observasi, kemudian dikalikan 100%, sehingga menghasilkan 66,27%. Kelas Tidak Sehat+ berjumlah 616 observasi. Persentasenya dihitung dengan membagi 616 terhadap total 1.826 observasi, kemudian dikalikan 100%, sehingga menghasilkan 33,73%. Komposisi ini menunjukkan adanya

ketidakseimbangan kelas karena kelas Bukan Tidak Sehat+ lebih dominan daripada kelas Tidak Sehat+. Oleh karena itu, evaluasi model tidak hanya bertumpu pada satu metrik, tetapi membaca Precision, Recall, F1-Score, dan ROC-AUC secara bersamaan.Data target biner dapat ditelusuri melalui tautan berikut: [https://drive.google.com/file/d/17hhsfT7o6OTmn7UIAvbAXrDmdc9_s5rC/view?usp=drive_link].

4.7. Pemeriksaan Missing Values Awal

Pemeriksaan missing values dilakukan pada data final 1.826 observasi untuk mengetahui kelengkapan setiap parameter polutan. Pemeriksaan ini penting karena model machine learning membutuhkan input numerik yang lengkap. Selain itu, pola nilai kosong perlu dipahami agar proses imputasi tidak dilakukan secara sembarangan dan tetap mempertimbangkan karakter data deret waktu harian.



```
[12]
✓ 5s
    missing_summary = (
        feature_df_raw[["tanggal"] + pollutant_cols]
        .isna()
        .sum()
        .rename_axis("Kolom")
        .reset_index(name="Jumlah Missing")
    )
    missing_summary["Persentase Missing"] = (missing_summary["Jumlah Missing"] / len(feature_df_raw) * 100).round(2)
    save_table(missing_summary, "08_missing_values_per_kolom.csv")
    display(missing_summary)

    missing_plot = missing_summary.loc[missing_summary["Kolom"].isin(pollutant_cols)].copy()
    fig, ax = plt.subplots(figsize=(12, 6))
    sns.barplot(data=missing_plot, x="Kolom", y="Jumlah Missing", ax=ax)
    ax.set_title("Missing Values per Kolom Polutan", loc="left", fontweight="bold")
    ax.set_xticklabels([display_feature_name(label.get_text()) for label in ax.get_xticklabels()])
    clean_axes(ax, xlabel="Polutan", ylabel="Jumlah Missing")
    add_bar_labels(ax)
    add_note(ax, "Nilai kosong ditangani melalui imputasi bertahap dan ditandai dengan indikator missing.")
    plt.tight_layout()
    save_figure(fig, "03_missing_values_per_kolom.png")
    plt.show()
```

Gambar IV. 14 Cuplikan Kode Python Perhitungan Missing Values

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.14 menghitung jumlah nilai kosong pada setiap kolom polutan menggunakan fungsi isna().sum(). Setelah jumlah missing values diperoleh, persentasenya dihitung dengan membagi jumlah missing pada setiap kolom terhadap total data final 1.826

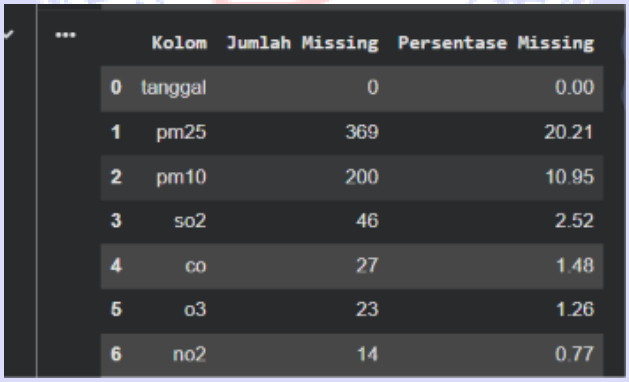
observasi. Perhitungan ini menghasilkan ukuran yang sebanding antarpolutan sehingga dapat diketahui polutan mana yang memiliki masalah kelengkapan data paling besar.

Tabel IV. 8 Missing Values pada Parameter Polutan

Polutan	Jumlah Missing	Perhitungan Persentase	Persentase Missing
PM2.5	369	(369 / 1.826) × 100%	20,21%
PM10	200	(200 / 1.826) × 100%	10,95%
SO2	46	(46 / 1.826) × 100%	2,52%
CO	27	(27 / 1.826) × 100%	1,48%
O3	23	(23 / 1.826) × 100%	1,26%
NO2	14	(14 / 1.826) × 100%	0,77%

Sumber: Diolah oleh penulis (2026)

Tabel IV.8 menunjukkan bahwa PM2.5 memiliki missing values terbesar, yaitu 369 nilai, PM10 memiliki 200 missing values, SO2 memiliki 46 missing values, CO memiliki 27 missing values, O3 memiliki 23 missing values, NO2 memiliki 14 missing values.

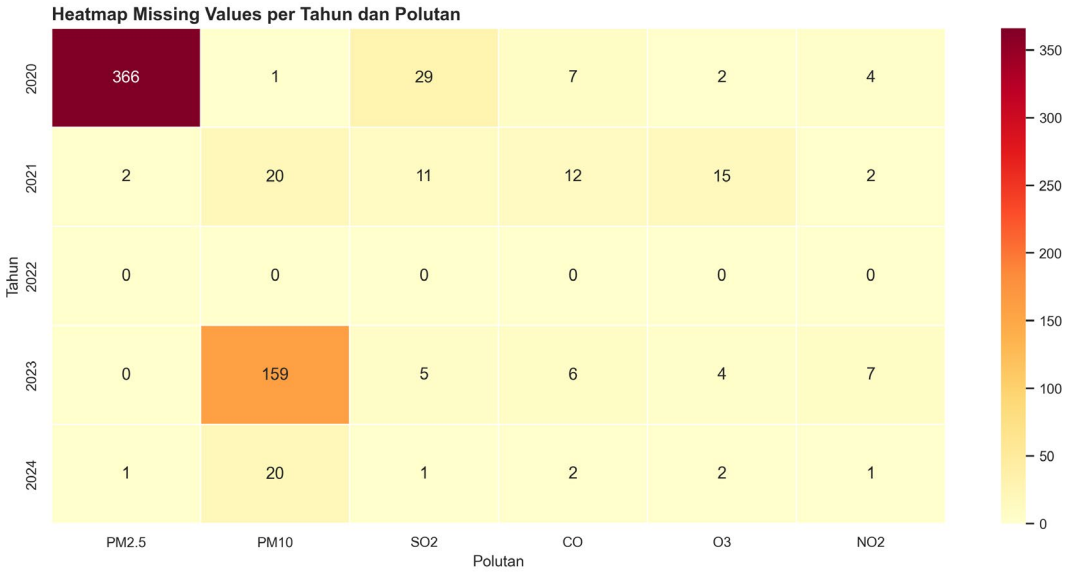


	Kolom	Jumlah Missing	Persentase Missing
0	tanggal	0	0.00
1	pm25	369	20.21
2	pm10	200	10.95
3	so2	46	2.52
4	co	27	1.48
5	o3	23	1.26
6	no2	14	0.77

Gambar IV. 15 Screenshot Output Tabel Missing Values per Polutan

Sumber: Diolah oleh penulis (2026)

Gambar IV.15 memperlihatkan output notebook yang menjadi dasar perhitungan pada Tabel IV.8. Kolom tanggal tidak memiliki nilai kosong, sedangkan nilai kosong hanya ditemukan pada sebagian parameter polutan. Hasil ini menunjukkan bahwa permasalahan utama pada data bukan terletak pada tanggal observasi, melainkan pada kelengkapan pengukuran polutan tertentu.



Gambar IV. 16 Screenshot Output Heatmap Missing Values per Tahun dan Polutan

Sumber: Diolah oleh penulis (2026)

Heatmap pada Gambar IV.16 menunjukkan distribusi missing values berdasarkan tahun dan polutan. PM2.5 pada tahun 2020 memiliki 366 nilai kosong dari 366 hari, yang berarti seluruh observasi PM2.5 pada tahun tersebut tidak tersedia sebelum imputasi. Persentase missing PM2.5 tahun 2020 dihitung dengan membagi 366 terhadap 366 hari, kemudian dikalikan 100%, sehingga menghasilkan 100,00%. Kondisi ini perlu diperhatikan dalam interpretasi hasil, terutama ketika membaca kontribusi PM2.5 pada tahun 2020.

```
plt.show()

train_imputed, monthly_medians, global_medians = impute_pollutants(train_raw, fit=True)
test_imputed, _, _ = impute_pollutants(test_raw, monthly_medians=monthly_medians, global_medians=global_medians, fit=False)

post_missing = pd.DataFrame({
    "Subset": ["Data Latih", "Data Uji"],
    "Jumlah Missing Polutan Setelah Imputasi": [
        int(train_imputed[pollutant_cols].isna().sum().sum()),
        int(test_imputed[pollutant_cols].isna().sum().sum()),
    ],
})
save_table(post_missing, "10_missing_setelah_imputasi.csv")
display(post_missing)

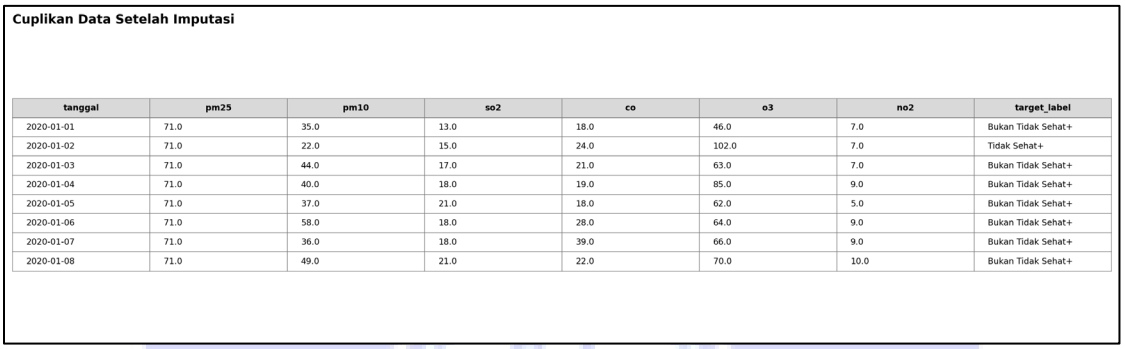
pm25_2020_missing_rate = feature_df_raw.loc[feature_df_raw["tahun"] == 2020, "pm25"].isna().mean()
display(Markdown(
    f"Proporsi nilai PM2.5 yang kosong pada tahun 2020 adalah **{pm25_2020_missing_rate:.1%}**. "
    "Interpretasi kontribusi PM2.5 pada tahun tersebut perlu dibaca dengan batasan ini."
```

Gambar IV. 17 Cuplikan Kode Python Proses Imputasi Train-Only

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.17 menunjukkan bahwa imputasi dilakukan dengan prinsip train-only. Data terlebih dahulu dibagi secara kronologis menjadi data latih dan data uji, kemudian

parameter imputasi dibentuk dari data latih. Proses pengisian nilai kosong dilakukan secara bertahap, yaitu interpolasi berbasis waktu untuk celah pendek, median bulanan data latih untuk nilai kosong yang masih tersisa, dan median global data latih sebagai langkah akhir. Prinsip ini digunakan agar informasi dari data uji tidak bocor ke proses pelatihan.



Cuplikan Data Setelah Imputasi

tanggal	pm25	pm10	so2	co	o3	no2	target_label
2020-01-01	71.0	35.0	13.0	18.0	46.0	7.0	Bukan Tidak Sehat+
2020-01-02	71.0	22.0	15.0	24.0	102.0	7.0	Tidak Sehat+
2020-01-03	71.0	44.0	17.0	21.0	63.0	7.0	Bukan Tidak Sehat+
2020-01-04	71.0	40.0	18.0	19.0	85.0	9.0	Bukan Tidak Sehat+
2020-01-05	71.0	37.0	21.0	18.0	62.0	5.0	Bukan Tidak Sehat+
2020-01-06	71.0	58.0	18.0	28.0	64.0	9.0	Bukan Tidak Sehat+
2020-01-07	71.0	36.0	18.0	39.0	66.0	9.0	Bukan Tidak Sehat+
2020-01-08	71.0	49.0	21.0	22.0	70.0	10.0	Bukan Tidak Sehat+

Gambar IV. 18 Screenshot Output Validasi Setelah Imputasi

Sumber: Diolah oleh penulis (2026)

Gambar IV.18 memperlihatkan hasil setelah proses imputasi diterapkan. Data latih dan data uji tidak lagi memiliki missing values pada fitur polutan. Hal ini memastikan bahwa seluruh model dapat dilatih dan diuji menggunakan input numerik lengkap. Output missing values dan hasil validasi imputasi dapat ditelusuri melalui tautan berikut: [https://drive.google.com/file/d/12JSryd_KwaIIvgZmT17BLWK4dtdBMLzV/view?usp=sharing].

Tabel IV. 9 Ringkasan Hasil Setelah Imputasi

Subset	Jumlah Missing Polutan Setelah Imputasi
Data latih	0
Data uji	0

Sumber: Diolah oleh penulis (2026)

Tabel IV.9 menegaskan bahwa proses imputasi berhasil menghasilkan data latih dan data uji tanpa nilai kosong pada fitur polutan. Dengan demikian, tahapan feature engineering dan pemodelan dapat dilanjutkan tanpa kehilangan baris data tambahan akibat missing values.

4.8. Feature Engineering dan Pencegahan Target Leakage

Feature engineering dilakukan untuk membentuk representasi data yang lebih informatif bagi model. Selain enam fitur polutan utama, penelitian ini membentuk fitur waktu, indikator akhir pekan, indikator pasca-pandemi, dan indikator missing values. Indikator missing values dipertahankan agar model tetap memperoleh informasi bahwa suatu nilai polutan pada awalnya kosong sebelum diimputasi.



```
[10]
✓ 0s
    leakage_check = pd.DataFrame({
        "Kolom": ["stasiun", "max", "critical", "categori", "target_tidak_sehat", "target_label"],
        "Digunakan sebagai Fitur": [col in feature_cols for col in ["stasiun", "max", "critical", "categori", "target_tidak_sehat", "target_label"]],
        "Keputusan": ["Dikecualikan"] * 6,
    })

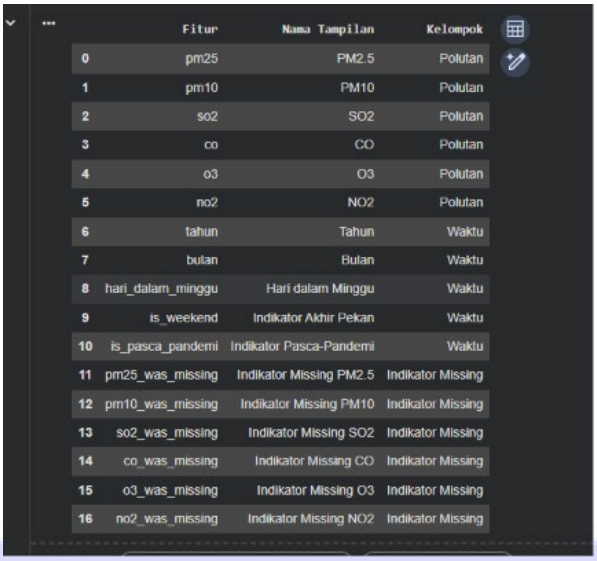
    if leakage_check["Digunakan sebagai Fitur"].any():
        raise ValueError("Terdapat kolom yang tidak boleh masuk ke fitur model.")

    save_table(leakage_check, "06_pencegahan_target_leakage.csv")
    display(leakage_check)
    print(f"Jumlah fitur sah yang digunakan: {len(feature_cols)}")
```

Gambar IV. 19 Cuplikan Kode Python Feature Engineering dan Pencegahan Target Leakage

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.19 menyusun daftar fitur final yang terdiri atas fitur polutan, fitur waktu, dan indikator missing values. Pada saat yang sama, kode tersebut juga mendefinisikan kolom yang tidak boleh digunakan sebagai input model. Kolom max dan critical dikeluarkan karena terlalu dekat dengan proses pembentukan kategori ISPU. Kolom categori, target_tidak_sehat, dan target_label dikeluarkan karena berkaitan langsung dengan target. Kolom stasiun juga dikeluarkan karena penelitian tidak diarahkan pada perbandingan antarstasiun pemantauan.



	Fitur	Nama Tampilan	Kelompok
0	pm25	PM2.5	Polutan
1	pm10	PM10	Polutan
2	so2	SO2	Polutan
3	co	CO	Polutan
4	o3	O3	Polutan
5	no2	NO2	Polutan
6	tahun	Tahun	Waktu
7	bulan	Bulan	Waktu
8	hari_dalam_minggu	Hari dalam Minggu	Waktu
9	is_weekend	Indikator Akhir Pekan	Waktu
10	is_pasca_pandemi	Indikator Pasca-Pandemi	Waktu
11	pm25_was_missing	Indikator Missing PM2.5	Indikator Missing
12	pm10_was_missing	Indikator Missing PM10	Indikator Missing
13	so2_was_missing	Indikator Missing SO2	Indikator Missing
14	co_was_missing	Indikator Missing CO	Indikator Missing
15	o3_was_missing	Indikator Missing O3	Indikator Missing
16	no2_was_missing	Indikator Missing NO2	Indikator Missing

Gambar IV. 20 Output Daftar Fitur Final

Sumber: Diolah oleh penulis (2026)

Output pada Gambar IV.20 menunjukkan bahwa fitur final model berjumlah 17. Fitur tersebut terdiri dari enam fitur polutan, lima fitur waktu atau konteks, dan enam indikator missing values. Penyusunan fitur seperti ini memungkinkan model membaca informasi polutan utama, konteks waktu, serta jejak nilai yang sebelumnya kosong tanpa memasukkan kolom yang dapat menyebabkan target leakage.

Tabel IV. 10 Ringkasan Fitur Final dan Kolom Dikecualikan

Komponen	Isi
Total fitur final	17 fitur
Fitur polutan	PM2.5, PM10, SO2, CO, O3, NO2
Fitur waktu/konteks	tahun, bulan, hari dalam minggu, indikator akhir pekan, indikator pasca-pandemi
Indikator missing	indikator missing untuk enam polutan
Kolom dikecualikan	max, critical, categori, target_tidak_sehat, target_label, stasiun

Sumber: Diolah oleh penulis (2026)

Tabel IV.10 menunjukkan bahwa total fitur final diperoleh dari 6 fitur polutan, 5 fitur waktu atau konteks, dan 6 indikator missing values. Dengan demikian, jumlah fitur final adalah 6 ditambah 5 ditambah 6, yaitu 17 fitur. File daftar fitur final dan kolom yang dikecualikan

dapat ditelusuri melalui tautan berikut: [https://drive.google.com/file/d/1KwAZ1qfPZPVIafdAB4Ly_rRqr9a9KXtT/view?usp=drive_link].

4.9. Imputasi, Scaling, dan Pembentukan Sequence LSTM/GRU

Pembagian data dilakukan secara kronologis karena data ISPU berbentuk deret waktu harian. Data tahun 2020 sampai 2023 digunakan sebagai data latih, sedangkan data tahun 2024 digunakan sebagai data uji. Pendekatan ini dipilih agar evaluasi model menyerupai kondisi penggunaan pada data masa depan, yaitu model dilatih pada periode sebelumnya dan diuji pada periode setelahnya.



```
[11]
✓ 0s
feature_df_raw = feature_df_raw.sort_values("tanggal").reset_index(drop=True)
test_start_date = pd.Timestamp("2024-01-01")

train_raw = feature_df_raw.loc[feature_df_raw["tanggal"] < test_start_date].copy()
test_raw = feature_df_raw.loc[feature_df_raw["tanggal"] >= test_start_date].copy()

y_train = train_raw["target_tidak_sehat"].copy()
y_test = test_raw["target_tidak_sehat"].copy()
train_dates = train_raw["tanggal"].copy()
test_dates = test_raw["tanggal"].copy()

split_summary = pd.DataFrame({
    "Subset": ["Data Latih", "Data Uji"],
    "Tanggal Awal": [train_dates.min().date(), test_dates.min().date()],
    "Tanggal Akhir": [train_dates.max().date(), test_dates.max().date()],
    "Jumlah Observasi": [len(train_raw), len(test_raw)],
    "Proporsi Tidak Sehat+": [round(y_train.mean(), 3), round(y_test.mean(), 3)],
})
save_table(split_summary, "07_split_data_kronologis.csv")
display(split_summary)
```

Gambar IV. 21 Cuplikan Kode Python Split Kronologis

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.21 memisahkan data berdasarkan tanggal. Observasi sebelum 1 Januari 2024 ditempatkan sebagai data latih, sedangkan observasi mulai 1 Januari 2024 ditempatkan sebagai data uji. Pembagian seperti ini menghindari pengacakan data yang dapat mengganggu urutan temporal dan berpotensi membuat informasi masa depan tercampur ke dalam proses pelatihan.



	Subset	Tanggal Awal	Tanggal Akhir	Jumlah Observasi	Proporsi Tidak Sehat+
0	Data Latih	2020-01-01	2023-12-31	1460	0.361
1	Data Uji	2024-01-01	2024-12-31	366	0.243

Gambar IV. 22 Screenshot Output Ringkasan Split Kronologis

Sumber: Diolah oleh penulis (2026)

Gambar IV.22 memperlihatkan hasil pembagian data latih dan data uji. Data latih mencakup periode 2020 sampai 2023 sebanyak 1.460 observasi, sedangkan data uji mencakup tahun 2024 sebanyak 366 observasi. Tahun 2024 digunakan sebagai data uji karena tidak digunakan dalam proses pelatihan model, sehingga sesuai untuk membaca kemampuan generalisasi model pada periode setelah data latih.

Tabel IV. 11 Ringkasan Split Data Latih dan Data Uji

Subset	Periode	Observasi	Tidak Sehat+	Perhitungan	Proporsi Tidak Sehat+
Data latih	2020-2023	1.460	527	527 / 1.460 × 100%	36,10%
Data uji	2024	366	89	89 / 366 × 100%	24,32%

Sumber: Diolah oleh penulis (2026)

Tabel IV.11 menunjukkan bahwa data latih memiliki 527 observasi kelas Tidak Sehat+ dari total 1.460 observasi. Proporsi kelas Tidak Sehat+ pada data latih dihitung dengan membagi 527 terhadap 1.460, kemudian dikalikan 100%, sehingga menghasilkan 36,10%. Data uji memiliki 89 observasi kelas Tidak Sehat+ dari total 366 observasi. Proporsi kelas Tidak Sehat+ pada data uji dihitung dengan membagi 89 terhadap 366, kemudian dikalikan 100%, sehingga menghasilkan 24,32%. Perbedaan proporsi ini menunjukkan bahwa distribusi kelas pada tahun 2024 berbeda dari periode 2020-2023, sehingga evaluasi pada data uji menjadi penting.

Cuplikan Coding Python Scaling dan Sequence

```
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

X_train_seq_all, y_train_seq_all, train_seq_dates = create_sequences_with_dates(
    X_train_scaled_df.values, y_train.values, train_dates.values, window_size=14
)
```

Gambar IV. 23 Cuplikan Kode Python Scaling dan Pembentukan Sequence

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.23 memperlihatkan dua proses tambahan sebelum pemodelan. Pertama, StandardScaler dihitung menggunakan data latih dan kemudian diterapkan pada data uji. Proses ini menjaga agar parameter scaling tidak mengambil informasi dari data uji. Kedua, untuk model LSTM dan GRU, data dibentuk menjadi sequence 14 hari dengan pola X[i-window:i] sebagai input dan y[i] sebagai target. Dengan pola tersebut, model deep learning memanfaatkan konteks historis 14 hari sebelumnya untuk memprediksi target pada hari tertentu.

Tabel IV. 12 Ringkasan Input Sequence LSTM dan GRU

Komponen	Perhitungan	Nilai
Window sequence	Ditentukan sebagai konteks historis 14 hari	14 hari
Sequence latih	1.460 − 14	1.446
Sequence train internal	Hasil pembagian train-validation dari 1.446 sequence	1.156
Sequence validasi internal	1.446 − 1.156	290
Target uji	Seluruh observasi tahun 2024	366

Sumber: Diolah oleh penulis (2026)

Tabel IV.12 menunjukkan bahwa jumlah sequence latih diperoleh dari jumlah data latih 1.460 dikurangi window 14 hari, sehingga menghasilkan 1.446 sequence. Sequence latih tersebut kemudian dipisahkan menjadi 1.156 sequence untuk pelatihan internal dan 290 sequence untuk validasi internal.

4.10. Training Random Forest, XGBoost, LSTM, dan GRU

Empat model dilatih untuk dibandingkan dalam penelitian ini, yaitu Random Forest, XGBoost, LSTM, dan GRU. Random Forest dan XGBoost menggunakan input tabular pada hari target, sedangkan LSTM dan GRU menggunakan sequence 14 hari sebelumnya. Perbedaan jenis input ini perlu diperhatikan dalam interpretasi hasil karena model ensemble dan model deep learning tidak menerima bentuk input yang identik.



```
[18]
✓ 0s
    model_outputs = {
        "Random Forest": {"y_true": y_test.values, "y_pred": rf_pred, "y_proba": rf_proba},
        "XGBoost": {"y_true": y_test.values, "y_pred": xgb_pred, "y_proba": xgb_proba},
        "LSTM": {"y_true": y_test_seq, "y_pred": lstm_pred, "y_proba": lstm_proba},
        "GRU": {"y_true": y_test_seq, "y_pred": gru_pred, "y_proba": gru_proba},
    }

    results_df = pd.DataFrame([
        rf_result,
        xgb_result,
        lstm_result,
        gru_result,
    ]).sort_values(["F1-Score", "ROC-AUC", "Recall", "Precision"], ascending=False).reset_index(drop=True)

    save_table(results_df.round(6), "13_evaluasi_empat_model.csv")
    display(results_df.round(4))
```

Gambar IV. 24 Cuplikan Kode Python Training Empat Model

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.24 menunjukkan skema pelatihan empat model. Random Forest menggunakan parameter class_weight="balanced" untuk menyesuaikan pembelajaran terhadap ketidakseimbangan kelas. XGBoost menggunakan parameter scale_pos_weight yang dihitung dari rasio kelas negatif terhadap kelas positif pada data latih. Pada data latih terdapat 933 observasi kelas Bukan Tidak Sehat+ dan 527 observasi kelas Tidak Sehat+, sehingga nilai scale_pos_weight yang digunakan adalah 933 / 527 = 1,77. Sementara itu, LSTM dan GRU dibangun menggunakan TensorFlow/Keras dan dilatih pada input sequence 14 hari.

Tabel IV. 13 Ringkasan Input Pemodelan

Model	Jenis Input	Data Pelatihan	Data Validasi/Uji	Output
Random Forest	Tabular hari target	Train 2020-2023 = 1.460	Test 2024 = 366	Kelas dan probabilitas Tidak Sehat+

Model	Jenis Input	Data Pelatihan	Data Validasi/Uji	Output
XGBoost	Tabular hari target	Train 2020-2023 = 1.460	Test 2024 = 366	Kelas dan probabilitas Tidak Sehat+
LSTM	Sequence 14 hari	Sequence latih = 1.446	Validasi internal = 290; test 2024 = 366	Kelas dan probabilitas Tidak Sehat+
GRU	Sequence 14 hari	Sequence latih = 1.446	Validasi internal = 290; test 2024 = 366	Kelas dan probabilitas Tidak Sehat+
Kelas negatif data latih	1.460 - 527	933	-	Dasar rasio XGBoost
Kelas positif data latih	Jumlah Tidak Sehat+ pada data latih	-	527	Dasar rasio XGBoost
scale_pos_weight XGBoost	933 / 527	933	527	1,77

Sumber: Diolah oleh penulis (2026)

Tabel IV.13 memperlihatkan perbedaan bentuk input model dan rincian parameter penting pada XGBoost. Random Forest dan XGBoost dilatih pada 1.460 observasi tabular, sedangkan LSTM dan GRU dilatih pada 1.446 sequence karena setiap input membutuhkan konteks 14 hari sebelumnya. Pada XGBoost, parameter scale_pos_weight dihitung dari rasio kelas negatif terhadap kelas positif pada data latih. Jumlah kelas negatif diperoleh dari 1.460 dikurangi 527 sehingga menghasilkan 933 observasi, sedangkan kelas positif berjumlah 527 observasi. Dengan demikian, nilai scale_pos_weight adalah 933 dibagi 527, yaitu 1,77. Nilai ini digunakan agar XGBoost lebih memperhatikan kelas Tidak Sehat+ yang jumlahnya lebih sedikit dibandingkan kelas Bukan Tidak Sehat+ pada data latih. File notebook pelatihan model dan output evaluasi awal dapat dilampirkan melalui tautan berikut:

[https://drive.google.com/file/d/1zoZmP6O0RCxMeGiFhYcaEb8zaPdGfwP4/view?usp=drive_link].

4.11. Evaluasi Model

Evaluasi model dilakukan pada data uji tahun 2024. Kelas positif dalam evaluasi ini adalah Tidak Sehat+. Metrik yang digunakan meliputi Precision, Recall, F1-Score, dan ROC-AUC. Precision menunjukkan proporsi prediksi Tidak Sehat+ yang benar, Recall menunjukkan kemampuan model menangkap seluruh kasus Tidak Sehat+, F1-Score menyeimbangkan Precision dan Recall, sedangkan ROC-AUC menunjukkan kemampuan model membedakan kelas berdasarkan probabilitas prediksi.

```
[18]
✓ 0s
    model_outputs = {
        "Random Forest": {"y_true": y_test.values, "y_pred": rf_pred, "y_proba": rf_proba},
        "XGBoost": {"y_true": y_test.values, "y_pred": xgb_pred, "y_proba": xgb_proba},
        "LSTM": {"y_true": y_test_seq, "y_pred": lstm_pred, "y_proba": lstm_proba},
        "GRU": {"y_true": y_test_seq, "y_pred": gru_pred, "y_proba": gru_proba},
    }

    results_df = pd.DataFrame([
        rf_result,
        xgb_result,
        lstm_result,
        gru_result,
    ]).sort_values(["F1-Score", "ROC-AUC", "Recall", "Precision"], ascending=False).reset_index(drop=True)

    save_table(results_df.round(6), "13_evaluasi_empat_model.csv")
    display(results_df.round(4))
```

Gambar IV. 25 Cuplikan Kode Python Evaluasi Model
Sumber: Notebook eksperimen, diolah oleh penulis (2026)

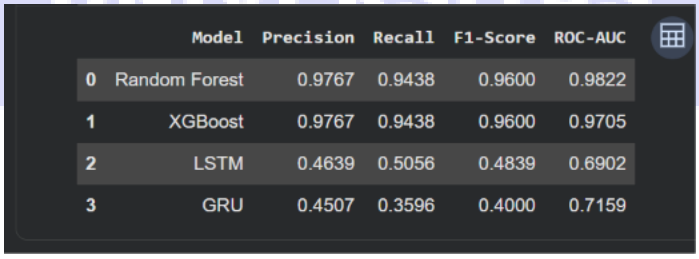
Kode pada Gambar IV.25 menyatukan target aktual, prediksi kelas, dan probabilitas kelas Tidak Sehat+ dari keempat model. Nilai tersebut digunakan untuk menghitung metrik evaluasi dan membentuk visualisasi pendukung seperti confusion matrix, grafik perbandingan performa, ROC curve, dan Precision-Recall curve. Dengan memusatkan evaluasi pada data uji 2024, hasil yang diperoleh tidak mencerminkan performa pada data latih, tetapi pada data yang tidak digunakan selama pelatihan model.

Tabel IV. 14 Hasil Evaluasi Kinerja Model

Model	Precision	Recall	F1-Score	ROC-AUC
Random Forest	84 / (84 + 2) = 0,9767	84 / (84 + 5) = 0,9438	2 × 0,9767 × 0,9438 / (0,9767 + 0,9438) = 0,9600	0,9822
XGBoost	84 / (84 + 2) = 0,9767	84 / (84 + 5) = 0,9438	2 × 0,9767 × 0,9438 / (0,9767 + 0,9438) = 0,9600	0,9705
LSTM	45 / (45 + 52) = 0,4639	45 / (45 + 44) = 0,5056	2 × 0,4639 × 0,5056 / (0,4639 + 0,5056) = 0,4839	0,6902
GRU	32 / (32 + 39) = 0,4507	32 / (32 + 57) = 0,3596	2 × 0,4507 × 0,3596 / (0,4507 + 0,3596) = 0,4000	0,7159

Sumber: Diolah oleh penulis (2026)

Tabel IV.14 menunjukkan bahwa Random Forest dan XGBoost memiliki Precision, Recall, dan F1-Score yang sama, yaitu Precision 0,9767, Recall 0,9438, dan F1-Score 0,9600. Perbedaan utama terletak pada ROC-AUC, yaitu Random Forest sebesar 0,9822 dan XGBoost sebesar 0,9705. LSTM memperoleh F1-Score 0,4839 dan ROC-AUC 0,6902, sedangkan GRU memperoleh F1-Score 0,4000 dan ROC-AUC 0,7159. Hasil ini menunjukkan bahwa model ensemble lebih stabil pada skema data tabular penelitian ini dibandingkan model sequence 14 hari yang digunakan oleh LSTM dan GRU.



	Model	Precision	Recall	F1-Score	ROC-AUC
0	Random Forest	0.9767	0.9438	0.9600	0.9822
1	XGBoost	0.9767	0.9438	0.9600	0.9705
2	LSTM	0.4639	0.5056	0.4839	0.6902
3	GRU	0.4507	0.3596	0.4000	0.7159

Gambar IV. 26 Screenshot Output Tabel Evaluasi Empat Model

Sumber: Diolah oleh penulis (2026)

Output pada Gambar IV.26 menjadi bukti langsung bahwa nilai evaluasi pada Tabel IV.14 berasal dari perhitungan notebook. Nilai Precision Random Forest dihitung dari true positive dibagi jumlah true positive dan false positive, yaitu 84 dibagi 86, sehingga

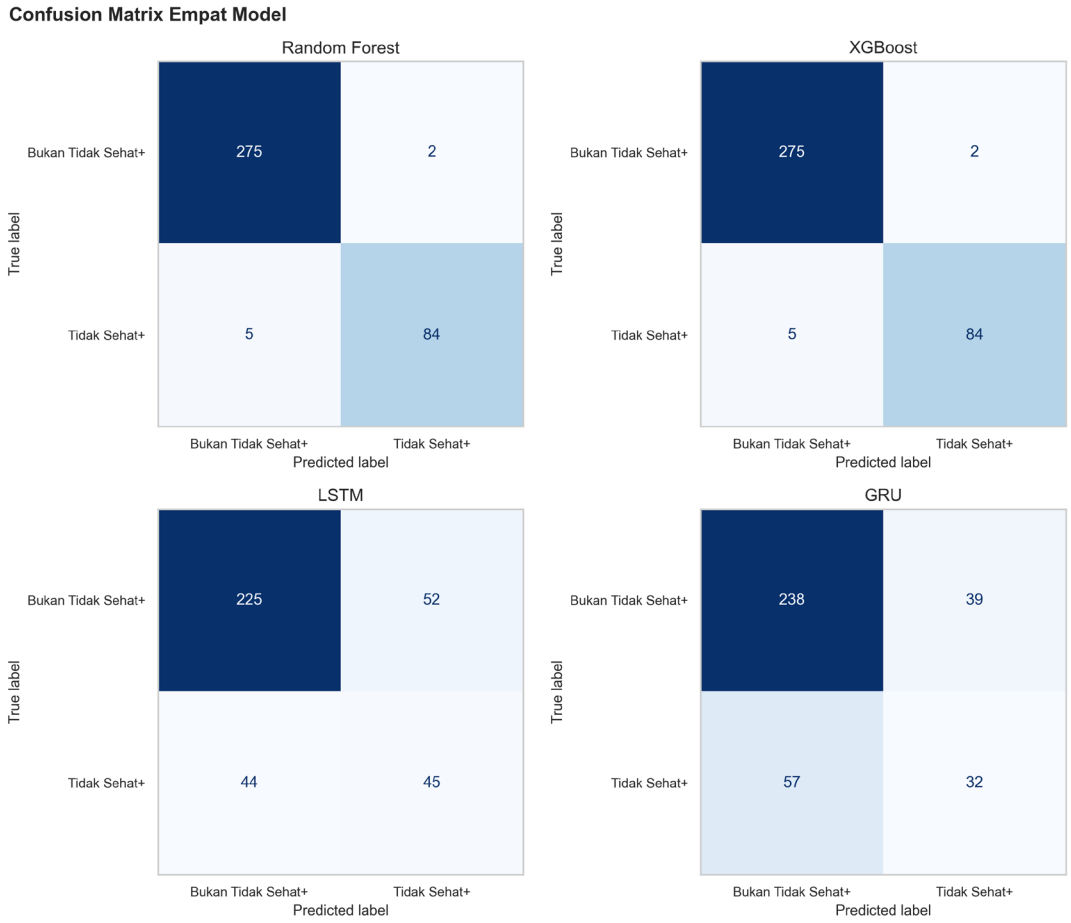
menghasilkan 0,9767. Nilai Recall dihitung dari true positive dibagi jumlah true positive dan false negative, yaitu 84 dibagi 89, sehingga menghasilkan 0,9438. F1-Score dihitung dari 2 dikalikan Precision dikalikan Recall, kemudian dibagi jumlah Precision dan Recall; 2 x 0,9767 x 0,9438 dibagi 1,9205 menghasilkan 0,9600.

Tabel IV. 15 Ringkasan Confusion Matrix Empat Model pada Data Uji 2024

Model	TN	FP	FN	TP	Precision	Recall	F1-Score
Random Forest	275	2	5	84	84 / (84 + 2) = 0,9767	84 / (84 + 5) = 0,9438	2PR / (P + R) = 0,9600
XGBoost	275	2	5	84	84 / (84 + 2) = 0,9767	84 / (84 + 5) = 0,9438	2PR / (P + R) = 0,9600
LSTM	225	52	44	45	45 / (45 + 52) = 0,4639	45 / (45 + 44) = 0,5056	2PR / (P + R) = 0,4839
GRU	238	39	57	32	32 / (32 + 39) = 0,4507	32 / (32 + 57) = 0,3596	2PR / (P + R) = 0,4000

Sumber: Diolah oleh penulis (2026)

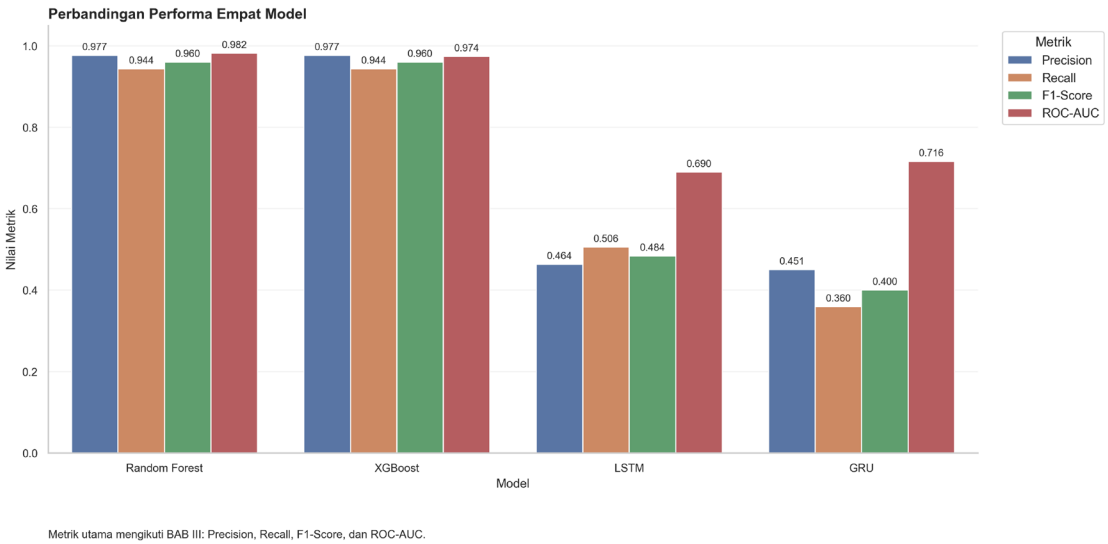
Tabel IV.15 memperlihatkan bahwa Random Forest dan XGBoost memiliki komposisi confusion matrix yang sama. Keduanya berhasil mengenali 84 hari Tidak Sehat+ dengan benar dan hanya gagal mengenali 5 hari Tidak Sehat+. Sebaliknya, LSTM dan GRU memiliki jumlah false negative yang lebih tinggi, yaitu 44 dan 57, sehingga lebih banyak hari Tidak Sehat+ yang tidak terdeteksi. Kondisi ini menjelaskan mengapa Recall dan F1-Score LSTM serta GRU lebih rendah dibandingkan model ensemble.



Gambar IV. 27 Screenshot Output Confusion Matrix Empat Model

Sumber: Diolah oleh penulis (2026)

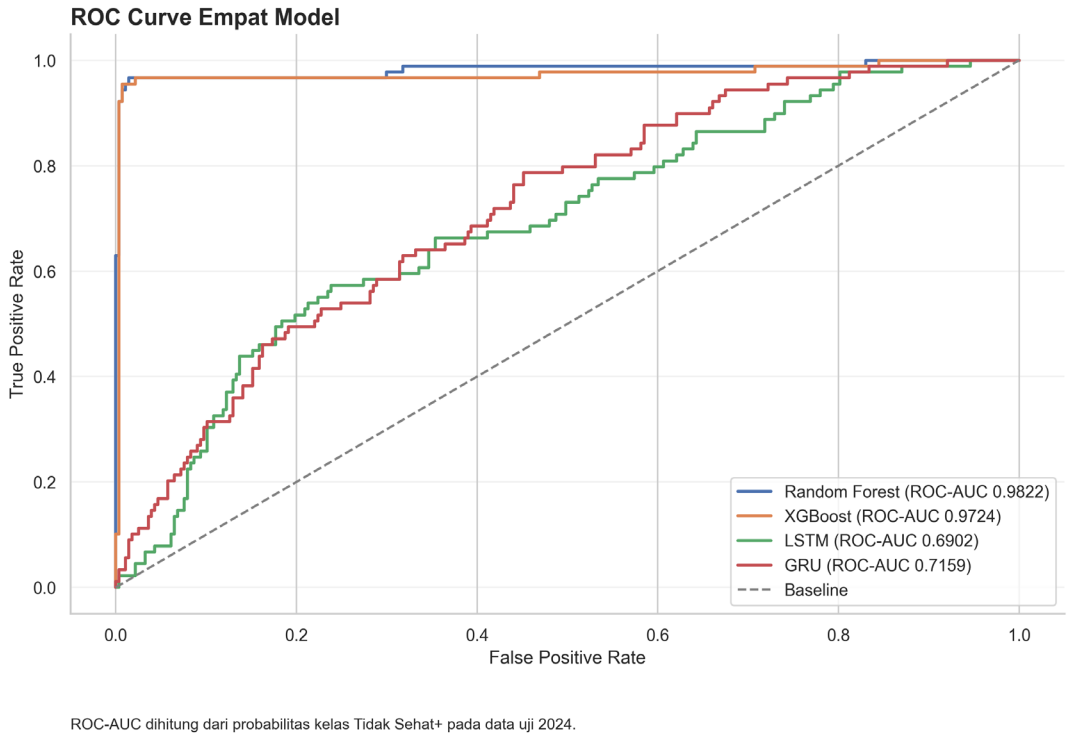
Gambar IV.27 memberikan visualisasi jumlah prediksi benar dan salah dari masing-masing model. Nilai diagonal menunjukkan prediksi benar, sedangkan nilai di luar diagonal menunjukkan kesalahan klasifikasi. Random Forest dan XGBoost menunjukkan pola kesalahan yang paling kecil pada data uji 2024, sedangkan LSTM dan GRU lebih sering mengalami kesalahan pada kelas positif Tidak Sehat+.



Gambar IV. 28 Screenshot Output Grafik Perbandingan Kinerja Model

Sumber: Diolah oleh penulis (2026)

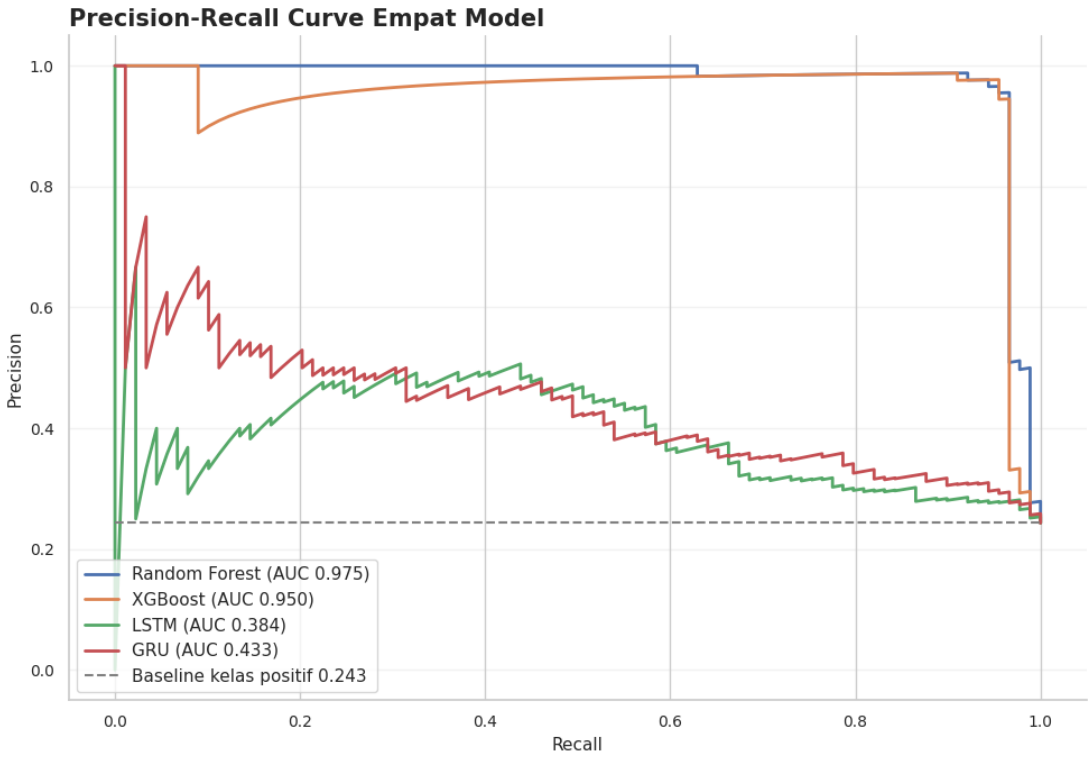
Grafik pada Gambar IV.28 memperjelas perbandingan antarmodel. Random Forest dan XGBoost memiliki batang Precision, Recall, dan F1-Score yang sangat tinggi dan hampir identik. LSTM dan GRU memiliki nilai metrik yang lebih rendah, terutama pada Recall dan F1-Score. Perbedaan ini menunjukkan bahwa pada rancangan eksperimen ini, pola tabular harian lebih mudah dimanfaatkan oleh model ensemble dibandingkan pola sequence 14 hari oleh model deep learning.



Gambar IV. 29 ROC Curve Empat Model pada Data Uji 2024

Sumber: Diolah oleh penulis (2026)

ROC curve pada Gambar IV.29 memperlihatkan kemampuan model membedakan kelas positif dan negatif berdasarkan probabilitas prediksi. Kurva Random Forest berada paling dekat dengan sudut kiri atas, yang menunjukkan kemampuan diskriminasi kelas paling baik. Hal ini sejalan dengan nilai ROC-AUC Random Forest sebesar 0,9822 pada tabel evaluasi.



Gambar IV. 30 Precision-Recall Curve Empat Model pada Data Uji 2024

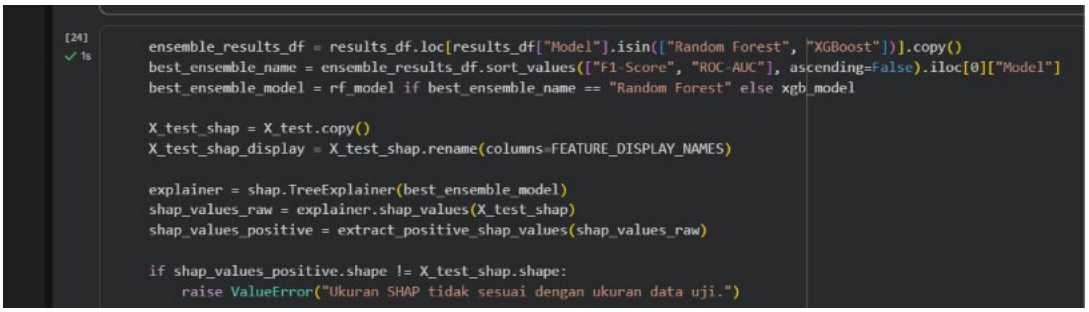
Sumber: Diolah oleh penulis (2026)

Precision-Recall curve pada Gambar IV.30 menjadi visual pendukung untuk membaca ketepatan dan kelengkapan prediksi kelas Tidak Sehat+. Kurva model ensemble menunjukkan area yang lebih baik dibandingkan LSTM dan GRU. Visual ini penting karena kelas positif Tidak Sehat+ merupakan kelas yang menjadi perhatian utama penelitian. File evaluasi model, confusion matrix, ROC curve, dan Precision-Recall curve dapat ditelusuri melalui tautan berikut: [https://drive.google.com/file/d/1hVLOx3vditU-Az9ONl9sWf8rLifsn9V2/view?usp=drive_link].

4.12. Pemilihan Model Terpilih

Setelah evaluasi model dilakukan, penelitian menetapkan model yang digunakan untuk interpretasi SHAP. Pemilihan model dilakukan pada kelompok model ensemble karena Random Forest dan XGBoost menunjukkan performa terbaik dibandingkan LSTM dan GRU.

Keduanya memiliki F1-Score yang sama, sehingga ROC-AUC digunakan sebagai pembeda utama dalam pemilihan model terpilih.



```
[24]
✓ 1s
    ensemble_results_df = results_df.loc[results_df["Model"].isin(["Random Forest", "XGBoost"])].copy()
    best_ensemble_name = ensemble_results_df.sort_values(["F1-Score", "ROC-AUC"], ascending=False).iloc[0]["Model"]
    best_ensemble_model = rf_model if best_ensemble_name == "Random Forest" else xgb_model

    X_test_shap = X_test.copy()
    X_test_shap_display = X_test_shap.rename(columns=FEATURE_DISPLAY_NAMES)

    explainer = shap.TreeExplainer(best_ensemble_model)
    shap_values_raw = explainer.shap_values(X_test_shap)
    shap_values_positive = extract_positive_shap_values(shap_values_raw)

    if shap_values_positive.shape != X_test_shap.shape:
        raise ValueError("Ukuran SHAP tidak sesuai dengan ukuran data uji.")
```

Gambar IV. 31 Cuplikan Kode Python Pemilihan Model untuk SHAP

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.31 memilih model ensemble berdasarkan F1-Score dan ROC-AUC. Karena Random Forest dan XGBoost memiliki F1-Score sama, yaitu 0,9600, model dengan ROC-AUC lebih tinggi dipilih sebagai model terpilih untuk SHAP. Dengan dasar tersebut, Random Forest dipilih karena memiliki ROC-AUC 0,9822, sedangkan XGBoost memiliki ROC-AUC 0,9705.

Tabel IV. 16 Dasar Pemilihan Model Terpilih

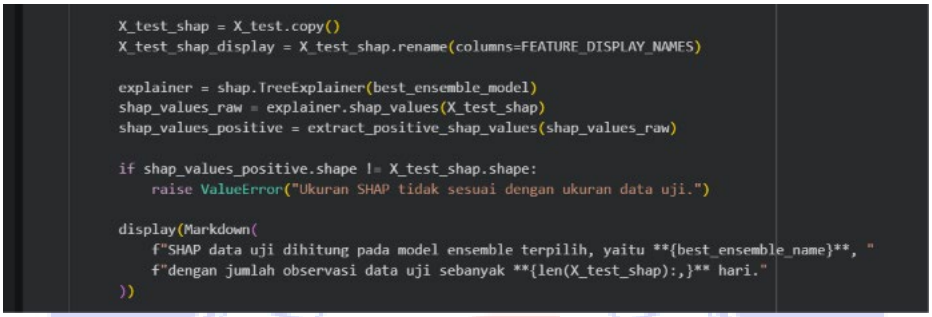
Model	F1-Score	ROC-AUC	Keputusan
Random Forest	0,9600	0,9822	Dipilih untuk interpretasi SHAP
XGBoost	0,9600	0,9724	Tidak dipilih karena ROC-AUC lebih rendah

Sumber: Diolah oleh penulis (2026)

Tabel IV.16 menunjukkan bahwa pemilihan Random Forest tidak berarti XGBoost memiliki performa buruk. Kedua model memiliki kinerja yang sangat dekat berdasarkan Precision, Recall, dan F1-Score. Namun, Random Forest dipilih karena nilai ROC-AUC yang lebih tinggi menunjukkan kemampuan diskriminasi kelas yang lebih baik pada data uji 2024. Output pemilihan model dan file pendukung SHAP dapat ditelusuri melalui tautan berikut: [https://drive.google.com/file/d/1hVLOx3voditUAz9ONl9sWf8rLifsn9V2/view?usp=drive_link].

4.13. Interpretasi SHAP Data Uji 2024

Interpretasi SHAP dilakukan untuk menjelaskan kontribusi fitur terhadap keputusan Random Forest pada data uji 2024. SHAP digunakan karena mampu memberikan ukuran kontribusi fitur pada setiap observasi dan merangkumnya menjadi kontribusi rata-rata. Interpretasi SHAP dalam penelitian ini bersifat penjelasan keputusan model, bukan bukti hubungan sebab-akibat lingkungan.



```
X_test_shap = X_test.copy()
X_test_shap_display = X_test_shap.rename(columns=FEATURE_DISPLAY_NAMES)

explainer = shap.TreeExplainer(best_ensemble_model)
shap_values_raw = explainer.shap_values(X_test_shap)
shap_values_positive = extract_positive_shap_values(shap_values_raw)

if shap_values_positive.shape != X_test_shap.shape:
    raise ValueError("Ukuran SHAP tidak sesuai dengan ukuran data uji.")

display(Markdown(
    f"SHAP data uji dihitung pada model ensemble terpilih, yaitu **{best_ensemble_name}**, "
    f"dengan jumlah observasi data uji sebanyak **{len(X_test_shap):,}** hari."
))
```

Gambar IV. 32 Cuplikan Kode Python SHAP Data Uji 2024

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.32 menghitung nilai SHAP menggunakan model Random Forest yang telah dipilih. Nilai SHAP dihitung pada data uji 2024, kemudian nilai absolut SHAP dirata-ratakan untuk setiap fitur. Hasil rata-rata absolut ini disebut mean absolute SHAP dan digunakan untuk mengetahui fitur yang paling berkontribusi terhadap keputusan model.

Tabel IV. 17 Ringkasan Mean Absolute SHAP Data Uji 2024

Peringkat	Fitur	Rumus Perhitungan	Mean Absolute SHAP
1	PM2.5	Σ|SHAP PM2.5| / 366	0,323157
2	PM10	Σ|SHAP PM10| / 366	0,083515
3	O3	Σ|SHAP O3| / 366	0,047695
4	CO	Σ|SHAP CO| / 366	0,026628
5	NO2	Σ|SHAP NO2| / 366	0,023424
6	SO2	Σ|SHAP SO2| / 366	0,013650
7	Indikator Missing PM2.5	Σ|SHAP indikator PM2.5| / 366	0,008758

Peringkat	Fitur	Rumus Perhitungan	Mean Absolute SHAP
8	Bulan	Σ|SHAP bulan| / 366	0,007862
9	Tahun	Σ|SHAP tahun| / 366	0,007825
10	Indikator Missing PM10	Σ|SHAP indikator PM10| / 366	0,005726

Sumber: Diolah oleh penulis (2026)

Tabel IV.17 menunjukkan bahwa PM2.5 memiliki kontribusi rata-rata terbesar terhadap keputusan Random Forest pada data uji 2024, yaitu 0,323157. Nilai mean absolute SHAP PM2.5 dihitung dengan menjumlahkan nilai absolut SHAP PM2.5 pada seluruh 366 observasi data uji, kemudian membaginya dengan 366. Nilai ini bukan persentase, melainkan rata-rata kontribusi absolut fitur terhadap output model. PM10 berada pada peringkat kedua dengan nilai 0,083515, diikuti O3 sebesar 0,047695, CO sebesar 0,026628, NO2 sebesar 0,023424, dan SO2 sebesar 0,013650. Hasil ini menunjukkan bahwa keputusan model Random Forest paling banyak dipengaruhi oleh informasi PM2.5 pada data uji 2024.

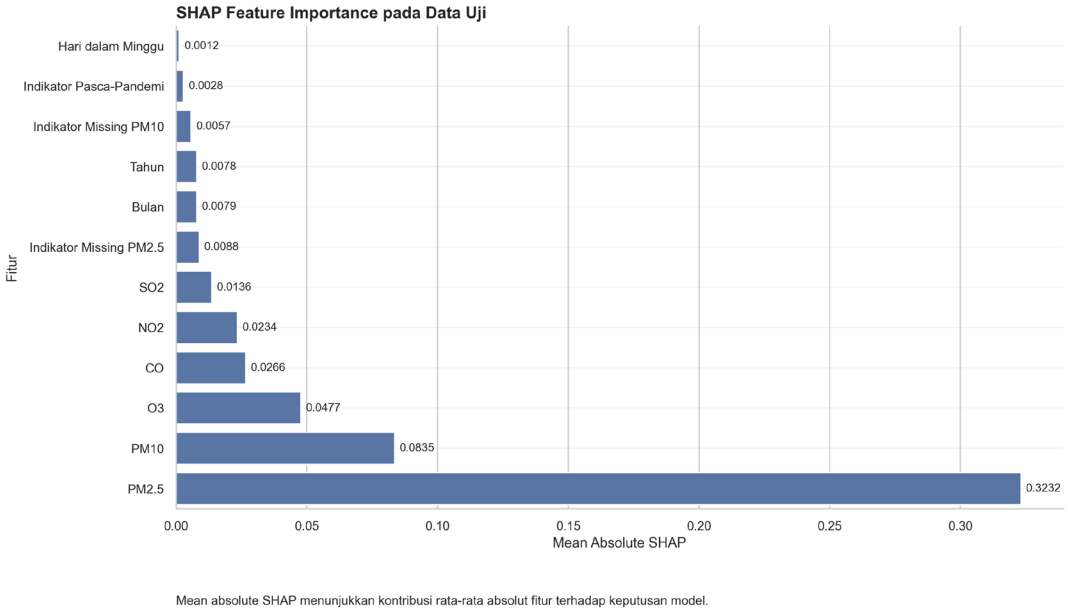


	Peringkat	Fitur	Nama Tampilan	Mean Absolute SHAP
0	1	pm25	PM2.5	0.323157
1	2	pm10	PM10	0.083515
2	3	o3	O3	0.047695
3	4	co	CO	0.026628
4	5	no2	NO2	0.023424
5	6	so2	SO2	0.013650
6	7	pm25_was_missing	Indikator Missing PM2.5	0.008758
7	8	bulan	Bulan	0.007862
8	9	tahun	Tahun	0.007825
9	10	pm10_was_missing	Indikator Missing PM10	0.005726
10	11	is_pasca_pandemi	Indikator Pasca-Pandemi	0.002825
11	12	hari_dalam_minggu	Hari dalam Minggu	0.001205

Gambar IV. 33 Screenshot Output Tabel Mean Absolute SHAP Data Uji 2024

Sumber: Diolah oleh penulis (2026)

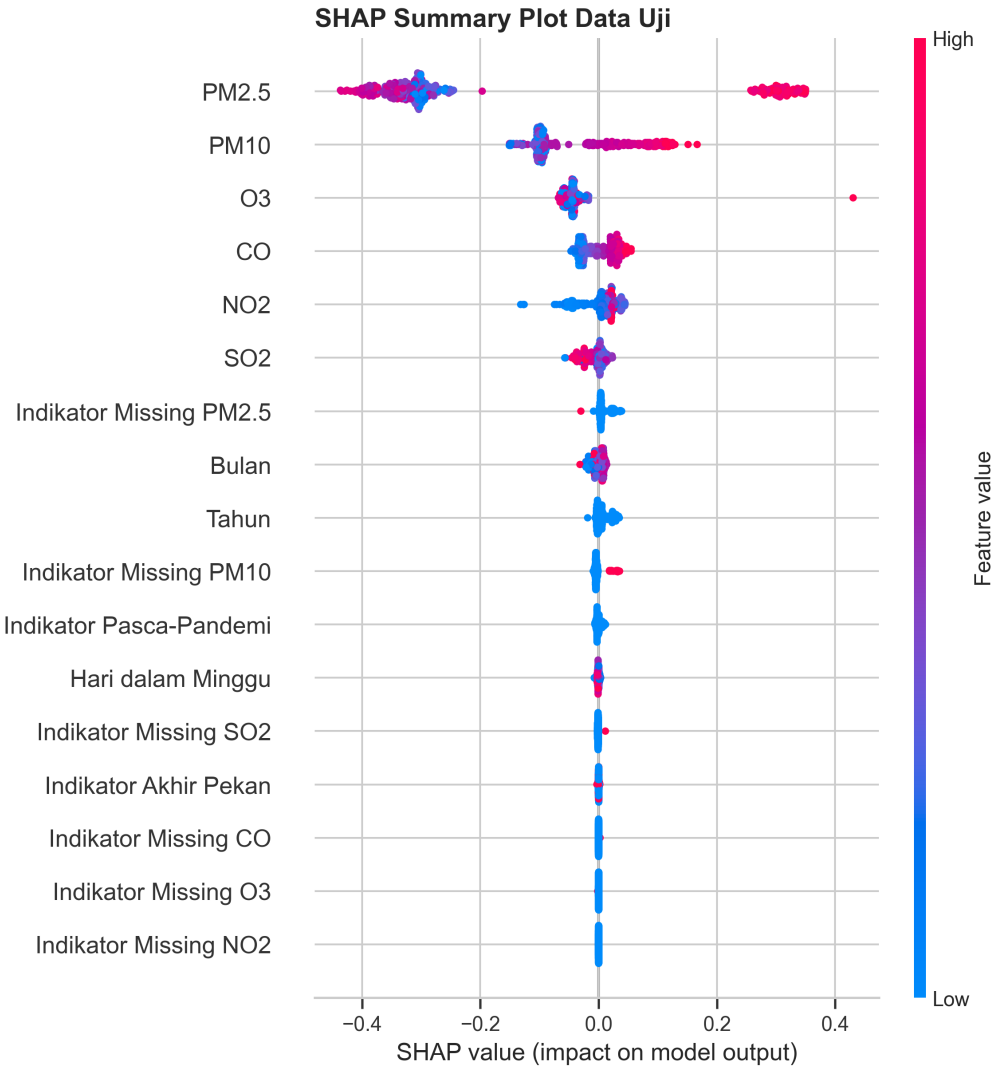
Gambar IV.33 memperlihatkan output notebook yang menjadi dasar penyusunan Tabel IV.17. Output tersebut menampilkan peringkat fitur, nama fitur, nama tampilan, dan nilai mean absolute SHAP.



Gambar IV. 34 SHAP Feature Importance pada Data Uji 2024

Sumber: Diolah oleh penulis (2026)

Gambar IV.34 menampilkan peringkat kontribusi fitur dalam bentuk grafik batang. Panjang batang menunjukkan besar mean absolute SHAP. PM2.5 tampak jauh lebih dominan dibandingkan fitur lain, sedangkan PM10 dan O3 berada di bawahnya. Visualisasi ini memperkuat pembacaan tabel bahwa partikulat halus PM2.5 menjadi fitur paling penting dalam keputusan Random Forest pada data uji 2024.



Gambar IV. 35 SHAP Summary Plot Data Uji 2024

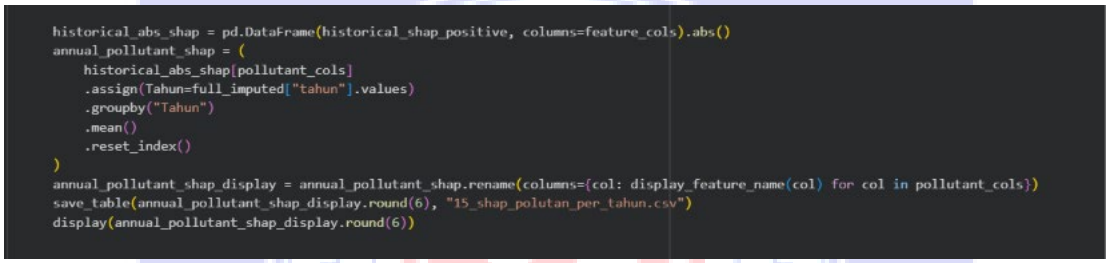
Sumber: Diolah oleh penulis (2026)

SHAP summary plot pada Gambar IV.35 memperlihatkan sebaran nilai SHAP setiap fitur pada seluruh observasi data uji. Titik yang berada ke arah kanan menunjukkan kontribusi yang mendorong prediksi ke kelas Tidak Sehat+, sedangkan titik yang berada ke arah kiri menunjukkan kontribusi yang mendorong prediksi ke kelas Bukan Tidak Sehat+. Warna titik menunjukkan nilai fitur, sehingga visual ini tidak hanya menggambarkan besar kontribusi rata-rata, tetapi juga arah pengaruh fitur terhadap keputusan model. File tabel SHAP dan gambar SHAP data uji dapat ditelusuri melalui tautan berikut: [https://drive.google.com/file/d/1DvP06zBKEjjPPzN5NsK9e7JmFEn8QSt9/view?usp=drive_link] dan

[https://drive.google.com/file/d/11kpDXnW5NX7hGmKzZgJJDV1uZ21PpQTY/view?usp=drive_link].

4.14. Interpretasi SHAP Historis 2020-2024

Interpretasi SHAP historis dilakukan untuk membaca pola kontribusi polutan dari tahun 2020 sampai 2024. Analisis ini bersifat diagnostik retrospektif karena model dilatih pada data periode 2020-2024 yang telah diimputasi untuk melihat kontribusi rata-rata polutan per tahun. Dengan demikian, hasil SHAP historis digunakan untuk memahami perubahan pola kontribusi fitur antar tahun, bukan sebagai evaluasi performa generalisasi model pada data baru.

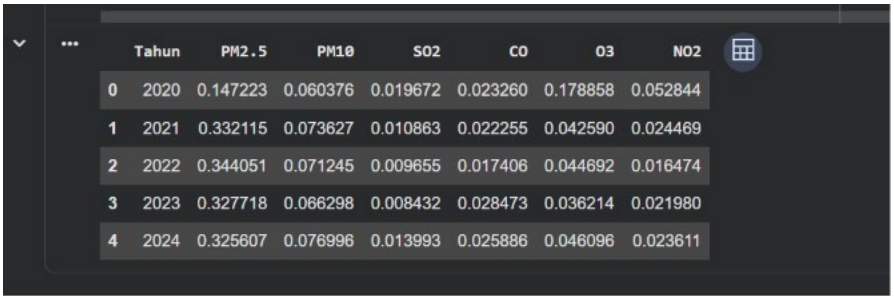


```
historical_abs_shap = pd.DataFrame(historical_shap_positive, columns=feature_cols).abs()
annual_pollutant_shap = (
    historical_abs_shap[pollutant_cols]
    .assign(Tahun=full_imputed["tahun"].values)
    .groupby("Tahun")
    .mean()
    .reset_index()
)
annual_pollutant_shap_display = annual_pollutant_shap.rename(columns={col: display_feature_name(col) for col in pollutant_cols})
save_table(annual_pollutant_shap_display.round(6), "15_shap_polutan_per_tahun.csv")
display(annual_pollutant_shap_display.round(6))
```

Gambar IV. 36 Cuplikan Kode Python SHAP Historis 2020-2024

Sumber: Notebook eksperimen, diolah oleh penulis (2026)

Kode pada Gambar IV.36 menghitung mean absolute SHAP tahunan untuk enam polutan. Nilai SHAP absolut dikelompokkan berdasarkan tahun, kemudian dirata-ratakan untuk setiap polutan. Hasil pengelompokan tersebut digunakan untuk menentukan polutan dominan dan polutan kedua pada setiap tahun.



	Tahun	PM2.5	PM10	SO2	CO	O3	NO2
0	2020	0.147223	0.060376	0.019672	0.023260	0.178858	0.052844
1	2021	0.332115	0.073627	0.010863	0.022255	0.042590	0.024469
2	2022	0.344051	0.071245	0.009655	0.017406	0.044692	0.016474
3	2023	0.327718	0.066298	0.008432	0.028473	0.036214	0.021980
4	2024	0.325607	0.076996	0.013993	0.025886	0.046096	0.023611

Ringkasan Dominasi SHAP Historis

Tahun	Polutan Dominan	Mean Absolute SHAP	Polutan Kedua	Mean Absolute SHAP Kedua
2020	O3	0.178858	PM2.5	0.147223
2021	PM2.5	0.332115	PM10	0.073627
2022	PM2.5	0.344051	PM10	0.071245
2023	PM2.5	0.327718	PM10	0.066298
2024	PM2.5	0.325607	PM10	0.076996

Gambar IV. 37 Screenshot Output Tabel Dominasi SHAP Historis

Sumber: Diolah oleh penulis (2026)

Gambar IV.37 memperlihatkan output tabel dominasi SHAP historis. Output ini menunjukkan polutan dengan nilai mean absolute SHAP tertinggi dan kedua tertinggi pada setiap tahun. Dengan menampilkan output notebook, pembahasan historis tetap dapat ditelusuri ke proses komputasi yang menghasilkan angka tersebut.

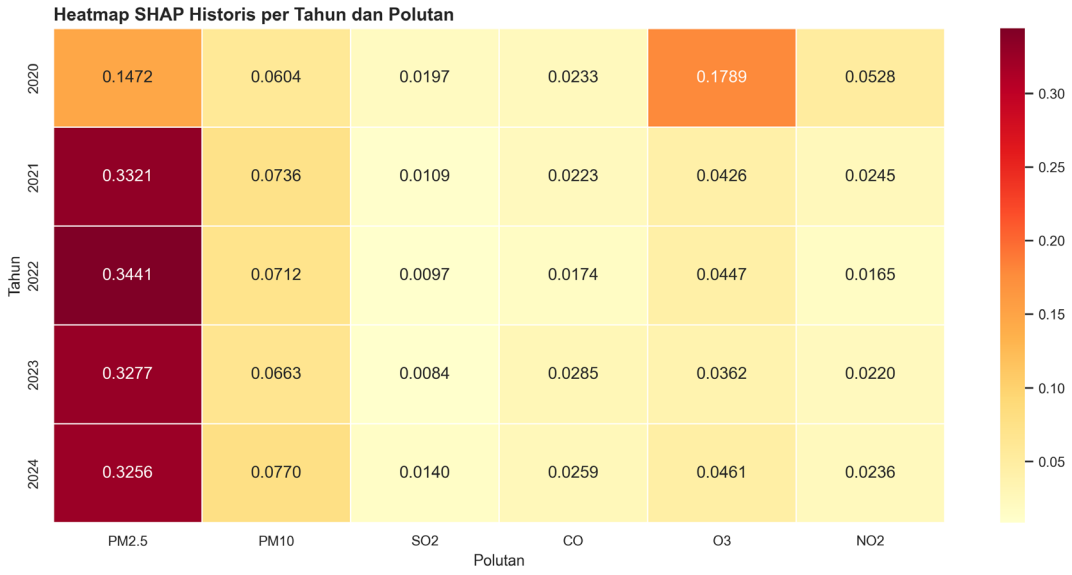
Tabel IV. 18 Ringkasan Dominasi SHAP Historis 2020-2024

Tahun	Polutan Dominan	Mean Absolute SHAP	Polutan Kedua	Mean Absolute SHAP Kedua
2020	O3	0,178858	PM2.5	0,147223
2021	PM2.5	0,332115	PM10	0,073627
2022	PM2.5	0,344051	PM10	0,071245
2023	PM2.5	0,327718	PM10	0,066298
2024	PM2.5	0,325607	PM10	0,076996

Sumber: Diolah oleh penulis (2026)

Tabel IV.18 menunjukkan bahwa O3 menjadi polutan dominan pada tahun 2020 dengan mean absolute SHAP sebesar 0,178858, sedangkan PM2.5 menjadi polutan kedua dengan nilai 0,147223. Pada tahun 2021 sampai 2024, PM2.5 menjadi polutan dominan secara konsisten.

Nilai PM2.5 pada tahun 2021 adalah 0,332115, tahun 2022 sebesar 0,344051, tahun 2023 sebesar 0,327718, dan tahun 2024 sebesar 0,325607. PM10 menjadi polutan kedua pada tahun 2021 sampai 2024. Pola ini menunjukkan bahwa PM2.5 memiliki kontribusi paling kuat dalam keputusan model pada sebagian besar periode penelitian.



Gambar IV. 38 Gambar IV.38 Heatmap SHAP Historis per Tahun dan Polutan

Sumber: Diolah oleh penulis (2026)

Heatmap pada Gambar IV.38 memperjelas perbedaan kontribusi polutan antar tahun. Warna yang lebih pekat menunjukkan nilai mean absolute SHAP yang lebih besar. PM2.5 tampak dominan pada tahun 2021 sampai 2024, sedangkan O3 menjadi fitur paling dominan pada tahun 2020. Interpretasi tahun 2020 perlu dibaca secara hati-hati karena PM2.5 pada tahun tersebut memiliki missing values penuh sebelum imputasi. Oleh karena itu, kontribusi PM2.5 tahun 2020 tidak dapat dipahami sebagai observasi asli sepenuhnya, tetapi sebagai hasil pembacaan model setelah proses imputasi. File SHAP historis dapat ditelusuri melalui tautan berikut:[https://drive.google.com/file/d/1SYgjbtdqx8U8dpPRyJSkUKNq0xsmHHN/view?usp=sharing].

BAB V

PENUTUP

5.1. Kesimpulan

Berdasarkan hasil penelitian, model klasifikasi biner ISPU DKI Jakarta periode 2020-2024 berhasil dikembangkan untuk membedakan kelas Tidak Sehat+ dan Bukan Tidak Sehat+. Data final berjumlah 1.826 observasi dan dibagi secara kronologis menjadi data latih 2020-2023 serta data uji 2024.

Hasil evaluasi menunjukkan bahwa model ensemble lebih unggul dibandingkan model pembelajaran mendalam pada rancangan eksperimen ini. Random Forest memperoleh Precision 0,9767, Recall 0,9438, F1-Score 0,9600, dan ROC-AUC 0,9822. XGBoost memiliki F1-Score sama, tetapi ROC-AUC lebih rendah, sedangkan LSTM dan GRU menunjukkan performa yang lebih kecil pada input sekuens 14 hari.

Random Forest dipilih sebagai model terpilih untuk interpretasi SHAP. Hasil SHAP menunjukkan bahwa PM2.5 menjadi fitur paling dominan pada data uji 2024, diikuti PM10, O3, CO, NO2, dan SO2. Secara historis, PM2.5 dominan pada 2021-2024, sedangkan O3 dominan pada 2020. Dengan demikian, H1(1) dan H1(2) diterima karena terdapat perbedaan kinerja model dan kontribusi fitur yang dominan.

5.2. Saran

Berdasarkan hasil penelitian dan batas interpretasi yang telah dijelaskan, penelitian selanjutnya disarankan untuk menambahkan variabel meteorologi seperti suhu, kelembapan, curah hujan, arah angin, dan kecepatan angin. Variabel tersebut dapat memperkaya konteks analisis karena kualitas udara tidak hanya dipengaruhi oleh konsentrasi polutan, tetapi juga oleh kondisi cuaca dan dinamika atmosfer. Penambahan variabel meteorologi juga dapat membantu menjelaskan pola kontribusi fitur yang tidak sepenuhnya dapat ditangkap oleh fitur polutan dan fitur waktu pada dataset utama.

Penelitian selanjutnya juga disarankan untuk memperkuat kualitas data, khususnya pada parameter yang memiliki missing values besar. Pada penelitian ini, PM2.5 tahun 2020 memiliki nilai kosong penuh sebelum imputasi. Oleh karena itu, penelitian berikutnya dapat menggunakan sumber data tambahan atau mekanisme validasi data yang lebih rinci agar interpretasi pada periode dengan missing values besar dapat dilakukan dengan lebih kuat.

Untuk model deep learning, penelitian berikutnya dapat menguji variasi panjang jendela waktu selain 14 hari, misalnya 7 hari, 21 hari, atau 30 hari. Pengujian beberapa ukuran window dapat membantu menentukan apakah pola temporal kualitas udara lebih sesuai dibaca dalam rentang pendek atau panjang. Selain itu, tuning hyperparameter dan penggunaan arsitektur lain seperti Bidirectional LSTM, Attention, atau Transformer berbasis time series dapat dipertimbangkan untuk mengevaluasi kemampuan model deep learning secara lebih luas.

Pengembangan berikutnya juga dapat menerapkan time series cross-validation atau pengujian pada periode data yang lebih panjang. Strategi tersebut dapat membantu menilai stabilitas model ketika digunakan pada periode yang berbeda. Apabila data setelah tahun 2024 telah tersedia dalam satu tahun penuh, data tersebut dapat digunakan sebagai periode uji tambahan untuk mengevaluasi kemampuan generalisasi model.

Penelitian selanjutnya dapat mempertimbangkan analisis berbasis stasiun pemantauan. Dalam penelitian ini, kolom stasiun tidak digunakan sebagai fitur karena penelitian memosisikan data sebagai deret harian ISPU DKI Jakarta secara umum, bukan sebagai perbandingan antarstasiun. Analisis berbasis stasiun dapat memberikan pemahaman yang lebih rinci mengenai perbedaan pola kontribusi polutan pada lokasi pemantauan yang berbeda.

Dari sisi interpretabilitas, penggunaan SHAP dapat dikembangkan dengan analisis yang lebih mendalam, misalnya dengan membandingkan kontribusi fitur antarperiode pandemi, transisi, dan pasca-pandemi, atau dengan membaca kontribusi fitur berdasarkan musim dan

karakter waktu tertentu. Namun, interpretasi SHAP tetap perlu dibatasi sebagai penjelasan terhadap keputusan model, bukan bukti kausalitas lingkungan.

Terakhir, hasil penelitian ini dapat dijadikan dasar awal pengembangan sistem pendukung keputusan kualitas udara yang tidak hanya menampilkan hasil klasifikasi Tidak Sehat+ atau Bukan Tidak Sehat+, tetapi juga memberikan penjelasan mengenai fitur yang memengaruhi keputusan model. Dengan pendekatan tersebut, model klasifikasi kualitas udara dapat menjadi lebih transparan, lebih mudah dipahami, dan lebih informatif bagi peneliti maupun pihak yang berkepentingan dalam pemantauan kualitas udara perkotaan.

BINA SARANA INFORMATIKA
UNIVERSITAS

DAFTAR PUSTAKA

Agbehadji, I. E., & Obagbuwa, I. C. (2025). Explainable Artificial Intelligence and Machine Learning for Air Pollution Risk Assessment and Respiratory Health Outcomes: A Systematic Review. In *Atmosphere* (Vol. 16, Number 10). Multidisciplinary Digital Publishing Institute (MDPI). https://doi.org/10.3390/atmos16101154

Awasthi, Amit., Pattnayak, K. Charan., Dhiman, Gaurav., & Tiwari, P. Raj. (2025). *Artificial intelligence for air quality monitoring and prediction*. CRC Press. https://doi.org/https://doi.org/10.1201/9781032683805

Banjarnahor, E., Belferik, R., Cendana, W., Adi, Y., & Abraham, S. (2025). Analisis Implementasi Support Vector Machine dan Random Forest untuk Prediksi Kategori Indeks Kualitas Udara Jakarta. *Jurnal INSTEK (Informatika Sains Dan Teknologi)*, *10*(1), 2541–1179. https://www.researchgate.net/profile/Wiputra-Cendana/publication/392528848_ANALISIS_IMPLEMENTASI_SUPPORT_VECTOR_MACHINE_DAN_RANDOM_FOREST_UNTUK_PREDIKSI_KATEGORI_INDEKS_KUALITAS_UDARA_JAKARTA/links/684785878a76251f22ec92ab/ANALISIS-IMPLEMENTASI-SUPPORT-VECTOR-MACHINE-DAN-RANDOM-FOREST-UNTUK-PREDIKSI-KATEGORI-INDEKS-KUALITAS-UDARA-JAKARTA.pdf

Bhattacharya, Aditya. (2022). *Applied Machine Learning Explainability Techniques*. https://ieeexplore.ieee.org/document/10162818

Fahim, A., Osman, A. M., Tarek, Z., & Elshewey, A. M. (2025). Enhancing Air Quality Index Classification Based on Ensemble Machine Learning Techniques. *Engineering, Technology and Applied Science Research*, *15*(6), 29325–29333. https://doi.org/10.48084/etasr.13875

Hasna, H., Nonong Amalita, Dony Permana, & Admi Salma. (2024). Random Forest Implementation for Air Pollution Standard Index Classification in DKI Jakarta 2022. *UNP Journal of Statistics and Data Science*, *2*(2), 226–233. https://doi.org/10.24036/ujsds/vol2-iss2/173

Jalali, M. W., Saidi, B., Farahmand, H., Panah, M. A. R., & Saruhan, E. N. (2025). Scalable AI-driven air quality forecasting and classification for public health applications. *Discover Atmosphere*, *3*(1). https://doi.org/10.1007/s44292-025-00052-8

Karmoude, M., Munhungewarwa, B., Chiraira, I., Mckenzie, R., Kong, J., Smith, B., Ayana, G., Njara, N., Mathaha, T., Kumar, M., & Mellado, B. (2025). Machine learning for air quality prediction and data analysis: Review on recent advancements, challenges, and outlooks. *Science of the Total Environment*, *1002*. https://doi.org/10.1016/j.scitotenv.2025.180593

Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia. (2020). *Peraturan Menteri Lingkungan Hidup dan Kehutanan Nomor 14 Tahun 2020 tentang Indeks Standar Pencemar Udara*. Database Peraturan BPK RI. https://peraturan.bpk.go.id/Details/163466/permen-lhk-no-14-tahun-2020

Klosterman, Stephen. (2021). *Data science projects with Python : a case study approach to gaining valuable insights from real data with machine learning*. Packt Publishing. https://books.google.co.id/books?id=dN06EAAAQBAJ&printsec=frontcover&hl=id&source=gbs_ge_summary_r&cad=0#v=onepage&q&f=false

Liu, Q., Cui, B., & Liu, Z. (2024). Air Quality Class Prediction Using Machine Learning Methods Based on Monitoring Data and Secondary Modeling. *Atmosphere*, *15*(5). https://doi.org/10.3390/atmos15050553

Pemerintah Provinsi DKI Jakarta. (2025). *Data Indeks Standar Pencemar Udara (ISPU) Provinsi DKI Jakarta*. Portal Satu Data Indonesia / Satu Data Jakarta. https://satudata.jakarta.go.id/open-data/detail?kategori=dataset&page_url=data-indeks-standar-pencemar-udara-ispu-di-provinsi-dki-jakarta&data_no=1

Radjabaycolle, J. E. T., Wattimena, E. M. C., & Pattiradjawane, V. E. (2025). Improving Air Quality Forecasts with LSTM and SHAP Explainability: A Case Study in Jakarta. *Journal of Embedded System Security and Intelligent Systems*, *6*(3), 337–347. https://journal.unm.ac.id/index.php/JESSI/article/view/9512

Rajagukguk, I. M., Hartanto, R., Julian, & Halim, R. (2025). Comparative Analysis of XGBoost, Random Forest, and Logistic Regression for Classifying Jakarta's Air Pollution Index (ISPU). *Procedia Computer Science*, *269*, 108–120. https://doi.org/10.1016/j.procs.2025.08.264

Sajiwo, A. F. B., Rahmat, B., & Junaidi, A. (2024). KLASIFIKASI INDEKS STANDAR PENCEMARAN UDARAN (ISPU) MENGGUNAKAN ALGORITMA XGBOOST DENGAN TEKNIK IMBALANCED DATA (SMOTE). *Jurnal Informatika Dan Teknik Elektro Terapan*, *12*(3). https://doi.org/10.23960/jitet.v12i3.4699

Thampi, Ajay. (2022). *Interpretable AI : building explainable machine learning systems*. Manning Publications Co. https://ieeexplore.ieee.org/document/10280544

VASILEV, IVAN. (2023). *PYTHON DEEP LEARNING - THIRD EDITION exploring deep learning techniques and neural network... architectures with pytorch*. PACKT PUBLISHING LIMITED. https://books.google.co.id/books/about/Python_Deep_Learning.html?id=-OPgEAAAQBAJ&redir_esc=y

Yenkikar, A., Mishra, V. P., Bali, M., & Ara, T. (2025). Explainable forecasting of air quality index using a hybrid random forest and ARIMA model. *MethodsX*, *15*. https://doi.org/10.1016/j.mex.2025.103517

DAFTAR RIWAYAT HIDUP

I. Biodata Mahasiswa

NIM : 17220785

Nama Lengkap : Eriel Setiawan Dewantoro

Tempat/ Tanggal Lahir : Bekasi, 18 Desember 2004

Alamat Lengkap : Jl. Raya AL Jatimakmur, RT 001/RW 009, Jatimakmur, Pondok Gede, Bekasi, Jawa Barat

II. Pendidikan

a. formal

1. SDN Jatiwarigin I, lulus tahun 2016
2. SMPN 06 Bekasi, lulus tahun 2019
3. SMAN 21 Bekasi, lulus tahun 2022

III. Riwayat Pengalaman Organisasi/Pekerjaan

1. Tennis Circle Jakarta – Operations & Member Relations

Bekasi, 7 Juli 2026



Eriel Setiawan Dewantoro

SURAT PERNYATAAN KEBENARAN/KEABSAHAN DATA HASIL RISET UNTUK KARYA ILMIAH

Yang bertanda tangan di bawah ini, saya:

Nama	: Eriel Setiawan Dewantoro
NIM	17220785
Jenjang	: Sarjana (S1)
Program Studi	: Teknologi Informasi
Fakultas	: Fakultas Teknik dan Informatika
Perguruan Tinggi	: Universitas Bina Sarana Informatika

Dengan ini menyatakan bahwa data dan informasi yang saya gunakan dalam penulisan karya ilmiah dengan judul "ANALISIS PERBANDINGAN KINERJA MODEL *ENSEMBLE* DAN *DEEP LEARNING* UNTUK KLASIFIKASI ISPU JAKARTA MENGGUNAKAN EXPLAINABLE AI (SHAP)" merupakan data atau informasi yang saya peroleh melalui hasil penelitian sendiri dan tidak didasarkan pada data dan informasi hasil riset dari perusahaan/instansi/lembaga manapun.

Saya bersedia untuk bertanggung jawab secara pribadi, tanpa melibatkan pihak Universitas Bina Sarana Informatika, atas materi/isi karya ilmiah tersebut, termasuk bertanggung jawab atas dampak atau kerugian yang timbul dalam bentuk akibat tindakan yang berkaitan dengan data dan atau informasi yang terdapat pada karya ilmiah saya ini.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Bekasi
Pada tanggal : 7 Juli 2026

Yang Menyatakan,

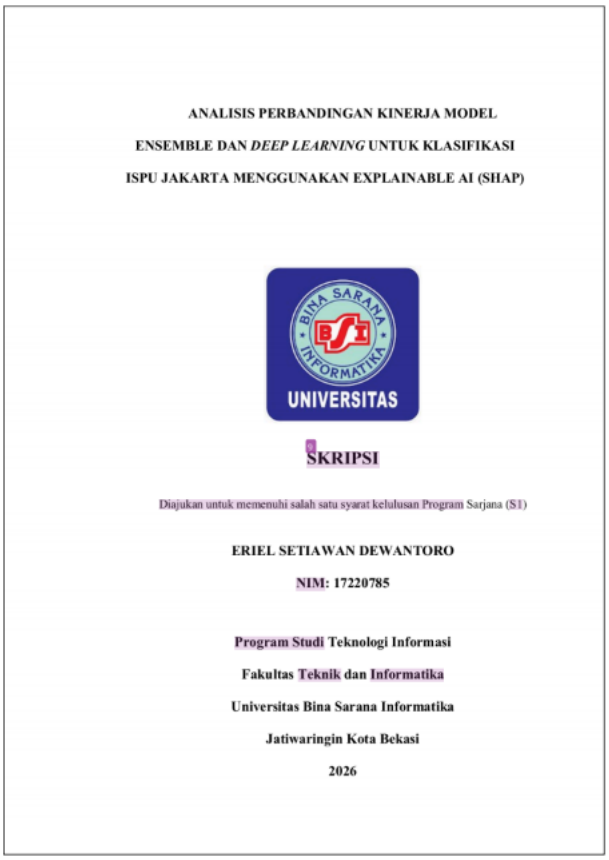
Dosen Pembimbing I

Ditandatangani Digital:
Suharjanti
2026-07-08 10:21:31

Suharjanti, M.Kom

Eriel Setiawan Dewantoro

BUKTI HASIL PENGECEKAN PLAGIARISME



ANALISIS PERBANDINGAN KINERJA MODEL
ENSEMBLE DAN *DEEP LEARNING* UNTUK KLASIFIKASI
ISPU JAKARTA MENGGUNAKAN EXPLAINABLE AI (SHAP)

UNIVERSITAS

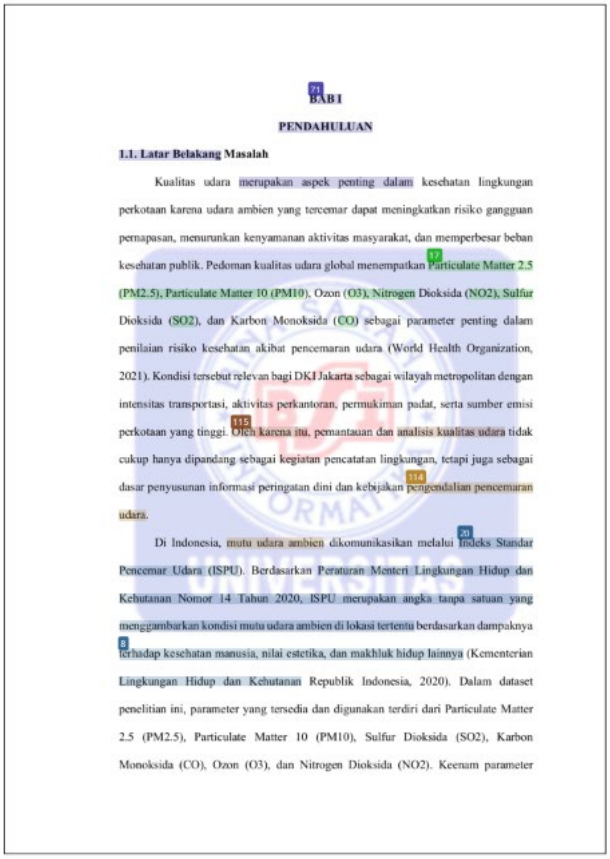
SKRIPSI

Diajukan untuk memenuhi salah satu syarat kelulusan Program Sarjana (S1)

ERIEL SETIAWAN DEWANTORO

NIM: 17220785

Program Studi Teknologi Informasi
Fakultas Teknik dan Informatika
Universitas Bina Sarana Informatika
Jatiwaringin Kota Bekasi
2026



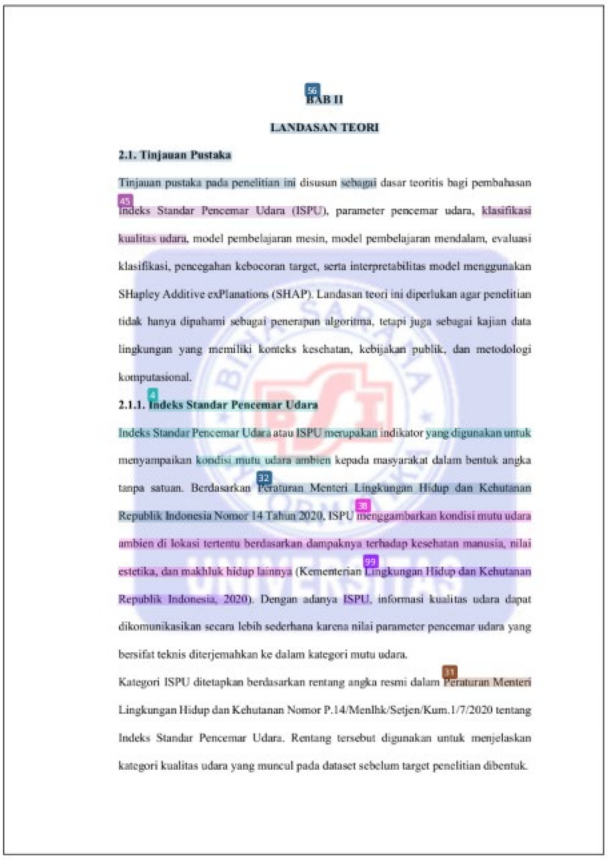
BAB I

PENDAHULUAN

1.1. Latar Belakang Masalah

Kualitas udara merupakan aspek penting dalam kesehatan lingkungan perkotaan karena udara ambien yang tercemar dapat meningkatkan risiko gangguan pernapasan, menurunkan kenyamanan aktivitas masyarakat, dan memperbesar beban kesehatan publik. Pedoman kualitas udara global menempatkan Particulate Matter 2.5 (PM2.5), Particulate Matter 10 (PM10), Ozon (O3), Nitrogen Dioksida (NO2), Sulfur Dioksida (SO2), dan Karbon Monoksida (CO) sebagai parameter penting dalam penilaian risiko kesehatan akibat pencemaran udara (World Health Organization, 2021). Kondisi tersebut relevan bagi DKI Jakarta sebagai wilayah metropolitan dengan intensitas transportasi, aktivitas perkantoran, permukiman padat, serta sumber emisi perkotaan yang tinggi. Oleh karena itu, pemantauan dan analisis kualitas udara tidak cukup hanya dipandang sebagai kegiatan pencatatan lingkungan, tetapi juga sebagai dasar penyusunan informasi peringatan dini dan kebijakan pengendalian pencemaran udara.

Di Indonesia, mutu udara ambien dikomunikasikan melalui Indeks Standar Pencemar Udara (ISPU). Berdasarkan Peraturan Menteri Lingkungan Hidup dan Kehutanan Nomor 14 Tahun 2020, ISPU merupakan angka tanpa satuan yang menggambarkan kondisi mutu udara ambien di lokasi tertentu berdasarkan dampaknya terhadap kesehatan manusia, nilai estetika, dan makhluk hidup lainnya (Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia, 2020). Dalam dataset penelitian ini, parameter yang tersedia dan digunakan terdiri dari Particulate Matter 2.5 (PM2.5), Particulate Matter 10 (PM10), Sulfur Dioksida (SO2), Karbon Monoksida (CO), Ozon (O3), dan Nitrogen Dioksida (NO2). Keenam parameter



BAB II

LANDASAN TEORI

2.1. Tinjauan Pustaka

Tinjauan pustaka pada penelitian ini disusun sebagai dasar teoritis bagi pembahasan Indeks Standar Pencemar Udara (ISPU), parameter pencemar udara, klasifikasi kualitas udara, model pembelajaran mesin, model pembelajaran mendalam, evaluasi klasifikasi, pencegahan kebocoran target, serta interpretabilitas model menggunakan SHapley Additive exPlanations (SHAP). Landasan teori ini diperlukan agar penelitian tidak hanya dipahami sebagai penerapan algoritma, tetapi juga sebagai kajian data lingkungan yang memiliki konteks kesehatan, kebijakan publik, dan metodologi komputasional.

2.1.1. Indeks Standar Pencemar Udara

Indeks Standar Pencemar Udara atau ISPU merupakan indikator yang digunakan untuk menyampaikan kondisi mutu udara ambien kepada masyarakat dalam bentuk angka tanpa satuan. Berdasarkan Peraturan Menteri Lingkungan Hidup dan Kehutanan Republik Indonesia Nomor 14 Tahun 2020, ISPU menggambarkan kondisi mutu udara ambien di lokasi tertentu berdasarkan dampaknya terhadap kesehatan manusia, nilai estetika, dan makhluk hidup lainnya (Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia, 2020). Dengan adanya ISPU, informasi kualitas udara dapat dikomunikasikan secara lebih sederhana karena nilai parameter pencemar udara yang bersifat teknis diterjemahkan ke dalam kategori mutu udara.

Kategori ISPU ditetapkan berdasarkan rentang angka resmi dalam Peraturan Menteri Lingkungan Hidup dan Kehutanan Nomor P.14/MenIhk/Setjen/Kum.1/7/2020 tentang Indeks Standar Pencemar Udara. Rentang tersebut digunakan untuk menjelaskan kategori kualitas udara yang muncul pada dataset sebelum target penelitian dibentuk.

BAB III

METODOLOGI PENELITIAN

Bab ini menjelaskan proses penelitian yang dilakukan untuk mengklasifikasikan status Indeks Standar Pencemar Udara (ISPU) DKI Jakarta. Metodologi disusun sebagai alur kerja eksperimen komputasional, mulai dari pengumpulan data sekunder, pemahaman data, pengolahan fitur, pembentukan target, pembagian data, pemodelan, evaluasi, sampai penyiapan *output* untuk BAB IV.

Dataset awal yang digunakan terdiri dari 5.538 baris dan 11 kolom dengan rentang tanggal 1 Januari 2010 sampai 28 Februari 2025. Penelitian membatasi data pada periode 1 Januari 2020 sampai 31 Desember 2024. Setelah seleksi periode, data berjumlah 1.827 observasi. Satu baris dengan kategori TIDAK ADA DATA dikeluarkan, sehingga data pemodelan final berjumlah 1.826 observasi harian.

3.1. Tahapan Penelitian

Tahapan penelitian dirancang agar setiap keputusan teknis dapat ditelusuri dari data mentah sampai *output* analisis. Alur penelitian disajikan dalam bentuk gambar agar tahapan penelitian dapat dibaca sebagai proses yang berurutan, mulai dari pengumpulan data hingga penyiapan *output* untuk BAB IV.

Model yang digunakan dalam alur penelitian adalah Random Forest, Extreme Gradient Boosting (XGBoost), Long Short-Term Memory (LSTM), dan Gated Recurrent Unit (GRU). Interpretasi model dilakukan dengan SHapley Additive exPlanations (SHAP).

BAB IV

HASIL PENELITIAN DAN PEMBAHASAN

Bab ini menyajikan hasil penelitian berdasarkan tahapan eksperimen yang telah dirancang pada BAB III. Penyajian hasil dilakukan secara berurutan mulai dari lingkungan komputasi, pemuatan dataset, pemahaman struktur data, seleksi periode, pembersihan data, pembentukan target biner, penanganan nilai kosong, feature engineering, pembagian data, pelatihan model, evaluasi model, hingga interpretasi kontribusi fitur menggunakan SHAP. Urutan tersebut digunakan agar seluruh hasil penelitian dapat ditelusuri dari proses komputasi yang dijalankan pada notebook sampai pada output yang ditampilkan dalam bentuk tabel dan visualisasi.

4.1. Library dan Lingkungan Komputasi

Eksperimen penelitian ini dijalankan menggunakan bahasa pemrograman Python pada lingkungan notebook berbasis Google Colab. Lingkungan notebook dipilih karena mendukung eksekusi kode secara bertahap, dokumentasi proses eksperimen, serta penyimpanan output dalam bentuk tabel maupun gambar. Notebook eksperimen digunakan sebagai media utama untuk melakukan pemuatan data, pembersihan data, pembentukan fitur, pelatihan model, evaluasi, dan interpretasi SHAP.

BAB V

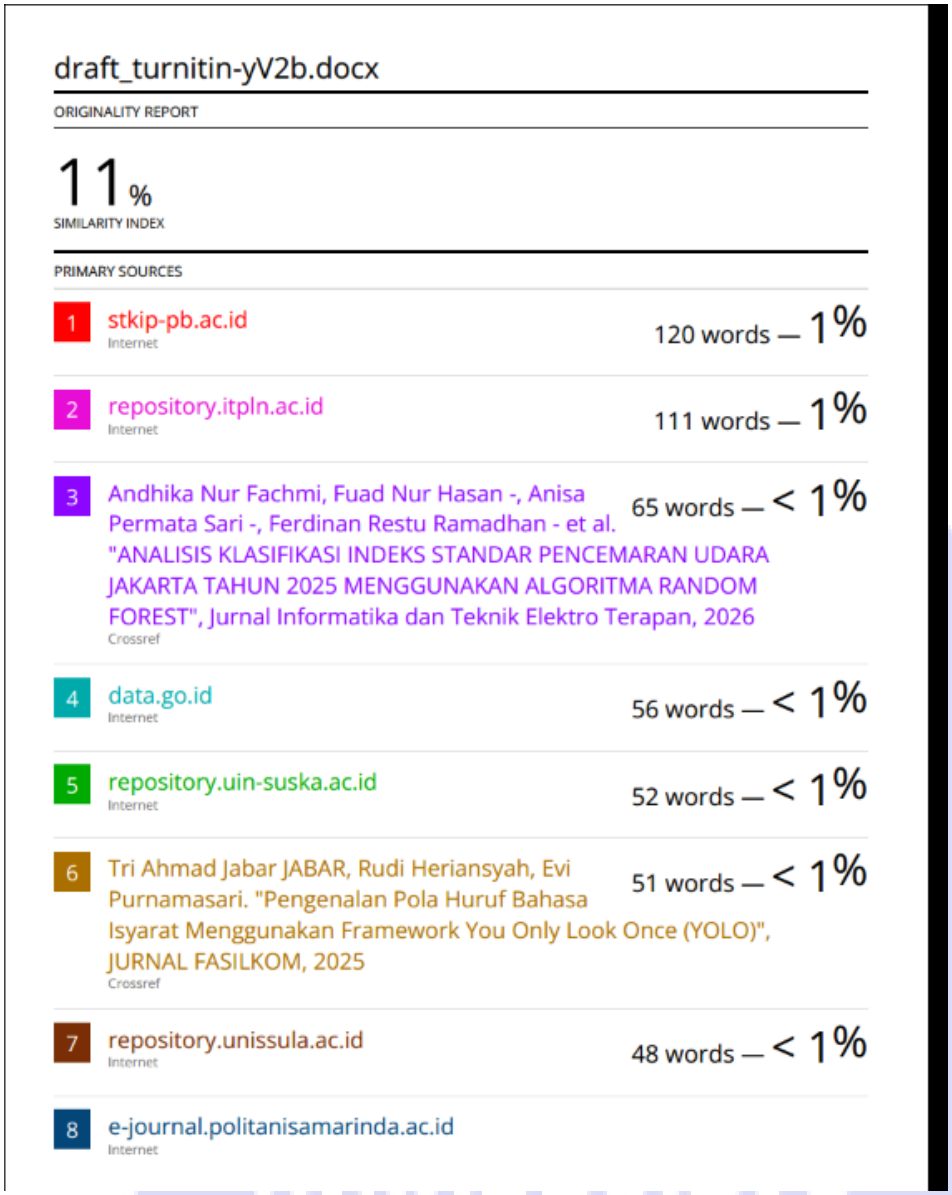
PENUTUP

5.1. Kesimpulan

Berdasarkan hasil penelitian terhadap data Indeks Standar Pencemar Udara (ISPU) DKI Jakarta periode 2020-2024, penelitian ini berhasil membangun, membandingkan, dan mengevaluasi empat model klasifikasi, yaitu Random Forest, XGBoost, LSTM, dan GRU. Target penelitian dibentuk sebagai klasifikasi biner yang terdiri dari kelas Tidak Sehat+ dan Bukan Tidak Sehat+. Kelas Tidak Sehat+ berasal dari kategori TIDAK SEHAT dan SANGAT TIDAK SEHAT, sedangkan kelas Bukan Tidak Sehat+ berasal dari kategori BAIK dan SEDANG. Dengan demikian, istilah Tidak Sehat+ dalam penelitian ini tetap diposisikan sebagai definisi operasional penelitian, bukan sebagai kategori resmi baru dalam regulasi ISPU.

Data yang digunakan dalam pemodelan berjumlah 1.826 observasi harian. Jumlah tersebut diperoleh setelah data periode 2020-2024 dipilih dari dataset awal dan satu baris berkategori TIDAK ADA DATA dikeluarkan karena tidak dapat dipetakan ke dalam target klasifikasi. Data final kemudian dibagi secara kronologis menjadi data latih tahun 2020-2023 sebanyak 1.460 observasi dan data uji tahun 2024 sebanyak 366 observasi. Pembagian kronologis digunakan agar proses evaluasi mengikuti karakter data harian berbasis waktu, yaitu model dilatih menggunakan periode yang lebih awal dan diuji pada periode setelahnya.

Rumusan masalah pertama dalam penelitian ini menanyakan perbandingan performa model pembelajaran ensemble, yaitu Random Forest dan XGBoost, terhadap model pembelajaran mendalam, yaitu LSTM dan GRU, dalam klasifikasi status ISPU Tidak Sehat+ dan Bukan Tidak Sehat+. Hasil evaluasi menunjukkan bahwa Random Forest



draft_turnitin-yV2b.docx

ORIGINALITY REPORT

11%
SIMILARITY INDEX

PRIMARY SOURCES

1	stkip-pb.ac.id Internet	120 words — 1%
2	repository.itpln.ac.id Internet	111 words — 1%
3	Andhika Nur Fachmi, Fuad Nur Hasan -, Anisa Permata Sari -, Ferdinan Restu Ramadhan - et al. "ANALISIS KLASIFIKASI INDEKS STANDAR PENCEMARAN UDARA JAKARTA TAHUN 2025 MENGGUNAKAN ALGORITMA RANDOM FOREST", Jurnal Informatika dan Teknik Elektro Terapan, 2026 Crossref	65 words — < 1%
4	data.go.id Internet	56 words — < 1%
5	repository.uin-suska.ac.id Internet	52 words — < 1%
6	Tri Ahmad Jabar JABAR, Rudi Heriansyah, Evi Purnamasari. "Pengenalan Pola Huruf Bahasa Isyarat Menggunakan Framework You Only Look Once (YOLO)", JURNAL FASILKOM, 2025 Crossref	51 words — < 1%
7	repository.unissula.ac.id Internet	48 words — < 1%
8	e-journal.politanisamarinda.ac.id Internet	

UNIVERSITAS

LAMPIRAN

Lampiran. 1 Data Awal Penelitian (5.539 Observasi)

	tanggal	stasiun	pm25	pm10	so2	co	o3	no2	max	critical	categori
2	2010-01-01	DKI1 (Bunderan HI)		60.0	4.0	73.0	27.0	14.0	73.0	CO	SEDANG
3	2010-01-02	DKI1 (Bunderan HI)		32.0	2.0	16.0	33.0	9.0	33.0	O3	BAIK
4	2010-01-03	DKI1 (Bunderan HI)		27.0	2.0	19.0	20.0	9.0	27.0	PM10	BAIK
5	2010-01-04	DKI1 (Bunderan HI)		22.0	2.0	16.0	15.0	6.0	22.0	PM10	BAIK
6	2010-01-05	DKI1 (Bunderan HI)		25.0	2.0	17.0	15.0	8.0	25.0	PM10	BAIK
7	2010-01-06	DKI1 (Bunderan HI)		30.0	3.0	22.0	19.0	11.0	30.0	PM10	BAIK
8	2010-01-07	DKI1 (Bunderan HI)		41.0	4.0	24.0	27.0	13.0	41.0	PM10	BAIK
9	2010-01-08	DKI1 (Bunderan HI)		64.0	8.0	51.0	19.0	15.0	64.0	PM10	SEDANG
10	2010-01-09	DKI1 (Bunderan HI)		55.0	5.0	39.0	23.0	16.0	55.0	PM10	SEDANG
11	2010-01-10	DKI1 (Bunderan HI)		34.0	5.0	23.0	26.0	12.0	34.0	PM10	BAIK
12	2010-01-11	DKI1 (Bunderan HI)		55.0	10.0	32.0	23.0	16.0	55.0	PM10	SEDANG
13	2010-01-12	DKI1 (Bunderan HI)		45.0	4.0	33.0	9.0	17.0	45.0	PM10	BAIK
14	2010-01-13	DKI1 (Bunderan HI)		28.0	5.0	29.0	10.0	12.0	29.0	CO	BAIK
15	2010-01-14	DKI1 (Bunderan HI)		38.0	6.0	28.0	15.0	10.0	38.0	PM10	BAIK
16	2010-01-15	DKI1 (Bunderan HI)		35.0	5.0	33.0	17.0	17.0	35.0	PM10	BAIK

Sumber: Dinas Lingkungan Hidup Provinsi DKI Jakarta melalui Satu Data Jakarta (diakses melalui Kaggle), diolah oleh penulis (2026).

Gambar A.3 menampilkan sebagian data awal penelitian yang digunakan sebagai sumber utama dalam proses analisis. Dataset merupakan data sekunder Indeks Standar Pencemar Udara (ISPU) DKI Jakarta yang mencakup periode 1 Januari 2010 sampai 28 Februari 2025 dengan total 5.539 observasi. Data memuat informasi tanggal pengamatan, lokasi stasiun pemantauan, nilai parameter pencemar udara (PM2.5, PM10, SO_2, CO, O_3, dan NO_2), nilai maksimum (max), parameter kritis (critical), serta kategori status kualitas udara. Dataset lengkap penelitian tersedia pada tautan: https://drive.google.com/file/d/10GA-CjmIl_6htHX4n-c6XeveHduLhQ9J/view?usp=sharing

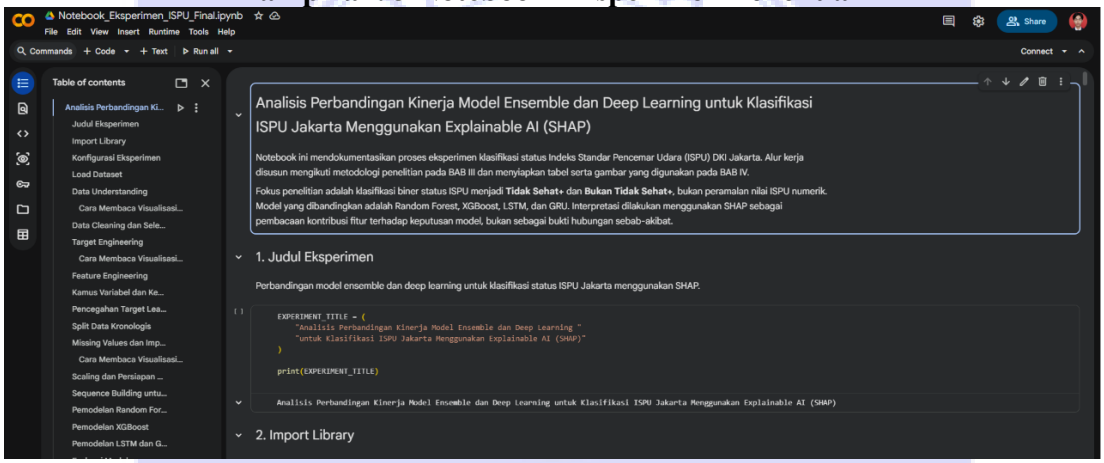
Lampiran. 2 Data Final Penelitian (1.826 Observasi)

	A	B	C	D	E	F	G	H	I	J	K
1	tanggal	stasiun	pm25	pm10	so2	co	o3	no2	max	critical	categori
2	2020-01-01	DKI5 (Kebon Jeruk)		35.0	13.0	18.0	46.0		46.0	O3	BAIK
3	2020-01-02	DKI5 (Kebon Jeruk)		22.0	15.0	24.0	102.0	7.0	102.0	O3	TIDAK SEHAT
4	2020-01-03	DKI5 (Kebon Jeruk)		44.0	17.0	21.0	63.0	7.0	63.0	O3	SEDANG
5	2020-01-04	DKI5 (Kebon Jeruk)		40.0	18.0	19.0	85.0	9.0	85.0	O3	SEDANG
6	2020-01-05	DKI5 (Kebon Jeruk)		37.0	21.0	18.0	62.0	5.0	62.0	O3	SEDANG
7	2020-01-06	DKI5 (Kebon Jeruk)		58.0	18.0	28.0	64.0	9.0	64.0	O3	SEDANG
8	2020-01-07	DKI5 (Kebon Jeruk)		36.0	18.0	39.0	66.0	9.0	66.0	O3	SEDANG
9	2020-01-08	DKI5 (Kebon Jeruk)		49.0	21.0	22.0	70.0	10.0	70.0	O3	SEDANG
10	2020-01-09	DKI4 (Lubang Buaya)		82.0	38.0	31.0	30.0	6.0	82.0	PM10	SEDANG
11	2020-01-10	DKI5 (Kebon Jeruk)		25.0	17.0	17.0	47.0	7.0	47.0	O3	BAIK
12	2020-01-11	DKI5 (Kebon Jeruk)		36.0	17.0	22.0	80.0	9.0	80.0	O3	SEDANG
13	2020-01-12	DKI5 (Kebon Jeruk)		24.0	18.0	13.0	46.0	3.0	46.0	O3	BAIK

Sumber: Diolah oleh penulis (2026).

Gambar A.4 menampilkan sebagian data final penelitian yang digunakan pada tahap pemodelan. Dataset ini merupakan hasil seleksi dan prapemrosesan data dengan membatasi periode pengamatan menjadi 1 Januari 2020 sampai 31 Desember 2024 serta mengeluarkan satu observasi berkategori TIDAK ADA DATA, sehingga diperoleh 1.826 observasi valid. Data final digunakan sebagai masukan dalam proses pembentukan model klasifikasi dan evaluasi kinerja model. Dataset lengkap dapat diakses melalui tautan: https://drive.google.com/file/d/1KwAZ1qfPZPVIafdAB4Ly_rRqr9a9KXtT/view?usp=drive_link

Lampiran. 3 Notebook Eksperimen Penelitian



Sumber: Diolah oleh penulis (2026).

(Notebook_Eksperimen_ISPU_Final.ipynb) yang digunakan sebagai media dokumentasi dan pelaksanaan seluruh tahapan penelitian. *Notebook* ini memuat alur eksperimen secara sistematis, mulai dari persiapan lingkungan kerja, pemahaman dan prapemrosesan data, pembentukan target dan fitur, pembagian data secara kronologis, penanganan *missing values*, proses pelatihan dan evaluasi model Random Forest, XGBoost, LSTM, dan GRU, hingga interpretasi hasil menggunakan *SHapley Additive exPlanations* (SHAP). Selain itu, pada bagian awal *notebook* ditampilkan identitas eksperimen beserta daftar isi yang memudahkan penelusuran setiap tahapan penelitian.

Notebook lengkap dapat diakses melalui tautan: https://drive.google.com/file/d/1zoZmP6O0RCxMeGiFhYcaEb8zaPdGfwP4/view?usp=drive_link